الجمهورية العربية السورية
جامعة أنطاكية السورية الخاصة
كلية الهندسة قسم الحاسوب
مشروع التخرج

جامعة أنطاكية السورية الخاصة
Antioch Syrian Private University

تصميم وبناء مساعد ذكي متخصص بأمراض السُكري باستخدام تقنية النماذج اللغوية الضخمة LLMs

قُدمت هذه الدراسة إستكمالاً لمتطلبات الحصول على الإجازة الجامعية من كلية الهندسة قسم الحواسيب في جامعة أنطاكية السورية الخاصة، في العام الدراسي 2024

إعداد

محمد حسن ياسين نصار **غريس سمير حداد**

إشراف

د. داوود قرة كوالله

أستاذ مدرس في كلية الهندسة جامعة انطاكية السورية الخاصة

شكر وتقدير

بسم الله الرحمن الرحيم

الحمد لله الذي بنعمته تتم الصالحات

الحمد لله الذي يسر لنا إتمام هذا العمل

اما بعد

من خلال هذا المنبر نتقدم بجزيل الشكر والامتنان وكل التقدير والإحترام إلى كل من:

- أستاذنا المشرف د.داوود قره كوللّه الذي كان ومازال بمثابة السراج المنير الذي أنار الطريق من خلال توجيهاته وارشاداته القيمة والتي رافقتنا في جميع مراحل هذا العمل، فكان له الفضل الكبير في إتمام هذه الاطروحة.
- الأستاذ الدكتور راكان رزوق والذي كان معنا منذ اليوم الدراسي الأول مُعلماً ومُرشداً، فله جزيل الشكر والإمتنان.
- السادة الكرام أعضاء لجنة المناقشة، لتفضلهم بقبول مناقشة المشروع، وعلى ما بذلوه من جهد في القرأة والمُناقشة.
- أساتذة قسم الحواسيب في جامعة انطاكية السورية الخاصة، وذلك بالتكرم بالإجابة على أسئلتنا واستفساراتنا المختلفة.
- كل من ساعدنا من قريب أو بعيد في إنجاز هذه الأطروحة ولو بكلمة طيبة، ونخص بالذكر د. مادلين عبود، د.إباء عويشق، م.معتز يعقوب.

{ ٱقۡرَأۡ بِٱسۡمِ رَبِّكَ ٱلَّذِى خَلَقَ (1) خَلَقَ ٱلۡإِنسَٰنَ مِنۡ عَلَقٍ (2) ٱقۡرَأۡ وَرَبُّكَ ٱلۡأَكۡرَمُ (3) ٱلَّذِى عَلَّمَ بِٱلۡقَلَمِ (4) عَلَّمَ ٱلۡإِنسَٰنَ مَا لَمۡ يَعۡلَمۡ (5) } [سُورَةُ العَلَقِ: 1 – 5]

اهدي ثمرة هذا العمل الى الأعزاء الأحباء، الى اقرب الناس، **الى**

الوالدين الكريمين

(ياسين، هبة)

الإخوة والأخوات

(عبد الرحمن، كنانة، حسام)

العائلة المُحبة

(خديجة، ياسر، أنور، عبد السلام، محمد، عمار)

الأساتذة الأفاضل

(د.راكان رزوق، د.داوود قره قوالله، د.مادلين العبود، د.أحمد خضور، م.لينا عرار، م.معتز يعقوب)

كل الأحباء والاصدقاء

(علي، روني، غريس، رزفان، عبادة، محمد، إلياس، أسامة، ميزر)

العزيز على القلب، عَمي وقُدوتي

(بشّار نصار)

{ إنَّ إلهَ السَّماءِ يُعطِينا النَّجَاحَ، وَنَحنُ عَبيدُهُ نَقّومُ ونَبْني } [سفر نحميا 20:2]

اهدي ثمرة هذا العمل

إلى جريح أتمنى زوال جِراحهِ.

إلى الحبّ الحقيقي و عنوان الامان...

وطني الحبيب

إلى مثلي الأول، من افتخرُ به و أحملُ اسمه بكل اعتزاز.

إلى من أعطاني دون مقابل، وآمن بقدراتي.

إلى ملجأ الامان، والداعم لي في كل خطواتي...

أبي الغالي

إلى مدرسة الحبّ و الصبر، من رسمت لي درب المستقبل بروحِها.

إلى مصدر قوتي و إلهامي.

لا تفي الكلمات مقدار امتناني لكِ...

أمي الحبيبة

إلى ضِلعي الثابت الذي لا يميل وصندوق أسراري.

إلى من تشاركتُ معهم الضحكات والأحلام، من أضاف وجودهم لذةً للحياة.

إلى أشِقاء الروح ...

إخوتي سعاد .. سارة

إلى الطيّبات منبع العطف والحنان.

إلى من كان دعائهم جزءاً من هذا الإنجاز...

جدتي سعاد .. نهاد

إلى من غرس في قلبي اطمئناناً

إلى من كان دعائهم لنجاحي كلمتهم الأولى ...

أبونا إليان..أبونا فادي

إلى من ساندوني و كانوا عوناً لي، الذين تمنوا لي الخير.

إلى من لهم مكانة كبيرة في قلبي...

أعمامي وعمتي ..أخوالي و خالاتي

إلى أخوتي التي لم تلدهم أمي..

من ضاقت عن ذكرهم الكلمات ووسعهم قلبي...

ميريام..آنجيل..كلارا..كاترين..كارولين..تريز..ريتا..لورين

إلى الذين جعلوا هذه الرحلة مليئة بالذكريات والتجارب القيمة

إلى شموع الأمل...

أنتم الأبقى طالما بقيَّ الحب...

ليجيوماريا (سيدة الزيارة)

إلى أصحاب الذكريات التي لاتُنسى، من تعلوا الضحكات برفقتهم.

إلى ثروتي الحقيقية، مهندسات المستقبل...

جوسلين.. رغد.. تسنيم.. مانويلا

إلى صديقة الطفولة صاحبة الروح المرحة الجذابة

إلى المميزة جداً في قلبي...

المهندسة ساندرا

إلى أجمل الصدف في حياتي.

لأصحاب الوجه الواحد والقلوب الصافية...

وديان..مارغو..هبة

إلى أجمل ما أهدتني إياه حياتي الجامعية، من تحلو بالوفاء وخطوا معي خطواتي.

إلى مهندسي المستقبل...

جورجيت..مايا..ريم ..علي...روني..جورج..حسن..عبادة...رزفان

إلى من أضاؤوا دربي...

إلى أصدقاء المواقف و السنين...

أصدقائي

إلى من ساعدني للوصول إلى سلم النجاح.

إلى كل من أعطاني من علمه، و زرع فيَّ حب المعرفة.

إلى من منح لقراراتي الثقة على التقدم ...

د.راكان رزوق، د.داوود قره قوالله، د.مادلين العبود، د.أحمد خضور، م.لينا عرار، م.معتز يعقوب

وكل اساتذة و مهندسي كلية هندسة الحاسوب

إلى من ثابرتْ واجتهدتْ وتحدَّتْ الصعوبات لتحقيق هذا الإنجاز.

فخورة بما وصلت إليه وأتطلع إلى المزيد.

إلى من استحق خير إهداء...

إلى نفسي

مُلخص الدراسة

في السنوات الأخيرة، أحدثت التطورات في الذكاء الاصطناعي (AI) تحولاً كبيراً في مختلف القطاعات، لاسيما قطاع الرعاية الصحية، ومن بين الابتكارات الأكثر تأثيراً في هذا المجال برزت نماذج اللغة الضخمة LLMs التي تستفيد من التعلم العميق والشبكات العصبونية لتحليل ومعالجة اللغة الطبيعية، لم تعد هذه النماذج مجرد مولدات نصوص تقليدية، بل تَطورت لتصبح أدوات قوية لتحليل البيانات الطبية وتقديم استشارات طبية دقيقة وشاملة.

يهدف مشروعنا، "مساعد ذكي متخصص في مرض السُكري باستخدام نماذج اللغة الضخمة"، إلى الاستفادة من قدرات نماذج LLMs لتطوير نظام ذكي يساعد مرضى السُكري في إدارة صحتهم بشكل أكثر فعالية وكفاءة، حيث يستخدم هذا النظام تقنيات معالجة اللغة الطبيعية NLP المتطورة لتقديم نصائح طبية مُخصصة ودقيقة تتناسب مع احتياجات كل مريض.

يُعد مرض السُكري حالة مزمنة تؤثر على قدرة الجسم على تنظيم مستويات السكر في الدم، ويتطلب مراقبة وإدارة مستمرة، ونظراً لوتيرة التقدم السريع في المجالات الطبية والكم الهائل من المعلومات الطبية التي تُنتج يومياً، يواجه المرضى ومقدمو الرعاية الصحية تحدياً في الاطلاع الدائم على أحدث مستجدات مرض السُكري، وهنا يبرز مشروعنا حيث أنه يعالج هذه المسألة من خلال تنفيذ ثلاثة أساليب رئيسية لتكييف نماذج LLMs للاستخدام الطبي في علاج السُكري، وهي، تحسين النماذج لتحقيق الدقة الطبية، هندسة التلقينات لتعزيز مخرجات النموذج بأقل قدر من التعديل، وتوليد المعزز بالاسترجاع (RAG) لدمج الإرشادات الطبية الخارجية في ردود النموذج.

من خلال دمج هذه الأساليب، يهدف مُساعدنا الذكي إلى تزويد مرضى السُكري بمعلومات دقيقة وفي الوقت المناسب، مما يحسن تجربتهم الصحية بشكل عام، كما يوضح النظام الذي طورناه إمكانات نماذج LLMs في تحويل وتغيير طرق إدارة مرض السُكري وذلك من خلال تقديم حلول مبتكرة تعتمد على أحدث تقنيات معالجة اللغة الطبيعية.

كشفت نتائج المشروع عن زيادة ملحوظة في دقة النصائح الطبية المقدمة من قبل النماذج المُقترحة في هذا المشروع (Aya، Llama3، BioMistral، Mistral، PubMed)، وتقليل الأخطاء الطبية بفضل التحسينات التي أجريناها على النماذج المُقترحة، بالإضافة إلى ذلك، وجدنا أن التفاعل بين المرضى والمساعد الذكي كان إيجابياً، حيث أبدى المستخدمون رضاهم عن سهولة استخدام النظام وفعاليته في تقديم المعلومات الضرورية.

Abstract

In recent years, advancements in artificial intelligence (AI) have significantly transformed various sectors, particularly healthcare, Among the most impactful innovations in this field are Large Language Models (LLMs) that leverage deep learning and neural networks to analyze and process natural language, These models have evolved beyond traditional text generators to become powerful tools for medical data analysis and providing precise and comprehensive medical consultations.

Our project, "Smart Assistant for Diabetes Using Large Language Models," aims to harness the capabilities of LLMs to develop an intelligent system that helps diabetes patients manage their health more effectively and efficiently, This system uses advanced natural language processing (NLP) techniques to offer personalized and accurate medical advice tailored to each patient's needs.

Diabetes is a chronic condition that affects the body's ability to regulate blood sugar levels, requiring continuous monitoring and management, Given the rapid pace of advancements in medical fields and the vast amount of medical information produced daily, patients and healthcare providers face the challenge of staying up-to-date with the latest developments in diabetes care, This is where our project steps in, addressing this issue by implementing three main approaches to adapting LLMs for medical use in diabetes treatment: enhancing models for medical accuracy, prompt engineering to optimize model outputs with minimal data, and retrieval-augmented generation (RAG) to integrate external medical guidelines into the model's responses.

By integrating these approaches, our smart assistant aims to provide diabetes patients with timely and accurate information, improving their overall health experience, The system we developed demonstrates the potential of LLMs to transform and innovate diabetes management methods by offering cutting-edge solutions based on the latest NLP technologies.

The project results revealed a significant increase in the accuracy of medical advice provided by the proposed models (Aya, Llama3, BioMistral, Mistral, PubMed) and a reduction in medical errors thanks to the enhancements we made to the proposed models, Additionally, we found that patient interaction with the smart assistant was positive, with users expressing satisfaction with the system's ease of use and effectiveness in delivering necessary information.

جدول المصطلحات

Retrieval-Augmented Generation (RAG)	توليد مُعزز بالاسترجاع
Recurrent Neural Network (RNN)	الشبكات العصبونية الإلتفافية
Natural Language Processing (NLP)	معالجة اللغة الطبيعية
Large Language Models (LLMs)	نماذج اللغة الضخمة
Named Entity Recognition (NER)	التعرف على الكيانات
Relation Extraction (RE)	تصنيف النصوص
Semantic Text Similarity (STS)	التشابه الدلالي النصي
Information Retrieval (IR)	استرجاع المعلومات
Artificial Intelligence (AI)	الذكاء الاصطناعي
Electronic Health Records (EHR)	سجلات المرضى الإلكترونية
Prompt Engineering	هندسة التلقين
Healthcare	الرعاية الصحية
Chat Interface	واجهة دردشة
Diabetes	مرض السُكري
Transformers	المحولات
Attention	الانتباه

المحتويات

1.الفصل الأول: الدراسة النظرية 1

1.1- مُقدمة عامة..... 2

1.1.1-لمحة عن مرض السُكري 3

1.1.2-مشكلة الرعاية الصحية لمرضى السُكري 4

1.1.3-هدف و مراحل الدراسة..... 5

1.2-معالجة اللغات الطبيعيةNLP 5

1.2.1- تعريف معالجة اللغات الطبيعية..... 5

1.2.2التطور التاريخي لتقنيات معالجة اللغات الطبيعية..... 6

1.2.2.1 تقنية حقيبة الكلمات Bag of Words 7

1.2.2.2 الشبكات العصبونية الإلتفافية RNNs 7

1.2.2.3 الذاكرة طويلة المدى قصيرة المدى LSTM 8

1.2.2.4 آلية الانتباه Attention..... 10

1.2.2.5 تقنية المحولات Transformers..... 11

1.3- نماذج اللغة الضخمة LLMs..... 13

1.3.1- تعريف نماذج اللغة الضخمة 13

1.3.2- بنية النماذج اللغوية الضخمة..... 14

1.3.3- مكونات النماذج اللغوية الضخمة..... 16

1.3.4- أمثلة على النماذج اللغوية الضخمة 19

1.3.5- تطبيقات النماذج اللغوية الضخمة..... 20

1.3.6- أهمية نماذج اللغة الضخمة في الرعاية الصحية..... 21

1.4- دراسة مرجعية عن نماذج اللغة الضخمة في مجال الرعاية الصحية 21

1.4.1- تحديات وفرص النماذج اللغوية البارزة في مجال الرعاية الصحيّة..... 22

1.4.2- المهام الأساسية للنماذج اللغوية الكبيرة في مجال الرعاية الصحية 23

1.4.3- النماذج المعنية وبالرعاية الصحية وخصائصها 26

1.4.4- أهمية تصميم مجموعة البيانات DataSet..... 28

1.4.5- التشابهات والاختلافات بين النماذج السابقة والنموذج الذي نطوره 29

2. الفصل الثاني: دورة حياة نموذج اللغة الضخم 30

2.1- دورة حياة النماذج اللغوية الضخمة 31

2.2- تحديد حالة الاستخدام واختيار النماذج اللغوية المناسبة..... 34
2.2.1- النموذج الأول Mistral LLM..... 34
2.2.2- النموذج الثاني BioMistral 35
2.2.3- النموذج الثالث Llama3..... 37
2.2.4- النموذج الرابع Aya..... 38
2.2.5- جدول مقارنة بين النماذج المُقترحة 40
2.3-تكميم النماذج اللغوية الضخمة 41
2.3.1- فوائد تكميم النماذج اللغوية الضخمة 41
2.3.2- التحديات المُرتبطة بتكميم النماذج اللغوية الضخمة 42
2.4- هندسة التلقين في مجال الرعاية الصحية..... 42
2.5- تقييم النماذج..... 45
2.5.1- معايير التقييم الرئيسية..... 46
2.5.2- معايير التقييم البشرية..... 49
2.5.3- التقييم الآلي مقابل التقييم البشري 49
2.5.4- المعايير المرجعية في تدريب نماذج اللغة الضخمة..... 49
2.5.4.1- المعايير المرجعية المُستخدمة لقياس أداء نماذج اللغة الضخمة 50
2.5.4.2- قيود المعايير المرجعية الحالية..... 51
2.6- استخدام تقنية RAG 52
3.الفصل الثالث: التطبيق العملي..... 55
3.1- الأدوات المستخدمة في تنفيذ المشروع 56
3.1.1-بيئة التطوير 56
3.1.2-لغة البرمجة..... 56
3.1.3-مكتبة Gradio..... 57
3.2-النموذج المقترح الأول: PDF-based RAG..... 58
3.3- النموذج المقترح الثاني: WEB-based RAG 63
3.4- تصميم واجهة Chatbot..... 66
3.5- اختبارات ونتائج 76
3.6- التحديات والآفاق المستقبلية..... 82
3.7- المراجع..... 84

فهرس الأشكال

الشكل (1) تقنيات معالجة اللغات الطبيعية.....6
الشكل (2) تقنية حقيبة الكلمات.....7
الشكل (3) بنية الشبكات العصبونية الإلتفافية RNN.....8
الشكل (4) بنية الذاكرة طويلة المدى قصيرة المدى.....9
الشكل (5) آلية الانتباه.....10
الشكل (6) بنية نماذج LLM القائمة على المحولات.....15
الشكل (7) شبكة عصبية ذات تغذية امامية.....17
الشكل (8) مهام وتطبيقات النماذج اللغوية في مجال الرعاية الصحية.....23
الشكل (9) دورة حياة مشروع الذكاء الاصطناعي التوليدي.....31
الشكل (10) مثال على التلقين باستخدام سلسلة الأفكار.....45
الشكل (11) معيار التقييم ROUGE-N.....46
الشكل (12) معيار التقييم ROUGE-L.....47
الشكل (13) آلية عمل تقنية RAG.....53
الشكل (14) استرجاع نافذة الجُملة.....60
الشكل (15) نموذج PubMed الأولي.....63
الشكل (16) نموذج PubMed المُحسن.....65
الشكل (17) رد نموذج Llama3.....66
الشكل (18) رد ثاني لنموذج Llama3.....67
الشكل (19) رد نموذج Mistral.....68
الشكل (20) رد ثاني لنموذج Mistral.....69
الشكل (21) رد نموذج BioMistral.....70
الشكل (22) رد ثاني لنموذج BioMistral.....71
الشكل (23) رد نموذج Aya.....72
الشكل (24) رد ثاني لنموذج Aya.....73
الشكل (25) رد نموذج PubMed.....74
الشكل (26) رد ثاني لنموذج PubMed.....75

فهرس الجداول

جدول (1) تلخيص للنماذج اللغوية الضخمة في مجال الرعاية الصحي.....26
جدول (2) مقارنة بين النماذج المُقترحة.....40
جدول (3) أمثلة على تلقينات جيدة وتلقينات سيئة.....44
جدول (4) تقييم أجابات النماذج.....78
جدول (5) عينة من أجابات النماذج.....80
جدول (6) مقارنة بين النماذج من حيث الدقة وسرعة الإستجابة 81

1.الفصل الأول: الدراسة النظرية

يهدف هذا الفصل إلى تقديم لمحة عن مرض السُكري، وشرح موجز حول مجموعة من تقنيات معالجة اللغات الطبيعية ابتدائاً من التقنيات القديمة وصولاً للتقنيات المُعاصرة وهي نماذج اللغة الضخمة، كما سوف نتحدث عن النماذج المختصة بمجال الرعاية الصحية.

1.1- مُقدمة عامة

تشهد التكنولوجيا تطورًا مذهلاً في مجال الذكاء الاصطناعي، وقد أسهمت هذه التطورات في تحسين العديد من جوانب حياتنا، خاصة في مجال الرعاية الصحية، ومن بين الابتكارات الأكثر تأثيرًا في هذا المجال، تأتي نماذج اللغة الضخمة التي تعتمد على تقنيات التعلم العميق والشبكات العصبونية لتحليل ومعالجة النصوص الطبيعية، هذه النماذج ليست مجرد أدوات لتوليد النصوص، بل أصبحت أدوات فعالة لتحليل البيانات الطبية وتقديم استشارات طبية دقيقة وشاملة.

نماذج اللغة الضخمة(LLMs) ، مثل عائلة النماذج المعروفة بـ GPT منOpenAI، أظهرت قدرات كبيرة في معالجة المعلومات الطبية مثل استخراج البيانات وتلخيص المقالات الطبية وإنشاء المحتوى والتنبؤ، ومع ذلك، النماذج المتاحة تجاريًا، مثلChatGPT، حيث تم تدريبها على بيانات عامة وليست مخصصة للاستخدام الطبي، مما يعني أن مخرجاتها قد تحتوي على معلومات غير دقيقة أو غير كاملة عند استخدامها في المجال الطبي، ورغم هذه التحديات، هناك إمكانيات كبيرة لاستخدام نماذج اللغة الضخمة في التطبيقات الطبية، بما في ذلك علاج مرض السُكري، يعود ذلك إلى أن الطب يتطور بسرعة مع زيادة كبيرة في حجم المعلومات الطبية المتاحة، على سبيل المثال، يتم نشر العديد من الأبحاث الجديدة كل دقيقة، مما يجعل من الصعب متابعة كل هذه المعلومات بدون استخدام تقنيات حديثة.

هناك ثلاث طرق رئيسية لتخصيص نماذج اللغة الضخمة للاستخدام الطبي في علاج مرض السُكري:

1- ضبط النموذج بدقة (Fine tunning): يتطلب هذا تعديلات على النموذج ليصبح أكثر دقة في تقديم المعلومات الطبية، ولكنه مكلف من الناحية الحسابية.
2- الهندسة التلقينيّة (Prompting Engineering) : يتضمن هذا استخدام كميات صغيرة من البيانات مع مدخلات من المستخدم لتحسين مخرجات النموذج.
3- استرجاع البيانات المدعوم بالنماذج الضخمة (RAG): هذا النظام يستخدم بيانات خارجية، مثل إرشادات العلاج، لتكملة وتحسين مخرجات النموذج الضخم، في هذا النظام، يتم تحويل الإرشادات إلى شكل يمكن للنموذج فهمه واستخدامه لتحسين الإجابات وتقليل الأخطاء.

باستخدام هذه الطرق، يمكن لنماذج اللغة الضخمة أن تصبح أداة قوية في علاج مرض السُكري، مما يساعد الأطباء والمرضى على الوصول إلى معلومات دقيقة ومحدثة بسهولة.

مشروعنا " **تصميم وبناء مساعد ذكي متخصص بأمراض السُكري باستخدام النماذج اللغوي الضخمة**" يهدف إلى الاستفادة من هذه النماذج لتطوير نظام ذكي يساعد مرضى السُكري في إدارة حالتهم الصحية بشكل أفضل وأكثر فعالية، يُعنى المشروع بتقديم حلول مبتكرة تعتمد على أحدث التقنيات في معالجة اللغة الطبيعية لتوفير استشارات طبية مخصصة ودقيقة، تتناسب مع احتياجات كل مريض على حدة.

1.1.1-لمحة عن مرض السُكري

مرض السُكري هو حالة مزمنة تصيب نظام تنظيم السكر في الجسم، يتميز بارتفاع مستويات السكر في الدم بشكل غير طبيعي، يُعدّ السكر (الجلوكوز) المصدر الرئيسي للطاقة للجسم، حيث ينقله الأنسولين، وهو هرمون ينتج عن البنكرياس، من مجرى الدم إلى الخلايا لاستخدامه، في مرض السُكري، لا ينتج البنكرياس ما يكفي من الأنسولين، أو لا يستطيع جسمك استخدام الأنسولين بشكل فعال؛ يؤدي ذلك إلى تراكم الجلوكوز في مجرى الدم، مما قد يؤدي إلى مضاعفات خطيرة [1].

أنواع مرض السُكري

هناك ثلاثة أنواع رئيسية من مرض السُكري:

- **داء السُكري من النوع الأول**

يُعرف أيضًا باسم سكري الأحداث أو السُكري المعتمد على الأنسولين، يحدث عندما يهاجم جهاز المناعة في الجسم خلايا البنكرياس التي تنتج الأنسولين، لا يملك الأشخاص المصابون بهذا النوع ما يكفي من الأنسولين، لذا فهم بحاجة إلى حقن الأنسولين للعيش.

- **داء السُكري من النوع الثاني**

هو النوع الأكثر شيوعًا، يحدث عندما يصبح الجسم مقاومًا للأنسولين أو لا ينتج البنكرياس ما يكفي من الأنسولين، يمكن السيطرة على داء السُكري من النوع الثاني في كثير من الأحيان من خلال اتباع نظام غذائي صحي وممارسة الرياضة بانتظام، وقد تتطلب بعض الحالات أدوية أو حقن الأنسولين.

- **داء السُكري الحملي**

يحدث هذا النوع من السُكري خلال فترة الحمل، عادة ما يختفي بعد الولادة، ولكن قد يكون لدى النساء المصابات به خطر متزايد للإصابة بداء السُكري من النوع الثاني في وقت لاحق من حياتهن.

علاج مرض السُكري

يعتمد علاج مرض السُكري على نوعه وشدته، تشمل خيارات العلاج ما يلي:

- تغييرات نمط الحياة: اتباع نظام غذائي صحي وممارسة الرياضة بانتظام والحفاظ على وزن صحي.
- الأدوية: هناك العديد من الأدوية الفموية التي يمكن أن تساعد في خفض مستويات السكر في الدم.
- حقن الأنسولين: يُستخدم الأنسولين في علاج مرض السُكري من النوع الأول وبعض حالات النوع الثاني.
- جراحة: نادراً ما تُستخدم جراحة زراعة البنكرياس أو خلايا بيتا لعلاج مرض السُكري من النوع الأول.

1.1.2-مشكلة الرعاية الصحية لمرضى السُكري

يُعد مرض السُكري من أكثر الأمراض المزمنة شيوعًا في العالم، حيث يُصيب الملايين من الأشخاص حول العالم، يمثل هذا المرض تحديًا كبيرًا للأنظمة الصحية، حيث يتطلب رعاية طبية مستمرة ومتابعة دقيقة لحالة المريض.

التحديات الحالية في رعاية مرضى السُكري:

- نقص المعلومات: يعاني العديد من مرضى السُكري من نقص المعلومات حول مرضهم وكيفية إدارته بشكل فعال.
- صعوبة التواصل: قد يواجه المرضى صعوبة في التواصل مع أطبائهم لطرح الأسئلة والحصول على التوجيهات اللازمة.
- عدم اتباع التعليمات الطبية: قد لا يلتزم بعض المرضى بتعليمات أطبائهم، مما قد يؤدي إلى تفاقم حالتهم.
- الحاجة إلى رعاية مخصصة: تختلف احتياجات كل مريض من مرضى السُكري، مما يتطلب نهجًا مخصصًا للعلاج والرعاية.

1.1.3-هدف و مراحل الدراسة

يهدف هذا المشروع إلى تحقيق عدة أهداف رئيسية:

- تحسين إدارة مرض السُكري: من خلال توفير استشارات طبية دقيقة تساعد الأطباء على مراقبة حالة مرضاهم واتخاذ القرارات المناسبة بناءً على بياناتهم الشخصية.
- تقديم معلومات طبية مُحدثة: بفضل قدرة النماذج اللغوية الضخمة على تحليل أحدث الأبحاث والدراسات، يمكن تقديم توصيات مبنية على أحدث المعلومات الطبية المتاحة.
- تعزيز التواصل بين المرضى والأطباء: من خلال توفير أداة تساعد المرضى على طرح الأسئلة وتلقي الإجابات بطريقة سهلة وسريعة.

وتتألف هذه الأطروحة من ثلاث فصول رئيسية، يتضمن الفصل الأول دراسة نظرية لشرح نماذج اللغة الضخمة ودورها في مجال الرعاية الصحيّة، قمنا في هذه الدراسة بالتعرف على نماذج مختلفة مثل Llama3، BioMistral، Mistral، Aya وتحديد كيفية تطبيقها في تقديم الرعاية الصحية لمرضى السُكري، ويشرح الفصل الثاني دورة حياة مشروع نموذج لغوي ضخم ويتضمن الفصل الثالث التنفيذ العلمي للنماذج المختارة عن طريق تطبيق تقنية لتحليل المعلومات (RAG، استرجاع-توليدي) من مصادر متنوعة مثل ملفات PDF الطبيّة، ومواقع الويب، كما قمنا في الفصل الثالث بتصميم واجهة المستخدم وهي واجهة تفاعلية للمساعد الذكي، حيث تتيح للمستخدمين الحصول على استشارات طبية بطريقة سهلة ومباشرة، ثم ختاما قمنا بمقارنة النتائج واختيار النموذج الأفضل.

1.2-معالجة اللغات الطبيعية NLP

1.2.1- تعريف معالجة اللغات الطبيعية

تعد NLP فرعاً من فروع الذكاء الصنعي الأكثر سرعةً في التّطوّر، تهدف إلى تزويد الآلات بالقدرة على فهم اللغات الطبيعية ومساعدة البشر في تحقيق المهام المتعلقة بها مثل الترجمة من لغة إلى أخرى، تحديد المشاعر في نص معيّن أو تلخيص فقرة معينة، ولقد طوّر العالم الإنكليزي Alan Turing الذي يُعتبر أحد روّاد الذكاء الصنعي مجموعة من المعايير تُسمّى اختبار تورينج Turing test والتي اختبرت قدرة الآلات على إظهار سلوك ذكي لا يمكن تمييزه عن سلوك الإنسان، تعدّ قدرة الآلة على فهم ومعالجة اللغات الطبيعية معياراً أساسيا لهذا الاختبار [2].

ويعتبر مفهوم تضمين الكلمات Word Embeddingهو مفهوم أساسي في NLP ويقوم على تمثيل الكلمات كأرقام بدلاً من تمثيل الكلمات ككلمات منفصلة، بحيث يتم تحويل الكلمات إلى متجهات رقمية ذات أبعاد متعددة، تُمثل هذه المتجهات معنى الكلمة وسياقها في الجملة.

تُستخدم تقنية تضمين الكلمات في مهام NLP مثل الترجمة الآلية، والتلخيص النصي، والإجابة على الأسئلة، وتوليد النصوص الإبداعية، وتحليل المشاعر، واستخراج المعلومات، وتُساعد في التعامل مع مشكلة التباين الدلالي(Semantic Ambiguity) حيث يمكن أن يكون للكلمة معاني متعددة حسب السياق.

1.2.2التطور التاريخي لتقنيات معالجة اللغات الطبيعية

تُعد تقنيات معالجة اللغة الطبيعية (NLP) من أهم مجالات الذكاء الاصطناعي، حيث تُمكننا من تحليل وفهم وإنشاء النصوص بطريقة مشابهة للبشر.

سنقوم بسرد لأشهر تقنيات معالجة اللغات الطبيعية (NLP)، مع شرح مبسط لكل تقنية، سوف نبدأ من التقنيات البسيطة القديمة، وصولاً الى التقنيات الحديثة القوية، كما هو موضح بالشكل 1.

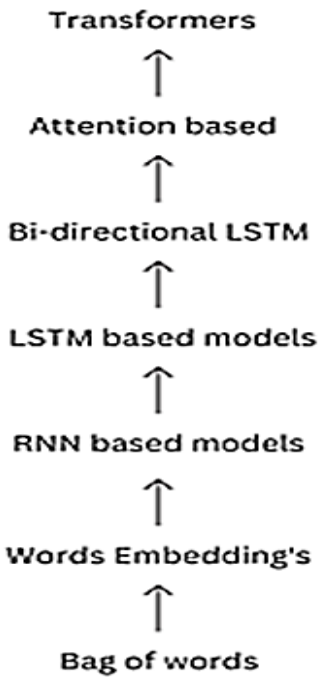

الشكل (1) تقنيات معالجة اللغات الطبيعية

1.2.2.1 تقنية حقيبة الكلمات Bag of Words

هي أول وأبسط تقنياتNLP، حيث تتعامل مع النص على اعتباره مجموعة من الكلمات الفردية المنفصلة دون مراعاة ترتيبها أو سياقها، من خلال هذه التقنية يتم تحويل كل كلمة في النص إلى تمثيل رقمي[3]، يُسمى المُتجه (vector) تُستخدم هذه المتجهات لتمثيل النص بمجموعة من الأرقام، يمكن تحليل هذه الأرقام باستخدام تقنيات التعلم الآلي، مثل تصنيف النصوص (Text classification).

مثال: الجملة "أنا أحب قراءة الكتب" يمكن تمثلها بمتجه فتُصبح كما التالي:

$$[1, 0, 0, 1, 0, 0, 0, 0, 1]$$

حيث تمثل كل قيمة وجود أو عدم وجود كلمة معينة في الجملة، يوضح الشكل 2 مثال مرئي يوضح آلية عمل تقنية حقيبة الكلمات.

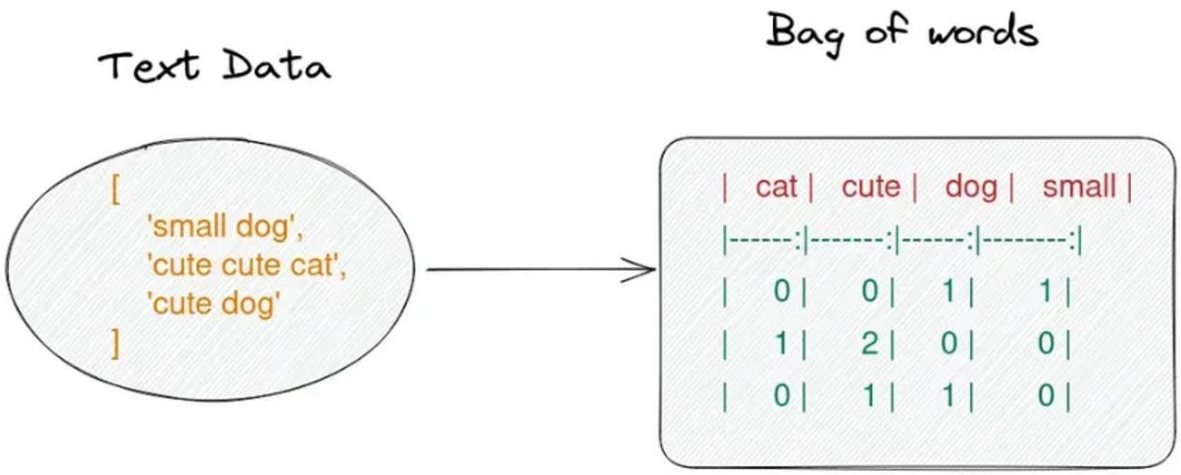

الشكل (2) تقنية حقيبة الكلمات

1.2.2.2 الشبكات العصبونية الإلتفافية RNNs

تُعد RNNs نوعًا من الشبكات العصبونية الاصطناعية مصممة للتعامل مع البيانات المتسلسلة، ففي الشبكات العصبونية التقليدية، تكون جميع المدخلات والمخرجات مستقلة عن بعضها البعض، ولكن، في الحالات التي يلزم فيها توقع الكلمة التالية في الجملة، تكون الكلمات السابقة مطلوبة، وبالتالي توجد حاجة لتذكر الكلمات السابقة، وهنا جاء دور شبكات RNN التي حلت هذه المشكلة.

تُعالج هذه الشبكات الكلمات في النص واحدة تلو الأخرى، مع مراعاة الكلمات التي سبقتها، هذا النوع من الشبكات يُتيح التعامل مع التبعيات قصيرة المدى في النص، مثل التنبؤ بالكلمة التالية في الجملة؛ تتمتع RNNs بذاكرة داخلية تسمح لها بتخزين المعلومات من المدخلات السابقة، تُستخدم هذه الذاكرة لتحديث حالة الشبكة، والتي بدورها تؤثر على كيفية معالجة المدخلات الحالية.

فعلى سبيل المثال، عند إدخال جملة "أنا أحب قراءة"، يمكن للنموذج التنبؤ بالكلمة التالية "الكتب" بدقة عالية، يوضح الشكل 3 مثال مرئي يوضح بنية الشبكات العصبونية الإلتفافية.

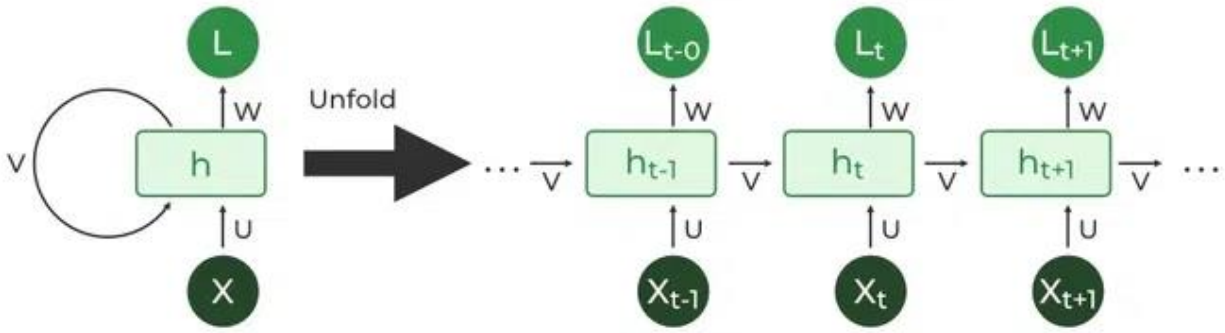

الشكل (3) بنية الشبكات العصبونية الإلتفافية RNN

1.2.2.3 الذاكرة طويلة المدى قصيرة المدى LSTM

تُعدّ ذاكرة (Long Short–Term Memory) نوعًا متطورًا من الشبكات العصبونية المتكررة، هناك مصطلح آخر يعبر عن LSTM وهو "RNNs طويلة المدى"، تُستخدمه هذه الشبكات لمعالجة البيانات التسلسلية، مثل النصوص والصور والصوت.

تتميز LSTM بقدرتها على تذكر المعلومات لفترة أطول من RNNs التقليدية، مما يجعلها مناسبة لمهام أكثر تعقيدًا مثل الترجمة الآلية والتلخيص والإجابة على الأسئلة، وتتكون من خلايا خاصة تُسمى خلايا الذاكرة، والتي تُمكنها من تذكر المعلومات من الخطوات السابقة، تحتوي كل خلية ذاكرة على ثلاثة أبواب:

- بوابة الإدخال: تُتحكم في تدفق المعلومات الجديدة إلى الخلية.
- بوابة النسيان: تُتحكم في نسيان المعلومات القديمة من الخلية.
- بوابة الخروج: تُتحكم في إخراج المعلومات من الخلية.

تتحكم هذه البوابات في تدفق المعلومات داخل الخلية، مما يسمح لـ LSTM بتذكر المعلومات المهمة ونسيان المعلومات غير المهمة.

ميزات LSTM

- تتغلب على مشكلة التلاشي التدريجي للتدرج: تُعاني RNNs التقليدية من مشكلة تسمى "التلاشي التدريجي للتدرج" حيث تصبح المعلومات القديمة غير مهمة مع مرور الوقت، تُمكن آلية الذاكرة في LSTM من التغلب على هذه المشكلة وتذكر المعلومات لفترة أطول.
- تتعامل بشكل أفضل مع التبعيات طويلة المدى: تُمكن آلية الذاكرة في LSTM من التعامل بشكل أفضل مع التبعيات طويلة المدى في البيانات التسلسلية، مما يجعلها مناسبة لمهام مثل الترجمة الآلية والتلخيص.
- تُستخدم في مجموعة واسعة من التطبيقات: بما في ذلك معالجة اللغة والكلام والتحكم بالآلات.

مثال: مع LSTM، يمكن للنموذج ترجمة جملة "أنا أحب قراءة الكتب" لتصبح "I love reading books" وبدقة عالية، مع الحفاظ على المعنى الأصلي للنص، يوضح الشكل 4 مثال مرئي يوضح بنية LSTM.

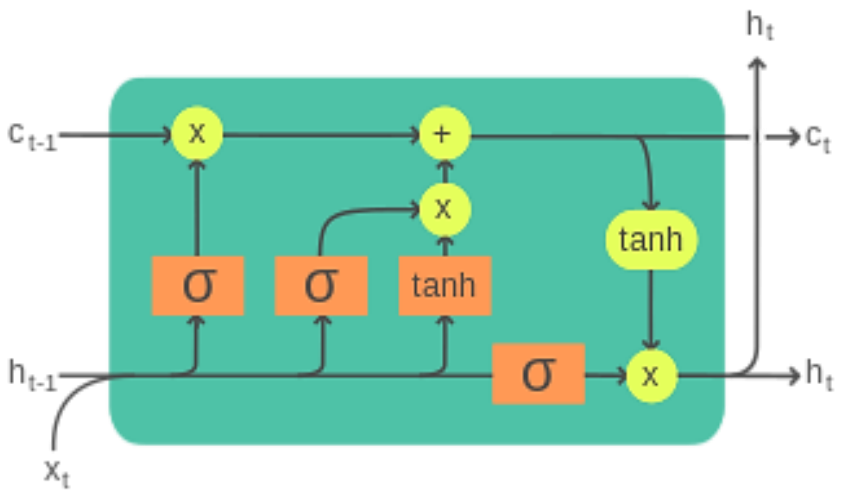

الشكل (4) بنية الذاكرة طويلة المدى قصيرة المدى

1.2.2.4 آلية الانتباه Attention

تُعدّ آلية الانتباه تقنية ثورية في مجال معالجة اللغة الطبيعية (NLP) تُمكن نماذج التعلم الآلي من التركيز على الأجزاء الأكثر أهمية من البيانات عند معالجة التسلسلات، مثل الجمل أو الفقرات، تُحسّن آلية الانتباه دقة نماذج معالجة اللغة الطبيعية في مهام مثل الترجمة الآلية والتلخيص والإجابة على الأسئلة.

تعمل آلية الانتباه، وفق التالي:

1. تحديد السياق: أولاً، تقوم آلية الانتباه بتحديد السياق لكل كلمة في التسلسل. يشمل السياق المعلومات المحيطة بالكلمة، مثل الكلمات القريبة منها في الجملة أو الفقرة.
2. حساب درجات الانتباه: بعد ذلك، تُحسب درجات الانتباه لكل كلمة في التسلسل. تُشير درجات الانتباه إلى مدى أهمية كل كلمة بالنسبة للكلمة التي يتم معالجتها حاليًا.
3. دمج المعلومات: أخيرًا، يتم دمج المعلومات من جميع الكلمات في التسلسل باستخدام درجات الانتباه. ينتج عن ذلك تمثيل موحد للبيانات يُركز على الأجزاء الأكثر أهمية.

مثال: مع آلية الانتباه، يمكن للنموذج التركيز على الكلمات "أنا" و "أحب" و "كتب" عند تلخيص جملة "أنا أحب قراءة الكتب"، مما ينتج عنه تلخيص دقيق للنص، يوضح الشكل 5 مثال مرئي يوضح بنية LSTM.

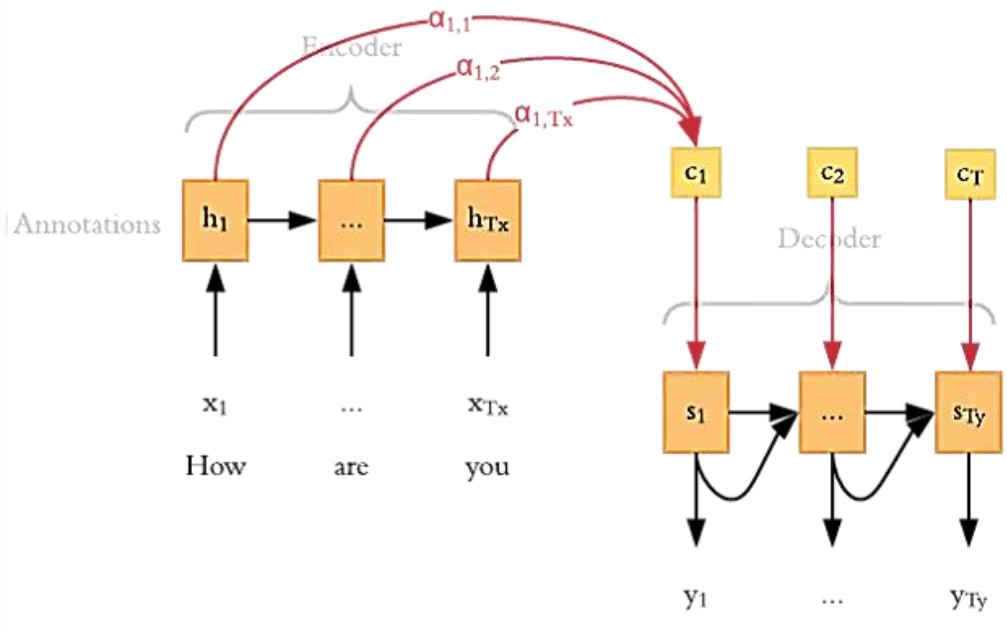

الشكل (5) آلية الانتباه

1.2.2.5 تقنية المحولات Transformers

أحدثت بنية المحولات ثورة في مجال معالجة اللغة الطبيعية، حيث تعتمد على آلية الانتباه الذاتي (Self Attention Mechanism) التي تُمكن النموذج من التركيز على الأجزاء ذات الصلة من النص أثناء معالجة كل كلمة، هذا يمكن النموذج من فهم السياق بشكل أفضل مقارنةً بالبنى التقليدية مثل الشبكات العصبونية التكرارية (RNNs).

كانت إحدى أفكار بنية المحوّلات هي الابتعاد عن معالجة الدّخل بشكل متسلسل حيث يتم تقديم المدخلات إلى الشبكة واحداً تلو الآخر كما في حالة LSTM وRNN ، تهدف المحوّلات إلى تغيير التصميم السابق من خلال توفير التسلسل الكامل للمدخلات وتغذيتها للشبكة دفعة واحدة والسماح لها بتعلّم سلسلة الدّخل كاملة، سيسمح هذا بحدوث معالجة متوازية إضافةً إلى إمكانية التوزيع على نوى أخرى أو وحدات معالجة الرسومات GPUs بالتوازي.

ميزات المُحوّلات

- تختلف المُحوّلات عن نماذج معالجة اللغات الطبيعية (NLP) التقليدية مثل الشبكات العصبونية المتكررة (RNNs) في طريقتها في معالجة البيانات التسلسلية، بحيث تُستخدم آلية الانتباه في Transformers بطريقة مختلفة عن نماذج RNNs السابقة، مما يسمح لها بمعالجة العلاقات طويلة المدى بين الكلمات بشكل أكثر فعالية.
- التقليل من الاعتماد على السياق المتسلسل: تعتمد RNNs على سياق الكلمات السابقة بشكل كبير عند معالجة الكلمة الحالية. بينما تعتمد المُحوّلات على آلية الانتباه التي تُمكنها من التركيز على الأجزاء الأكثر أهمية من السياق، مما يقلل من الاعتماد على السياق المتسلسل ويُحسّن من قدرتها على التعامل مع التبعيات طويلة المدى في البيانات.
- معالجة متوازية: تُمكن آلية الانتباه في المُحوّلات من معالجة جميع الكلمات في الجملة بشكل متوازٍ، مما يجعلها أسرع بكثير منRNNs.
- التعلم دون تحيز: تتمتع المُحوّلات بقدرة أفضل على التعلم دون تحيز مقارنةً بـ RNNs، مما يجعلها أكثر موثوقية ودقة.

آلية عمل المحولات

تعمل المحولات من خلال القيام بعمليتي الترميز وفك الترميز ، وهي كما هو موضح تالياً:

1- **الترميز**

- تبدأ العملية بالترميز، حيث يتم تحويل الكلمات الفردية في الجملة إلى متجهات(Vectors) تُمثل مَعَانِيها.
- تستخدم المحولات مُرمزاً ذاتي الانتباه، وهو نوع من الشبكات العصبونية يُمكنها التركيز على الأجزاء الأكثر أهمية من الجملة.
- ينتج عن ذلك تمثيل موحد للجملة يُركز على المعنى الأساسي.

2- **فكّ الترميز**

- بعد ذلك، يتم استخدام فكّ الترميز لإنشاء الترجمة أو الملخص أو الإجابة على السؤال.
- يُستخدم فكّ ترميز ذاتي الانتباه متوافق مع ترميز Transformer .
- ينتج عن ذلك تسلسل من الكلمات يُمثل الترجمة أو الملخص أو الإجابة على السؤال.

مثال: مع المحولات يمكن للنموذج فهم العلاقة بين الكلمات "أنا" و "أحب" و "كتب" في جملة "أنا أحب قراءة الكتب" بشكل أفضل، مما ينتج عنه ترجمة أو تلخيص أكثر دقة للنص.

أن تقنية المحولات نشأت في عام 2017 مع نشر ورقة بحثية بعنوان"Attention is All You Need" من قبل فريق Google AI [4]، تُعدّ هذه الورقة البحثية معلمًا هاما في مجال معالجة اللغة الطبيعية (NLP)، حيث قدمت نهجًا جديدًا لمعالجة البيانات التسلسلية باستخدام آلية الانتباه، حيث حققت نماذج المحولات نتائج متقدمة في العديد من مهام NLP، وكانت حجر الأساس الذي قامت عليه تقنية النماذج اللغوية الضخمة، والتي اصبحت منذ العام الماضي غنية عن التعريف ولعل أشهرها نموذج Chat GPT المقدم من شركة Open AI.

وبهذا نكون قد كونا رؤية واضحة للتطورات الحاصلة في مجال معالجة اللغات الطبيعة (NLP) ابتداءاً بتقنية حقيبة الكلمات وصولاً الى آليه الإنتباه، حيث أدت الأخيرة الى ظهور نماذج لغوية ضخمة (LLMs) حققت طفرة في عالم الذكاء الصناعي في سنوات قليلة، وعليه سوف نتعرف في القسم الثاني على النماذج اللغوية الضخمة.

1.3- نماذج اللغة الضخمة LLMs

نماذج اللغة الضخمة (Large Language Models – LLMs) تمثل واحدة من أهم التطورات في مجال الذكاء الاصطناعي ومعالجة اللغة الطبيعية (NLP)، تعتمد هذه النماذج على بنية الشبكات العصبونية العميقة، خاصة المحولات(Transformers) ، التي تمكنها من تحليل وفهم وتوليد النصوص البشرية بدقة فائقة.

1.3.1- تعريف نماذج اللغة الضخمة

نموذج اللغة الضخم هو نوع من النماذج الحاسوبية المدربة على كميات هائلة من النصوص المكتوبة (كتب إلكترونيةPDF، مواقع الويب) بلغات طبيعية، و يتم تدريب هذه النموذج باستخدام تقنيات التعلم ذاتي الإشراف (Supervise Learning) بهدف فهم السياق اللغوي وتوليد نصوص متناسقة وقابلة للفهم، حيث يتم تزويدها بكميات ضخمة من البيانات النصية، مما يتيح لها تعلم الأنماط اللغوية والعلاقات السياقية بين الكلمات، تعمل النماذج اللغوية الضخمة (LLMs) على أساسيات التعلم العميق، حيث تستفيد من بنيات الشبكات العصبونية لمعالجة وفهم اللغات البشرية، يتم تدريب هذه النماذج على مجموعات بيانات ضخمة باستخدام تقنيات التعلم ذاتي الإشراف (Supervise Learning).

يكمن جوهر وظيفتها في فهم السياق اللغوي وتوليد نصوص متناسقة وقابلة للفهم، حيث يتم تزويدها بكميات ضخمة من البيانات النصية من مصادر مختلفة (كتب إلكترونيةPDF، مواقع الويب) ، مما يتيح لها تعلم الأنماط اللغوية والعلاقات السياقية بين الكلمات، مما يسمح للنموذج باكتشاف التبعيات والعلاقات في النصوص.

1.3.2- بنية النماذج اللغوية الضخمة

تتحدد بنية النموذج اللغوي الضخم (LLM) بعدة عوامل، مثل هدف تصميم النموذج المحدد، والموارد الحسابية المتاحة، وأنواع مهام معالجة اللغة التي يتعين على النموذج اللغوي الضخم القيام بها، تتكون البنية العامة للنموذج اللغوي الضخم من العديد من الطبقات مثل طبقات التغذية الامامية وطبقات التضمين وطبقات الانتباه، و يتم التعاون بين النص المضمن بداخلها معًا لتوليد التنبؤات، من المهم أن نضع في الحسبان أن البنية الفعلية للنماذج اللغوية القائمة على المحولات يمكن أن تتغير وتتحسن بناءً على المكونات المستخدمة في بناء هذه النماذج، ونذكر منها:

- حجم النموذج وعدد المعاملات
- تمثيلات المدخلات
- آليات الانتباه الذاتي
- أهداف التدريب
- الكفاءة الحسابية
- فك الترميز وإنشاء الإخراج

وهذا ما يفسر وجود نماذج لغة ضخمة متنوعة من مثل GPT، BLOOM، RoBERTa،...،إلخ، وعلى الرغم من اختلاف كفاءة وأحجام هذه النماذج إلا أن هناك نموذج وبنية موحدة لنماذج LLM القائمة على المحولات[5]، وهي موضحة في الشكل 6.

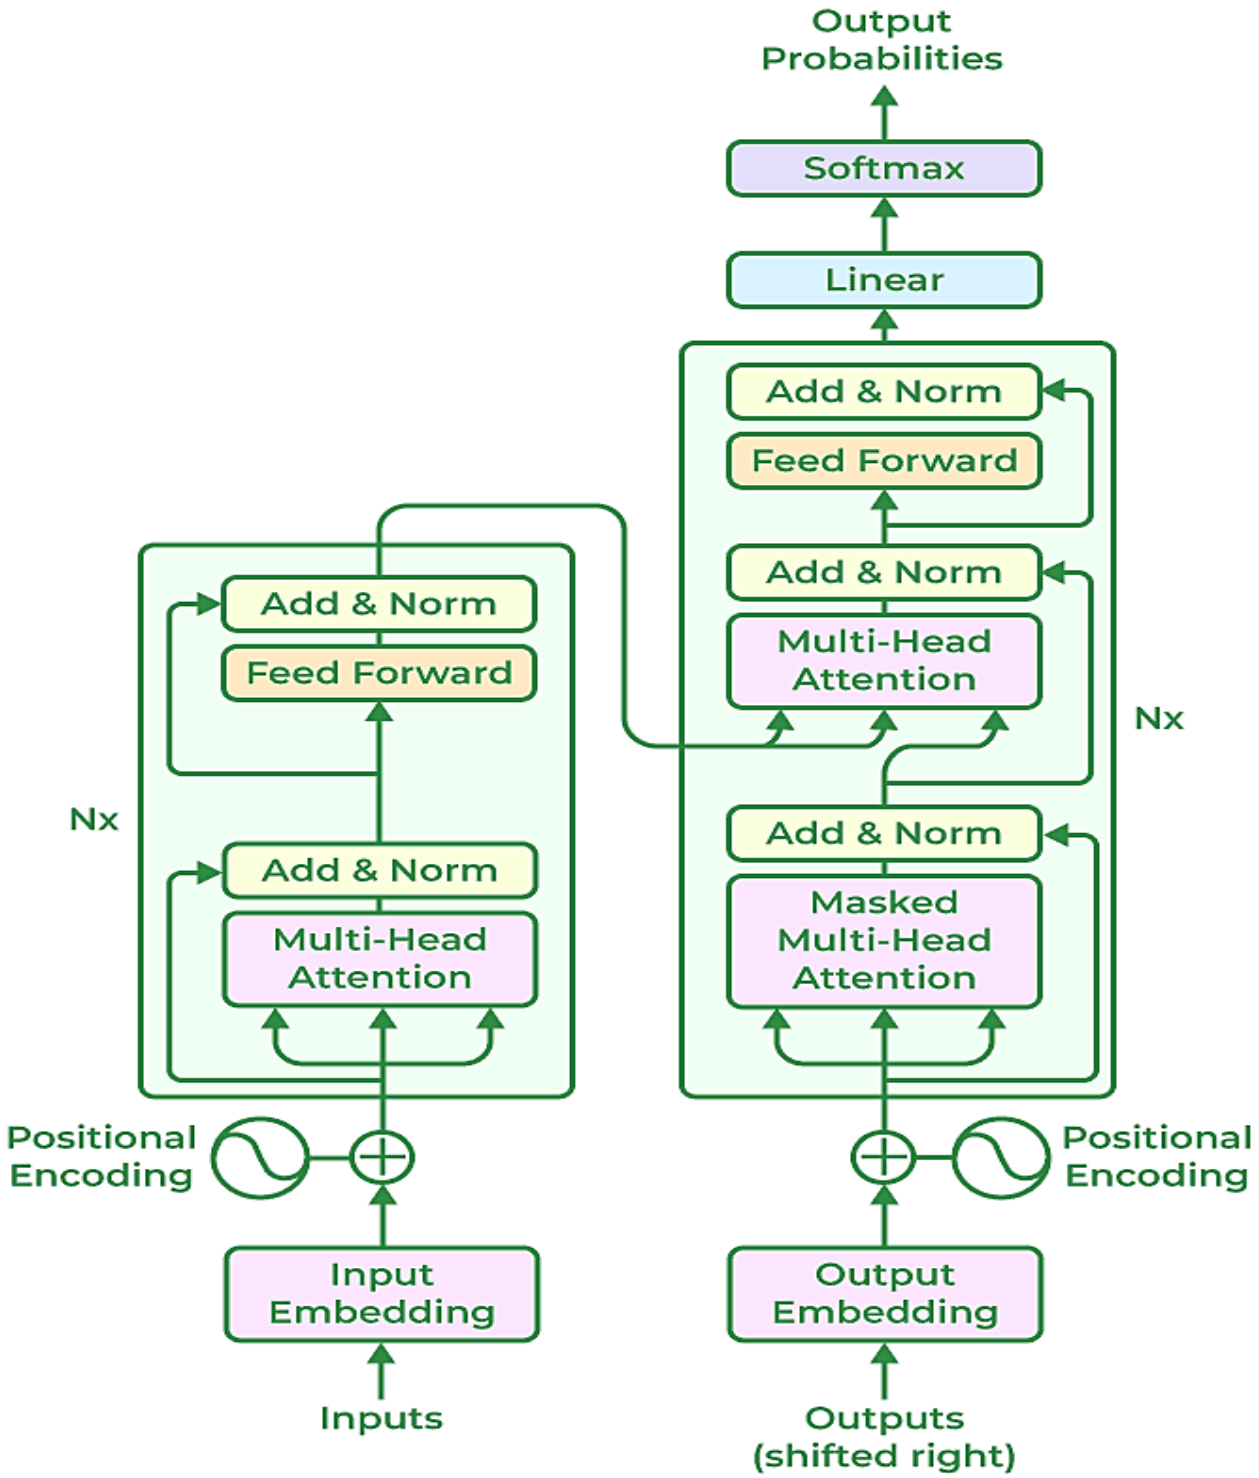

الشكل (6) بنية نماذج LLM القائمة على المحولات

1.3.3- مكونات النماذج اللغوية الضخمة

عادة ما تتبع النماذج القائمة على المحولات بنية عامة تتضمن المكونات الموضحة في الشكل (6)، وهي كالتالي:

1- تَضمين المدخلات Input Embeddings

يتم تقسيم النص المُدخل إلى وحدات أصغر(رموز – Tokens)، مثل الكلمات أو الكلمات الفرعية، ويتم تضمين وتمثيل كل رمز في متجه (vector)، تعمل خطوة التضمين هذه على التقاط المعلومات الدلالية والنحوية من المدخلات.

2- ترميز الموقع Positional Encoding

تتم إضافة ترميز الموقع (معلومات عن مواقع الرموز ضمن التسلسل النصي) إلى تضمينات المدخلات لتوفير معلومات حول مواضع الرموز لأن المحولات لا تقوم بشكل طبيعي بترميز ترتيب الرموز، وهذا يتيح للموديل معالجة الرموز مع الأخذ بالاعتبار ترتيبها وموقعها، إن إضافة معلومات حول موقع كل كلمة في الجملة إلى نموذج اللغة هي خطوة ضرورية لأن نماذج اللغات الضخمة المبنية على المحولات لا تأخذ ترتيب الكلمات بعين الاعتبار بشكل طبيعي، و في هذه الطريقة يتم تحويل كل كلمة إلى تمثيل رقمي، وبالتالي يتمكن النموذج من فهم السياق الذي تظهر فيه كل كلمة بشكل أفضل، على سبيل المثال، قد تصبح كلمة " قراءة " ممثلة بالرقم 3، بينما تصبح "أنا" ممثلة بالرقم 1، في الجملة "أنا احب قراءة الكتب"

3- المُرمز Encoder

هو الجزء الأول من النماذج اللغوية ، وهو مسؤول عن معالجة وتحليل النص المدخل، يتكون المرمز من طبقات متعددة من الشبكات العصبونية، تقوم كل طبقة بما يلي:

- تحليل الكلمات في النص المدخل.
- ربط الكلمات ببعضها البعض بناءً على معناها وسياقها.
- تخزين المعلومات المهمة من النص في "حالات مخفية".
- تُستخدم هذه "الحالات المخفية" كمدخلات للجزء التالي من نموذج اللغة (المُفكّك).

وبالتالي يفهم المرمز معنى النص ويُلخصه في "حالات مخفية"، تُستخدم هذه المعلومات لإنشاء نص جديد ذي صلة بالموضوع الأصلي.

4- آلية الانتباه الذاتي Self-Attention Mechanism

طريقة ذكية يستخدمها نموذج اللغة من أجل التركيز على أجزاء مهمة من النص المدخل، الأمر يشبه إلقاء نظرة فاحصة على أجزاء معينة من النص مع تجاهل الباقي، تُقسّم آلية الانتباه الذاتي النص إلى قطع صغيرة (رموز)، ومن ثم تُقيّم أهمية كل قطعة بناءً على سياقها (الكلمات المحيطة بها)، ومن ثم تُعطى درجة انتباه لكل قطعة، وكلما زادت الدرجة، زادت أهمية القطعة، و يركز النموذج بعد ذلك على القطع ذات درجات الانتباه العالية، ويستخدمها لفهم معنى النص بشكل أفضل، على سبيل المثال، إذا كان LLM يترجم جملة، فقد يركز على الكلمات الرئيسية في الجملة بدلاً من الكلمات غير المهمة مثل ("و"،"أو"،"إن"،"حيث"،"هو"...إلخ)

5- الشبكة العصبونية ذات التغذية الامامية Feed-Forward Neural Network

الشبكات العصبونية ذات التغذية الامامية هي نوع من الشبكات العصبونية التي تُستخدم للتعلم من البيانات، وتتكون من طبقات متعددة من العقد، كل عقدة متصلة بالعُقد الأخرى في الطبقات المجاورة، تتلقى كل عقدة بيانات من العقد في الطبقة العلوية البيانات النصية كدخل، ومن ثم تعالج هذه البيانات باستخدام وظيفة تنشيط غير خطية (تابع التنشيط Activation Functions)، ثم ترسل النتائج إلى العقد في الطبقة التالية، وتستمر كل طبقة من طبقات الشبكة بتمرير النتائج حتى يتم مسح الشبكة بشكل امامي من الأعلى للأسفل، نرفق تالياً شكل يوضح شبكة عصبية ذات تغذية امامية:

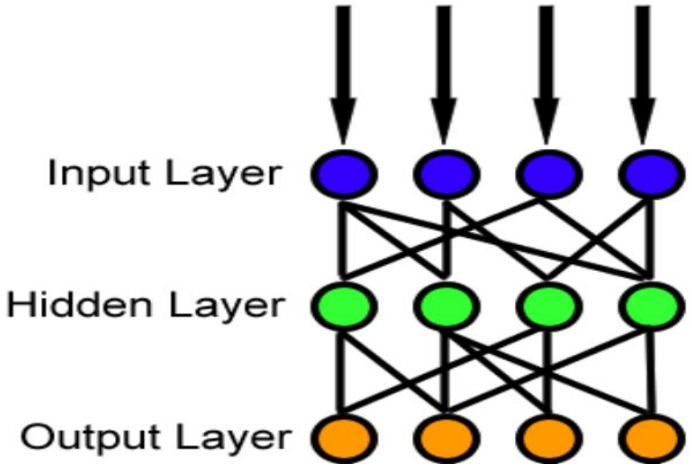

الشكل (7) شبكة عصبية ذات تغذية امامية

في سياق النماذج اللغوية الضخمة، تُستخدم الشبكات العصبونية ذات التغذية الامامية بعد آلية الانتباه الذاتي، بحيث تحلل المعلومات التي ركزت عليها آلية الانتباه الذاتي، وبه تتعلم التفاعلات المُعقدة بين الكلمات في النص.

6- طبقات فك الترميز Decoder Layers

في بعض النماذج اللغوية، مثل نماذج الترجمة الآلية، نجد مكونًا مهمًا يُعرف باسم طبقات فك الترميز، تُلعب هذه الطبقات دورًا أساسيًا في إنشاء مخرجات تسلسلية، مثل جملة مترجمة، بناءً على النص المدخل، تبدأ عملية فك الترميز بإنشاء كلمة واحدة بشكل عشوائي، بعد ذلك، تستخدم آلية الانتباه الذاتي من أجل التركيز على الكلمات التي تم إنشاؤها مسبقًا في التسلسل، بعد ذلك وبناءً على الكلمات التي ركزت عليها آلية الانتباه الذاتي، تتنبأ طبقات فك الترميز بالكلمة التالية في التسلسل، ونستمر في تكرار هذه العملية حتى يتم إنشاء التسلسل الكامل للمخرجات.

7- الانتباه المتعدد الرؤوس Multi-Head Attention

هي تقنية ذكية تُستخدم في النماذج اللغوية المبنية على المحولات من أجل فهم العلاقات المعقدة بين الكلمات تقوم هذه التقنية بتقسيم الجملة إلى أجزاء صغيرة (مثل الكلمات)، ثم يحسب "درجة الانتباه" لكل جزء، تُشير هذه الدرجة إلى مدى أهمية الجزء لفهم معنى الجملة، ولا يعتمد الانتباه متعدد الرؤوس على طريقة واحدة فقط لتحديد درجات الانتباه، بل يستخدم عدة طرق بشكل متزامن، وبالتالي يتمكن النموذج من فهم أنواع مختلفة من العلاقات بين الكلمات، مثل العلاقات السببية والعلاقات المكانية والعلاقات الزمنية.

على سبيل المثال الجملة "ذهبتُ إلى المتجر لشراء حليب" تتحول لتصبح القطع "ذهبتُ"، "إلى"، "المتجر"، "لشراء"، "حليب"، ومن ثم يتم تطبيق رؤوس أنتباه كالتالي:

- رأس الانتباه الأول: يُركز على "ذهبتُ" و "المتجر" لفهم من قام بالذهاب وإلى أين.
- رأس الانتباه الثاني: يُركز على "لشراء" و "حليب" لفهم سبب الذهاب إلى المتجر.

في النهاية يَدمج النموذج نتائج رؤوس الانتباه المختلفة لفهم معنى الجملة بشكل كامل.

8- تطبيع الطبقة Layer Normalization

يتم تطبيق تطبيع الطبقة بعد كل مكون فرعي أو طبقة في بنية المحول، مما يساعد في استقرار عملية التعلم ويحسن قدرة النموذج على التعميم عبر مدخلات مختلفة، كما يُحسّن من استقرار عملية التعلم، ويُقلّل من احتمالية انفجار الانحدار (مشكلة شائعة في التعلم العميق)،و كمثال على تطبيع الطبقة: لنفترض أن مُخرجات طبقة مُعينة في نموذج محول هي قيم تتراوح بين 0 و 100، يُطبّق تطبيع الطبقة على هذه القيم لضمان بقاء جميع القيم ضمن نطاق معين، بين 0 و 1، يُساعد ذلك على منع بعض القيم من أن تصبح كبيرة جدًا أو صغيرة جدًا، مما قد يُؤثّر سلبًا على عملية التعلم.

9- طبقات الإخراج Output Layers

هي آخر جزء من نموذج اللغة، وهي مسؤولة عن تحويل المعلومات التي تم معالجتها من قبل الطبقات السابقة إلى شكل قابل للفهم، تعتمد طبقات الإخراج على المهمة التي يقوم بها نموذج اللغة، و على سبيل المثال، في الترجمة الآلية تُستخدم طبقات الإخراج لتحويل الجملة المترجمة من لغة إلى أخرى، وفي تلخيص النصوص تُستخدم طبقات الإخراج لتحديد الجمل الأكثر أهمية في النص وتلخيصها.

1.3.4- أمثلة على النماذج اللغوية الضخمة

سوف نتعرف الآن على بعض النماذج اللغوية الضخمة الشهيرة التي تم تطويرها وتحسينها في السنوات القليلة الماضية، هذه النماذج تختلف من حيث الحجم والإستخدام، هي:

- **GPT-4 & GPT-3**

GPT هي اختصار (Generative Pre-trained Transformer) وتعني المحول التوليدي المُدرب مسبقًا، استخدمت شركة Open AI هذه التقنية من أجل انتاج النموذج الشهير GPT3 و نسخته المُحسنة GPT4 ، وهما من أبرز نماذج اللغة الضخمة، حيث يعتمد هذان النموذجان على بنية المحولات ويحتويان على مليارات المعلمات، مما يجعلهما قادرين على توليد نصوص بشرية بدقة عالية وتنفيذ مجموعة واسعة من المهام اللغوية [6].

- **BERT**

طورته Google، ويعتمد على تقنية الانتباه ثنائي الاتجاه، مما يتيح له فهم السياق اللغوي بشكل أعمق، ويستخدم BERT في العديد من تطبيقات معالجة اللغة الطبيعية مثل تصنيف النصوص، واستخراج المعلومات، وترجمة النصوص [7].

- **RoBERT**

الاسم الكامل لهذا النموذج هو (Robustly Optimized BERT Pretraining Approach) ويعني نهج التدريب المسبق لـBERT ، يعتبر RoBERTa إصدارًا محسنًا من نموذج BERT الذي تم تطويره بواسطة Facebook AI Research [8].

- **BLOOM**

هو أول نموذج لغوي ضخم متعدد اللغات تم إنشاؤه من خلال تعاون مؤسسات وباحثين مختلفين جمعوا خبراتهم لتطوير هذا النموذج الذي يشبه بنية GPT-3 [9].

1.3.5- تطبيقات النماذج اللغوية الضخمة

تُستخدم نماذج اللغة الضخمة في مجموعة واسعة من التطبيقات تشمل:

- الترجمة الآلية: تحسين جودة الترجمة بين اللغات المختلفة.
- توليد النصوص: إنشاء محتوى مكتوب مثل المقالات والقصص الإخبارية.
- تحليل المشاعر: فهم وتحليل مشاعر المستخدمين من النصوص.
- البحث والإجابة: تطوير محركات البحث والأنظمة التي تقدم إجابات دقيقة استنادًا إلى الاستفسارات النصية.
- الرعاية الصحية: تحليل السجلات الطبية وتقديم توصيات علاجية.

1.3.6- أهمية نماذج اللغة الضخمة في الرعاية الصحية

تعتبر نماذج اللغة تطورًا هائلًا في مجال الذكاء الاصطناعي، حيث تُمكن هذه النماذج من تحليل كميات هائلة من البيانات بسرعة وكفاءة، مما يتيح استخدامها في تطبيقات متعددة مثل، معالجة اللغة الطبيعية، البحث العملي، التعليم وأخيراً وليس أخراً الرعاية الصحية، وفي هذا السياق، يمكن لنماذج اللغة الضخمة أضافة العديد من الفوائد والتحسينات في مجال الرعاية الصحيّة، وكمثال على هذه الفوائد هو التالي:

- تشخيص الأمراض: تُستخدم LLMs لتحليل البيانات الطبية، مثل الصور الطبية والسجلات الصحية الإلكترونية، لتحديد الأمراض والتشخيصات المحتملة بشكل أكثر دقة وكفاءة.
- الدعم النفسي: تُستخدم LLMs لتوفير دعم نفسي للمرضى، وتقديم الاستشارة، وتحسين الصحة العقلية بشكل عام.
- البحث الطبي: تُستخدم LLMs لتحليل كميات هائلة من البيانات الطبية، واكتشاف أنماط جديدة، وتسريع عملية الاكتشاف الطبي.
- تعليم الرعاية الصحية: تُستخدم LLMs لتوفير تعليم تفاعلي للطلاب في مجال الرعاية الصحية، وتخصيص تجربة التعلم، وتحسين مهاراتهم.

وبما أن مرض السُكري يعد من أشهر الأمراض المزمنة الخطيرة التي تُؤثّر على ملايين الأشخاص حول العالم، فكان لابد من الاستفادة من محاسن النماذج اللغوية في مجال الرعاية الصحية [10] من أجل تحسين منظومة رعاية مرض السُكري، وهذا ما سوف نركز عليه في هذه الأطروحة، وهو إنشاء مساعد ذكي متخصص ذو معرفة طبية عامة، وفي نفس الوقت متخصص بأمراض السُكري.

1.4- دراسة مرجعية عن نماذج اللغة الضخمة في مجال الرعاية الصحية

في السنوات الأخيرة، شهدنا تقدمًا ملحوظًا في مجال نماذج اللغة الضخمة .(LLMs) أصبحت هذه النماذج قادرة على أداء مهام متنوعة [11]، بما في ذلك:

- معالجة اللغة الطبيعية :(NLP) يمكن للنماذج اللغوية الكبيرة فهم اللغة البشرية وإنشاءها، بما في ذلك الترجمة الآلية، والتلخيص، والإجابة على الأسئلة.
- المعرفة العلمية: يمكن للنماذج اللغوية الكبيرة الوصول إلى المعلومات من العالم الحقيقي ومعالجتها من خلال بحثGoogle ، والحفاظ على استجابتها متسقة مع نتائج البحث.

- الامتحانات الطبية: يمكن للنماذج اللغوية الكبيرة الإجابة على أسئلة الامتحانات الطبية بدقة عالية.

من أبرز نماذج اللغة الضخمة في مجال الرعاية الصحيّة:

- GPT-4: نماذج اللغة الضخمة التي تم تطويرها بواسطة OpenAI. زاد حجم نماذج اللغة الضخمة 5000 مرة في السنوات الخمس الماضية، مما أدى إلى ظهور سلوكيات جديدة وقدرات متميزة.
- Med-PaLM 2: نموذج اللغة الكبيرة الذي تم تطويره بواسطة Google، والذي تم تصميمه خصيصًا للمجال الطبي. تمكن Med-PaLM 2 من تحقيق دقة تزيد عن 85٪ في الإجابة على أسئلة الامتحان الطبي الأمريكي (USMLE) بأسلوب MedQA .

1.4.1- تحديات وفرص النماذج اللغوية البارزة في مجال الرعاية الصحيّة

- يواجه استخدام النماذج اللغوية الكبيرة في الرعاية الصحية عددًا من التحديات، أحد أهم هذه التحديات هو قلة البيانات المتاحة للتدريب على هذه النماذج، وغالبًا ما تكون البيانات الطبية حساسة ويتم حمايتها بشكل صارم، مما يجعل من الصعب جمع كميات كبيرة من البيانات اللازمة لتدريب النماذج اللغوية الكبيرة.
- القدرة على تفسير النتائج هي تحدٍّ آخر يواجه استخدام النماذج اللغوية الكبيرة في الرعاية الصحية، وغالبًا ما تكون النتائج التي تولدها هذه النماذج معقدة يصعب فهمها، وقد يؤدي ذلك إلى صعوبة ثقة مقدمي الرعاية الصحية في هذه النتائج واستخدامها في اتخاذ القرارات.

على الرغم من هذه التحديات، إلا أن النماذج اللغوية الكبيرة تقدم أيضًا العديد من الفرص لتعزيز الرعاية الصحية، على سبيل المثال، يمكن استخدام هذه النماذج لتحسين دقة التشخيص من خلال تحليل البيانات الطبية المعقدة وتحديد الأنماط التي قد لا يتمكن مقدمو الرعاية الصحية من رؤيتها بمفردهم، يمكن أيضًا استخدام النماذج اللغوية الكبيرة لتطوير أنظمة دعم القرار التي تساعد مقدمي الرعاية الصحية على اختيار أفضل مسار علاجي لمرضاهم، بالإضافة إلى ذلك، يمكن استخدام هذه النماذج لتطوير أدوات تواصل جديدة تسمح للمرضى بالتواصل مع مقدمي الرعاية الصحية بشكل أكثر فعالية.

1.4.2- المهام الأساسية للنماذج اللغوية الكبيرة في مجال الرعاية الصحية

لقد تم بذل جهود عديدة لتطبيق معالجة اللغة الطبيعية (NLP) أو النماذج اللغوية الكبيرة (LLMs) على الرعاية الصحية، وفي المراحل الأولى، ركزت الدراسات بشكل أساسي على المهام الأساسية، بما في ذلك التعرف على الكيانات المسماة الطبية (NER) واستخراج العلاقات (RE) وتصنيف النصوص (TC) والتشابه الدلالي النصي (STS)، وذلك بسبب التحديات المرتبطة بالوصول إلى مجموعات بيانات طبية متنوعة وتعقيد المجال الطبي وقيود قدرات النماذج [12].

يوضح الشكل 8 المهام والتطبيقات التي تقوم بها النماذج اللغوية في مجال الرعاية الصحية

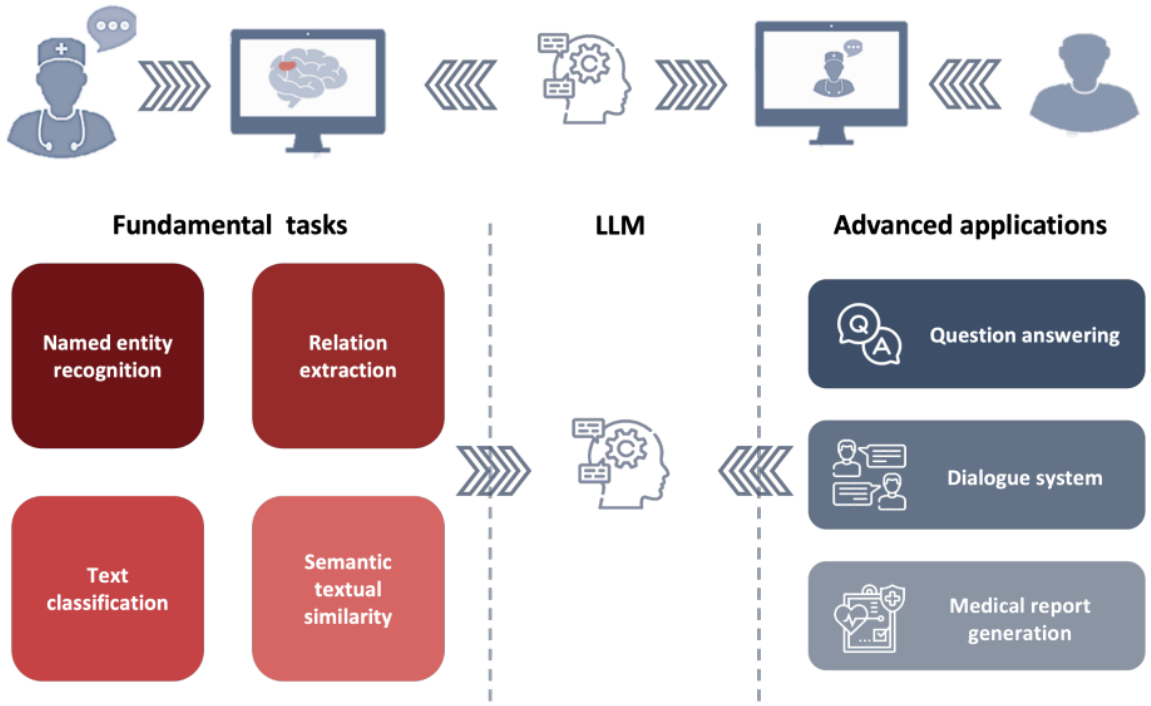

الشكل (8) مهام وتطبيقات النماذج اللغوية في مجال الرعاية الصحية

لقد تم تطبيق معالجة اللغة الطبيعية (NLP) أو النماذج اللغوية الكبيرة (LLMs) على نطاق واسع في مجال الرعاية الصحية ففي البداية، ركزت الدراسات على المهام الأساسية لبناء الأساس للتطبيقات الأكثر تعقيدًا [13]. فيما يلي بعض الأمثلة.

1. التعرف على الكيانات المسماة واستخراج العلاقات للرعاية الصحية NER & RE

باستخراج المعلومات الطبية مثل التحاليل، الامراض، الأدوية، الإجراءات الطبية والمعلومات الشخصية مثل العمر والطول والوزن من بيانات المريض النصية، يمكن تخزين هذه المعلومات في قواعد البيانات من أجل تحليلها وإجراء المقارنات وتطبيق القواعد الطبية من أجل إجراء التشخيص ووضع الخطط العلاجية.

2. تصنيف النصوص للرعاية الصحية Text Classification

هدف التصنيف النصي (TC) هو تعيين علامات لنصوص بأطوال مختلفة، مثل العبارات والجمل والفقرات والمستندات، ففي مجال أبحاث الرعاية الصحية، يتم جمع كمية كبيرة من بيانات المرضى في صيغة إلكترونية، بما في ذلك حالة المرض والسجل الدوائي وفحوصات المختبر ونتائج العلاج، وهي مصدر قيم للمعلومات للتحليل.

اقترحت دراسة بحثية [14] طرقًا تعتمد على خليط من الذاكرة طويلة المدى قصيرة الأجل (LSTM) والوحدات المتكررة ثنائية الاتجاه (Bi-GRU) لتحقيق تصنيف النصوص الطبية، وهناك مثال آخر هو AMuLaP [15] الذي يقترح التعليم الآلي متعدد العلامات القليل للتصنيف.

3. التشابه الدلالي النصي للرعاية الصحية Semantic Textual Similarity

التشابه الدلالي النصي هو طريقة لقياس مدى تشابه معنى عبارتين أو جملتين، ففي مجال الرعاية الصحية، يتم استخدام هذا التشابه في كثير من الأحيان لدمج المعلومات من مصادر مختلفة، خاصة في السجلات الصحية الإلكترونية (EHR) وقد أظهرت التحديات التي أجريت أن هذا التشابه يمكن أن يساعد في تقليل الأخطاء ومشاكل التنظيم في السجلات الصحية الإلكترونية الناتجة عن النسخ واللصق أو استخدام القوالب [16].

4. الإجابة على الأسئلة للرعاية الصحية Question Answering

يمكن أن تكون الإجابة على الأسئلة مفيدة جدًا للمختصين الطبيين للعثور على المعلومات الضرورية في الملاحظات أو المراجع الطبية، بالإضافة إلى توفير المعرفة الأساسية بالرعاية الصحية للمرضى، ومع ظهور النماذج اللغوية الكبيرة القوية، تم تقديم طرق تعتمد على المطالبات لحل مهام مختلفة عن طريق صياغتها كأسئلة وإجابات، وعلى سبيل المثال، حقق"Med-PaLM 2" ، وهو نموذج مجال الرعاية الصحيةLLM ، درجة تصل إلى 86.5٪ على مجموعة بيانات USMLE [17] .

5. أنظمة الحوار للرعاية الصحية Dialogue System

تصنف أنظمة الحوار بشكل عام إلى فئتين: أنظمة الحوار الموجهة بالمهام والمفتوحة المجال، حيث تم تصميم أنظمة الحوار الموجهة بالمهام لمعالجة قضايا محددة في الرعاية الصحية، مثل أدلة المستشفى أو استشارات الأدوية، وفي المقابل تُعطي أنظمة الحوار المفتوحة المجال الأولوية للتحدث مع المرضى دون أي مهام محددة وأظهرت دراسة أن المرضى الذين شاركوا في مشروع للرعاية الصحية عن بعد لديهم درجات أقل للاكتئاب والقلق والتوتر، وشهدوا انخفاضًا بنسبة 38٪ في دخول المستشفى [18] .

6. إنشاء التقارير الطبية من الصور Generation of Medical Reports from Images

تساعد هذه القدرة أطباء الأشعة في اتخاذ القرارات السريرية وتقلل من عبء كتابة التقارير من خلال صياغة تقارير تلقائية تصف كل من الحالات الشاذة والنتائج الطبيعية ذات الصلة، وهناك أمثلة على ذلك مثل ChatCAD و ChatCAD+ وهما أنظمة متكاملة تستخدم النماذج اللغوية الكبيرة الموجودة بالفعل، بدلاً من كونها نماذج لغوية كبيرة بحد ذاتها.

1.4.3- النماذج المعنية وبالرعاية الصحية وخصائصها

هناك العديد من نماذج الذكاء الاصطناعي المتقدمة التي تم تطويرها خصيصًا للتطبيقات الصحية، وكل منها يتميز بخصائص معينة تجعله مناسبًا لمهام محددة في المجال الطبي، فيما يلي أبرز هذه النماذج.

Model Name	Base	Para. (Billion)	Features
GatorTron[19]	Transformer	0.3, 3.9, 8.9	Training from scratch
Codex-Med[20]	GPT-3.5	175	CoT, Zero-shot
Galactica[21]	Transformer	1.3, 6.4, 30, 120	Reasoning, Multidisciplinary
Med-PaLM[22]	Flan-PaLM	540	CoT, Self-consistency
GPT-4-Med[23]	GPT-4	---	no specialized prompt crafting
DeID-GPT[24]	GPT-4	---	De-identifying
ChatDoctor[25]	LLaMA	7	Retrieve online, external knowledge
DoctorGLM[26]	ChatGLM	6	Extra prompt designer
MedAlpaca[27]	LLaMA	7, 13	Adapt to Medicine
BenTsao[28]	LLaMA	7	Knowledge graph
PMC-LLaMA[29]	LLaMA	7	Adapt to Medicine
Visual Med-Alpaca [30]	LLaMA	7	multimodal generative model, Self-Instruct
BianQue[31]	ChatGLM	6	Chain of Questioning
Med-PaLM 2[32]	PaLM 2	340	Ensemble refinement, CoT, Self-consistency
GatorTronGPT[33]	GPT-3	5, 20	Training from scratch for medicine
HuatuoGPT[34]	Bloomz	7	Reinforced learning from AI feedback
ClinicalGPT[35]	BLOOM	7	multi-round dialogue consultations
MedAGI[36]	MiniGPT-4	---	multimodal, AGI
LLaVA-Med[37]	LLaVA	13	multimodal, self-instruct, curriculum learning
OphGLM[38]	ChatGLM	6	multimodal, Ophthalmology LLM
SoulChat[39]	ChatGLM	6	Mental Healthcare
Med-Flamingo [40]	Flamingo	80	multimodal, Few-Shot generative medical VQA

جدول (1) تلخيص للنماذج اللغوية الضخمة في مجال الرعاية الصحي

و من بين العديد الموضحة في الجدول السابق، سوف نشير إلى أهم خمس نماذج(خصائصها، ميزاتها) وأفضلها في مجال الرعاية الصحية.

أفضل النماذج LLM في الرعاية الصحية

1. GatorTron

يركز نموذج GatorTron على تحسين مهام معالجة اللغة الطبيعية (NLP) على مستوى الجملة والمستند، مثل الاستنتاج اللغوي الطبي والأسئلة والأجوبة الطبية، حيث أظهر GatorTron تحسينات كبيرة في هذه المهام، مما يشير إلى أن نماذج المحولات الأكبر (مثل GatorTron) أكثر فائدة لمهام NLP واسعة النطاق، كما أن GatorTron على فهم اللغة الطبية بشكل دقيق، وقد لا يكون مناسبًا لمهام NLP الأخرى مثل إنشاء النصوص الإبداعية.

2. Codex-Med

هدفت دراسة Codex-Med إلى التحقيق في فعالية نماذج GPT-3.5 لأداء المهام المتعلقة بالمجال الصحي، كما استكشفت الدراسة أيضًا ثلاثة سيناريوهات مختلفة للتعليم الموجه، وهي:

- CoT (Chain of Thought)
- ICL (In-Context Learning)
- RAG (Retrieval Augmentation Generation)

وفقًا للدراسات السابقة، حقق الخبراء البشر أداءً بنسبة دقة 87 % و 90 % و 78% على مجموعات البيانات USMLE و MedMCQA و PubMedQA على التوالي، كما وجدت دراسة Codex-Med أن نموذج Codexحقق مع CoT دقة 60.2% و62.7% و78.2%على نفس مجموعات البيانات، وعليه أظهر نموذج Codex إمكانيات واعدة في مهام الرعاية الصحية، لكنها تتطلب المزيد من التطوير لتحل محل الخبراء البشريين.

3. Galactica

تم تصميم Galactica لتخزين المعلومات العلمية والجمع بينها واستنتاجها، بما في ذلك المعلومات المتعلقة بالرعاية الصحية، يمكن لـ Galactica استرجاع المعلومات العلمية من مصادر مختلفة، وتحليلها، وتلخيصها بلغة سهلة الفهم، حيث أظهر Galactica نتائج مذهلة في مهام متنوعة متعلقة بالرعاية الصحية، على وجه التحديد، حقق درجة 77.6٪ في مهمة PubMedQA [41]، وعليه يمكن أن يكون Galactica أداة قوية للباحثين والأطباء للعثور على المعلومات العلمية ذات الصلة وتحليلها.

4. Med-PaLM

يعتمد Med-PaLM على نموذج PaLM مع ضبط موجه لتحسين أدائه في مهام الرعاية الصحية، حيث حقق Med-PaLM توافقًا عالٍ مع الأطباء عند تقييم الإجابات على الأسئلة الطبية الموجودة في مجموعات البيانات في مجموعات بيانات HealthSearchQA و Live QA و Medication، و حقق كل من النموذج والأطباء نتائج بنسبة 92.6٪ و 92.9٪ على التوالي، وهذا يعني أن نموذج Med-PaLM يتيح إمكانية دمج نماذج اللغة الضخمة مع خبرة الأطباء لتحسين دقة التشخيص والعلاج.

5. Med-PaLM 2

هو إصدار محدث من نماذج LLM للرعاية الصحية، وهو مبني على نموذج MedPaLM من Google، ومن المثير للاهتمام أن هذا النموذج يمثل استثناءً نادرًا حيث يتفوق نموذج LLM "الأصغر" على نموذج LLM "الأكبر"، حقق Med-PaLM 2 ما يصل إلى 86.5٪ على مجموعة بيانات USMLE، مقارنة بـ 67.2٪ من نموذج MedPaLM، ويعود السبب أن Med-PaLM 2 يولد مسارات استدلال متعددة ويقوم بتكييفها لتحسين الإجابة النهائية.

1.4.4- أهمية تصميم مجموعة البيانات DataSet

تلعب مجموعات البيانات دورًا حيويًا في تحسين نماذج الذكاء الاصطناعي في الرعاية الصحية حيث إن تصميم مجموعات بيانات عالية الجودة يعد عنصرًا أساسيًا لتحقيق أداء متفوق للنماذج اللغوية الكبيرة، كما تتطلب المهام الصحية تعقيدًا وتنوعًا في البيانات، مما يفرض الحاجة إلى بيانات دقيقة وشاملة تغطي مجموعة واسعة من الحالات الطبية والمعلومات العلمية.

تتضمن عملية إعداد مجموعات البيانات ذات الجودة العالية جمع وتحليل بيانات طبية دقيقة ومتنوعة لضمان تغطية جميع الجوانب الممكنة في الرعاية الصحية، وتشمل هذه البيانات ملاحظات سريرية، نتائج فحوصات طبية، سجلات صحية إلكترونية، وأبحاث علمية، ويعد ضمان تنوع ودقة هذه البيانات أساسيًا لتدريب نماذج قادرة على التعامل مع السيناريوهات المعقدة والمتنوعة في الرعاية الصحية، علاوة على ذلك، تتطلب البيانات عالية الجودة معالجة وتنقيحًا دقيقين للتأكد من خلوها من الأخطاء والتناقضات، كما يجب أن تكون البيانات متنوعة بما يكفي لتمثيل جميع الفئات السكانية والحالات الطبية المختلفة، وهذه العملية تساعد في تحسين قدرة النماذج على التفاعل مع المعرفة العلمية المكثفة وتحقيق نتائج واعدة في المهام العلمية المتخصصة.

1.4.5- التشابهات والاختلافات بين النماذج السابقة والنموذج الذي نطوره

التشابهات

- استخدام نماذج اللغة الضخمة: كما هو الحال في الدراسات السابقة، يستخدم مشروعنا نماذج اللغة الضخمة لتحليل النصوص الطبية وتقديم استشارات طبية.
- تحليل النصوص الطبية: يركز مشروعنا، مثل الدراسات المذكورة، على تحليل النصوص الطبية، بما في ذلك السجلات الطبية الإلكترونية والملاحظات السريرية.

الاختلافات

- التركيز على مرض السُكري: بينما تتناول الدراسات السابقة استخدام نماذج اللغة الضخمة في مجموعة متنوعة من التطبيقات الطبية، يركز مشروعنا بشكل خاص على تقديم استشارات طبية وإدارة حالة مرضى السُكري.
- النماذج المقترحة الخاصة: يقدم مشروعنا نماذج متخصصة تعتمد على تقنية استرجاع-التوليد (RAG) لتقديم استشارات دقيقة بناءً على بيانات المرضى، يتمثل النموذجان المقترحان في PDF-based RAG و WEB-based RAG ، وهو ما يختلف عن تطبيقات النماذج العامة في الدراسات السابقة.
- تطبيقات التلقين في الرعاية الصحية: يتناول مشروعنا بعمق هندسة التلقين (Prompt Engineering) لتخصيص الاستجابات الطبية وتكييفها بشكل يناسب احتياجات مرضى السُكري، وهو جانب لم يُدرس بشكل مكثف في الأبحاث السابقة.

أثبتت نماذج اللغة الضخمة فعالية كبيرة في تحسين الرعاية الصحية من خلال تحليل النصوص الطبية وتوليد التقارير وتقديم الاستشارات الطبية، بينما تقدم الدراسات السابقة أمثلة ناجحة لتطبيقات هذه النماذج في مختلف المجالات الطبية، يهدف مشروعنا إلى تقديم نموذج متخصص لمرضى السُكري، مع التركيز على تحسين إدارة المرض وتقديم استشارات مخصصة، كما تبرز التحديات المتعلقة بالتكلفة، التحيز، والامان، ولكن مع التطورات المستمرة في هذا المجال، من المتوقع أن تساهم هذه النماذج بشكل متزايد في تقديم رعاية صحية أفضل وأكثر شمولاً.

2. الفصل الثاني: دورة حياة نموذج اللغة الضخم

سوف نتعرف في هذا الفصل على دورة حياة والمراحل العامة للنماذج اللغوية الضخمة، ثم سوف نستعرض النماذج المُقترحة لتلبية مُتلطبات المشروع، كما سوف نتعرف على التقنيات المُستخدمة في تحسين ورفع كفاءة النماذج اللغوية، مثل، التكميم وهندسة التلقينات، ثم في النهاية سوف نتحدث عن المعايير المُختلفة لتقييم نماذج اللغة الضخمة، وتقنية RAG.

2.1- دورة حياة النماذج اللغوية الضخمة

الذكاء الاصطناعي التوليدي هو فرع من فروع الذكاء الاصطناعي الذي يركز على تطوير نماذج يمكنها إنشاء محتوى جديد، مثل النصوص والصور والتعليمات البرمجية والموسيقى، تُستخدم هذه النماذج في مجموعة متنوعة من التطبيقات، بما في ذلك إنشاء المحتوى التسويقي وكتابة النصوص الإبداعية وتطوير المنتجات الجديدة.

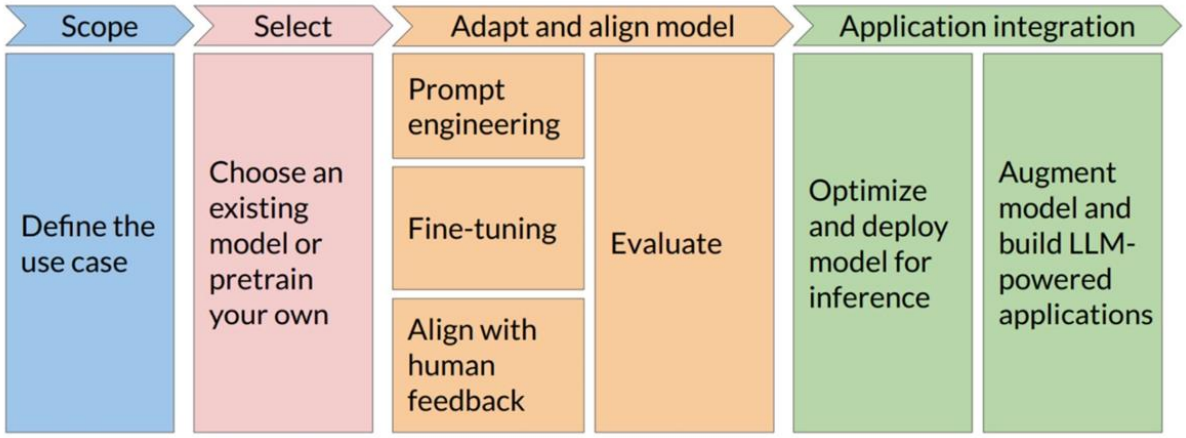

الشكل (9) دورة حياة مشروع الذكاء الاصطناعي التوليدي

تُقسم دورة حياة مشروع الذكاء الاصطناعي التوليدي إلى أربع مراحل[42] رئيسية:

المرحلة الأولى: تحديد حالة الاستخدام

تتمثل الخطوة الأولى في أي مشروع الذكاء الاصطناعي التوليدي في تحديد حالة الاستخدام، وهذا يعني تحديد المشكلة التي يحاول المشروع حلها أو الحاجة التي يحاول تلبيتها، على سبيل المثال قد يكون مشروع الذكاء الاصطناعي التوليدي يهدف إلى إنشاء صور واقعية للمنتجات لاستخدامها في الكتالوجات عبر الإنترنت، أو إنشاء نصوص إبداعية لحملات إعلانية، أو كتابة مقالات إخبارية.

المرحلة الثانية: اختيار نموذج موجود أو تدريب نموذجك الخاص

بمجرد تحديد حالة الاستخدام، تحتاج إلى اختيار نموذج الذكاء الاصطناعي التوليدي المناسب، حيث أن هناك العديد من نماذج الذكاء الاصطناعي التوليدي المتاحة، كل منها له نقاط قوته وضعفه الخاصة، إذا لم تتمكن من العثور على نموذج يلبي احتياجاتك، فيمكنك تدريب نموذجك الخاص.

المرحلة الثالثة: التكيّف والمحاذاة Adapt & Align

هو نهج جديد لتدريب النماذج التوليدية، يهدف إلى التغلب على مشكلة النسيان التدريجي، حيث تفقد النماذج المدربة على كميات كبيرة من البيانات أداءها عند التعرض لمجموعات بيانات جديدة ذات توزيعات مختلفة.

يُمكن تَكييف النموذج بعدة طرق وهي:

1- هندسة التلقيّن (Prompt Engineering): وتشمل إنشاء مطالبات محددة وواضحة توجه النموذج نحو المحتوى المطلوب، واستخدام تقنيات مثل التعلم المتعدد المهام والتعلم المعزز لتحسين هندسة المطالبات.

2- ضبط دقيق (Fine-tuning): تقوم هذه الطريقة على إعادة تدريب النموذج على مجموعات بيانات جديدة مع الحفاظ على المعرفة المكتسبة من البيانات السابقة، للقيام بذلك يتم استخدام تقنيات مثل التعلم التدريجي والتعلم المتعدد لتحسين عملية الضبط الدقيق.

3- المحاذاة مع التغذية الراجعة البشرية(Align with human feedback) : تعتمد هذ الطريقة على دمج التغذية الراجعة البشرية في عملية التدريب لتحسين جودة النتائج، واستخدام تقنيات مثل التعلم النشط والتعلم المعزز لجمع التغذية الراجعة البشرية بشكل فعال.

بعد اجراء علمية التكييف والمحاذاة يجب القيام بعملية التقييم، وغالباً ما يجري تكرار عمليتي التكييف ثم التقييم لحد الوصول الى الأداء المطلوب.

التقييم(Evaluate)

يضم التقييم كل مما يلي:

- قياس أداء النموذج على مجموعة متنوعة من المهام والمقاييس.
- تحليل تأثير تقنيات Adapt & Align على أداء النموذج.
- تحديد نقاط القوة والضعف في النموذج وتحديد مجالات التحسين.

سوف نشرح وبشكل مفصل في قسم منفصل عملية التقييم (أنواعها، طرقها).

المرحلة الرابعة: دمج تطبيقات الذكاء الاصطناعي التوليدي: من النموذج إلى التطبيق

دمج تطبيقات الذكاء الاصطناعي التوليدي هو عملية ربط نموذج الذكاء الاصطناعي التوليدي بنظام أو تطبيق موجود بحيث يمكن استخدامه لتوليد محتوى أو تنفيذ مهام معينة، وينقسم دمج تطبيقات الذكاء الاصطناعي التوليدي إلى مرحلتين رئيسيتين:

القسم الأول: تحسين النموذج ونشره للاستنتاج

يحوي هذا القسم خطوتين، هما:

الخطوة الأولى: تحسين النموذج(Optimize the model)

ويتضمن ذلك تقليل الزمن المطلوب لتوليد النصوص على خرج النموذج (الوقت الذي يستغرقه لإنشاء المحتوى) دون التأثير على جودة النتائج، تقليل موارد الحوسبة المطلوبة لتشغيل النموذج، مما يجعله أكثر قابلية للتطبيق في البيئات ذات الموارد المحدودة، ويتضمن التأكد من استقرار النموذج بحيث ينتج باستمرار نتائج عالية الجودة.

الخطوة الثانية: نشر النموذج لتوليد النصوص(Deploy the model for inference)

ويتضمن ذلك اختيار بيئة مناسبة لنشر النموذج، مثل السحابة الحاسوبية أو الجهاز المحلي، ومن ثم تطوير واجهة برمجة تطبيقات (API) تتيح للتطبيقات الأخرى الوصول إلى النموذج واستخدامه، ثم مراقبة أداء النموذج بعد النشر واكتشاف أي مشاكل أو تحسينات محتملة.

القسم الثاني: توسيع النموذج وبناء تطبيقات مدعومة بنماذج اللغة الضخمة(LLM)

يضم هذا القسم ما يلي:

1- توسيع النموذج(Augment the model) ، ودمج قدرات نماذج اللغة الضخمة (LLMs) مع تقنية RAG، على سبيل المثال، يمكن استخدام نموذج LLM لتحسين فهم النموذج للمطالبات النصية أو تحسين جودة المحتوى الذي ينشئه.

2- بناء تطبيقات مدعومة بنماذج اللغة الضخمة(Build LLM-powered applications)

تطوير تطبيقات جديدة تستفيد من قدرات كل من الذكاء الاصطناعي التوليدي ونماذج اللغة الضخمة.

2.2- تحديد حالة الاستخدام واختيار النماذج اللغوية المناسبة

بعد أن تعرفنا في القسم السابق على كم جيد من النماذج اللغوية الفعالة في المجال الصحي، وتعرفنا دورة حياة النماذج اللغوية، سوف نقترح عدة نماذج لغوية متخصصة للقيام بهمة المُساعد الذكي المُختص بمرض السُكري، وهي:

1. نموذج Mistral
2. نموذج BioMistral
3. نموذج Llama3
4. نموذج Aya

2.2.1- النموذج الأول Mistral LLM

نموذج Mistral LLM [43]، وهو نموذج لغة ضخم(LLM) تم تطويره بواسطة شركة Mistral AI الفرنسية، وهي الشركة التي أنشأت نموذج Mistral LLM، وهي توفر إصدارات مختلفة من النموذج، بما في ذلك خيارات مفتوحة المصدر ونماذج مرخصة تجاريًا ذات إمكانيات مختلفة.

الميزات الرئيسية لنموذج Mistral

- الكفاءة: بالمقارنة مع النماذج الأخرى ذات الأداء المماثل، فإنه معروف بكونه فعالاً، ويتطلب قوة حسابية أقل لتشغيله.
- قدرات متعددة اللغات: تم تصميم بعض إصدارات نموذج Mistral لفهم وإنشاء النص بلغات متعددة.

يمكن استخدام برنامج Mistral LLM في العديد من المهام، بما في ذلك:

- إنشاء التعليمات البرمجية: المساعدة في مهام مثل إكمال التعليمات البرمجية أو ملء الأجزاء المفقودة من التعليمات البرمجية.
- في حين أنه لا يزال قيد التطوير، إلا أنه لديه القدرة على أن يكون أداة قوية لمختلف التطبيقات.
- إنشاء النص: إنشاء تنسيقات نصية إبداعية مختلفة مثل القصائد أو النصوص أو القصص.
- الإجابة على الأسئلة بطريقة شاملة.
- تلخيص أجزاء طويلة من النص.

2.2.2- النموذج الثاني BioMistral

BioMistral [44] يشير هذا الى مجموعة من نماذج اللغة الضخمة (LLMs) المصممة خصيصًا للمجال الطبي، والمبنية على نموذج مؤسسة Mistral.

المجال الطبي: تم تدريب هذه النماذج مسبقًا على كمية هائلة من البيانات النصية الطبية الحيوية، وتحديدًا من PubMed Central، وهو مورد لمنشورات الأبحاث الطبية، كما يتيح هذا التدريب لشركة BioMistral فهم وإنشاء النصوص المتعلقة بالطب والرعاية الصحية.

ميزات نموذج BioMistral التي تجعله فريدًا من نوعه

- التركيز على الطب: يتم تدريب BioMistral بشكل خاص على النصوص الطبية، مما يجعله على معرفة بالمصطلحات والمفاهيم والعلاقات الطبية.
- مفتوح المصدر : بعض إصدارات BioMistral متاحة للعامة، مما يسمح للباحثين والمطورين باستكشاف قدراته في التطبيقات الطبية.

- مساعدة المهنيين الطبيين: يمكن أن يساعد BioMistral الأطباء والباحثين من خلال تلخيص الأدبيات الطبية، أو إنشاء التقارير، أو الإجابة على الأسئلة الطبية بطريقة شاملة (إخلاء مسؤولية مهم: لا ينبغي استخدام BioMistral للتشخيص أو العلاج الطبي).
- تطوير الأدوات التعليمية: يمكن استخدام BioMistral لإنشاء مواد تعليمية لطلاب الطب أو المرضى.
- تسهيل التواصل: يمكن أن يساعد BioMistral في سد فجوات التواصل بين الأطباء والمرضى من خلال ترجمة المصطلحات الطبية إلى لغة أبسط.

بفضل ميزاته الفريدة، يُقدم نموذج "BioMistral" العديد من الاستخدامات المُفيدة في مجال الطب، ونذكر منها:

1 .مساعدة المهنيين الطبيين:

تلخيص الأدبيات الطبية: يمكن لـ "BioMistral" تحليل كميات كبيرة من المعلومات الطبية، مثل المقالات العلمية والدراسات السريرية، وتلخيصها بطريقة مُفصّلة وواضحة، مما يُساعد الأطباء والباحثين على توفير الوقت والجهد في البحث عن المعلومات.

إنشاء التقارير الطبية: يمكن لـ "BioMistral" تحليل البيانات الطبية للمرضى، مثل نتائج الاختبارات والتشخيصات، وإنشاء تقارير طبية شاملة ومُنظمة، مما يُسهّل على الأطباء متابعة حالة المرضى والتواصل معها.

الإجابة على الأسئلة الطبية: يمكن لـ "BioMistral" الإجابة على أسئلة المرضى حول حالتهم الصحية بطريقة شاملة وغنية بالمعلومات، مما يُساعدهم على فهم حالتهم بشكل أفضل واتخاذ قرارات مستنيرة بشأن رعاية صحتهم.

2 .تطوير الأدوات التعليمية:

إنشاء مواد تعليمية لطلاب الطب: يمكن استخدام "BioMistral" لإنشاء مواد تعليمية تفاعلية وجذابة لطلاب الطب، مثل المحاضرات والعروض التقديمية والاختبارات.

توفير معلومات صحية للمرضى: يمكن استخدام "BioMistral" لإنشاء كتيبات أو مقاطع فيديو توضيحية تُقدم معلومات صحية مُبسطة للمرضى، مما يُساعدهم على فهم حالتهم الصحية بشكل أفضل واتباع تعليمات الطبيب.

3 .تسهيل التواصل بين الأطباء والمرضى:

ويتم ذلك من خلال ترجمة المصطلحات الطبية، حيث يمكن لـ "BioMistral" ترجمة المصطلحات الطبية المعقدة إلى لغة أبسط، مما يُساعد المرضى على فهم المعلومات الطبية التي يُقدمها الأطباء.

وايضاً يمكن تحسين التواصل بين الأطباء من مختلف التخصصات: يمكن لـ "BioMistral" تحليل النصوص الطبية المكتوبة بلغات مختلفة وترجمتها، مما يُسهّل التواصل بين الأطباء من مختلف التخصصات حول حالات المرضى.

2.2.3- النموذج الثالث Llama3

Llama3 [45] هو نموذج لغة ضخممتطور (LLM) تم تطويره بواسطة Meta AI.

Meta AI: هذا هو قسم الأبحاث في Meta (فيسبوك سابقًا) الذي أنشأ Llama3، ولقد أطلقوا Llama3 كنموذج مفتوح المصدر، مما جعله في متناول المطورين والباحثين.

ميزات Llama3

- أداء متطور: يتميز Llama3 بقدرات رائعة في العديد من مهام LLM مثل إنشاء النص والترجمة والإجابة على الأسئلة وإكمال التعليمات البرمجية، و تعتبر واحدة من أقوى برامج LLM المتاحة بشكل مفتوح حاليًا.
- أحجام متعددة: تقدم Meta Llama3 بأحجام مختلفة، مع عدد متغير من المعلمات (8 مليار و70 مليار)، ويتيح ذلك للمستخدمين اختيار نموذج يناسب مواردهم الحسابية واحتياجاتهم المحددة.

- ضبط التعليمات: بعض إصدارات Llama3 "مضبوطة حسب التعليمات"، مما يعني أنها تم تدريبها بشكل أكبر على مهام أو مجموعات بيانات محددة، مما قد يؤدي إلى تحسين أدائها في تلك المجالات.
- المصدر المفتوح: إحدى نقاط القوة الرئيسية في Llama3 هو أنه مفتوح المصدر، يتيح ذلك للباحثين والمطورين الوصول بحرية إلى النموذج وتجربته وحتى المساهمة في تطويره.
- الشفافية: يتيح الكود مفتوح المصدر للباحثين فهم كيفية عمل النموذج وتحديد التحيزات المحتملة.
- إمكانية الوصول: يمكن للمطورين والباحثين الاستفادة من Llama3 في العديد من التطبيقات دون عوائق مالية كبيرة.

التطبيقات المحتملة لنوذج Llama3

مهام معالجة اللغة الطبيعية (NLP): الترجمة الآلية، تلخيص النص، الإجابة على الأسئلة، تطوير روبوت الدردشة.

إنشاء المحتوى: إنشاء تنسيقات نصية إبداعية مختلفة مثل القصائد أو النصوص أو المقطوعات الموسيقية.

إنشاء التعليمات البرمجية: مساعدة المبرمجين في مهام مثل إكمال التعليمات البرمجية أو اقتراح تحسينات التعليمات البرمجية.

الأدوات التعليمية: إنشاء مواد تعليمية مخصصة أو تسهيل تجارب التعلم التفاعلية.

2.2.4- النموذج الرابع Aya

هو نموذج لغة ضخممثير للإعجاب، وهو معروف بقدراته المتعددة ودعمه لعدة للغات [46].

تم تطوير Aya بواسطة Cohere For AI، وتتميز بقدرتها على فهم التعليمات والاستجابة لها بأكثر من 101 لغة (منها اللغة العربية) وهذا يجعلها أداة قيمة للتواصل والوصول إلى المعلومات عبر الحواجز اللغوية.

ميزات نموذج Aya

أداء متطور: على الرغم من التعامل مع عدد كبير من اللغات، تقدم Aya أداءً عالي الجودة في مهام LLM المختلفة، فهو يتفوق في مجالات مثل إنشاء النصوص والترجمة والإجابة على الأسئلة، حتى عند التعامل مع محتوى متعدد اللغات.

مفتوح المصدر: من المزايا المهمة لـ Aya هو كونه مفتوح المصدر، و يتيح ذلك للباحثين والمطورين استكشاف قدراته بحرية، والمساهمة في تطويره، وربما إنشاء إصدارات مخصصة للغات أو تطبيقات محددة.

التركيز على اللغات: من خلال تضمين أكثر من 100 لغة، تتجاوز Aya التركيز المعتاد على اللغات الرئيسية في تطوير LLM، وهذا يعزز الشمولية ويسهل الوصول إلى تكنولوجيا الذكاء الاصطناعي المتقدمة للمجتمعات اللغوية الممثلة تمثيلا ناقصا.

التطبيقات المُحتملة لنموذج Aya

- الترجمة الآلية: كسر الحواجز اللغوية للتواصل في الوقت الحقيقي، وترجمة المستندات، والوصول إلى المعلومات.
- إنشاء محتوى متعدد اللغات: إنشاء محتوى مثل المقالات أو منشورات وسائل التواصل الاجتماعي أو المواد التسويقية بلغات مختلفة، مصممة خصيصًا لجماهير محددة.
- التعليم متعدد اللغات: إنشاء مواد تعليمية مخصصة، أو ترجمة المحتوى التعليمي، أو تسهيل تجارب تعلم اللغة.
- خدمة عملاء متعددة اللغات: تقديم الدعم والإجابة على أسئلة العملاء بلغتهم المفضلة.
- بشكل عام، يعد Aya LLM إنجازًا رائعًا في مجال الذكاء الاصطناعي متعدد اللغات، كما إن قدرتها على التعامل مع عدد كبير من اللغات تفتح الأبواب بشكل فعال للتواصل والوصول إلى المعلومات والابتكار في جميع أنحاء العالم.

2.2.5- جدول مقارنة بين النماذج المُقترحة

نوضح تالياً أهم الفوارق بين النماذج الأربعة المُقترحة، وهي مبينة في الجدول التالي:

	Mistral	BioMistral	Llama3	Aya
حجم النموذج	7b	7b	20b	7b
مجموعة بيانات التدريب	مجموعة بيانات ضخمة من النصوص والشفرات	مجموعة بيانات ضخمة من النصوص والشفرات، مع التركيز على المحتوى العلمي والطبي	مجموعة بيانات ضخمة من النصوص والشفرات	مجموعة بيانات ضخمة من النصوص والشفرات
المميزات	مناسب للمهام العامة	متخصص في فهم اللغة العلمية والطبية	مناسب للترجمة	مناسب للمهام العامة
العيوب	يكون متحيزًا في بعض الأحيان، اعتمادًا على بيانات التدريب.	قد لا يكون فعالًا في المهام غير العلمية.	لا يكون فعالًا في المهام غير المتعلقة بالترجمة.	يكون متحيزًا في بعض الأحيان، اعتمادًا على بيانات التدريب.

جدول (2) مقارنة بين النماذج المُقترحة

2.3-تكميم النماذج اللغوية الضخمة

تكميم النماذج اللغوية الضخمة هو تقنية تُستخدم لتقليل حجم هذه النماذج دون التأثير بشكل كبير على دقتها [47]، تُعدّ النماذج اللغوية الضخمة أدوات قوية لمعالجة اللغة الطبيعية، لكن حجمها الهائل يُشكل تحدياً من ناحية الحساب والتخزين.

آلية عمل التكميم

في النماذج اللغوية غير المُكمّمة، تُخزّن الأوزان والمعلمات بأعداد عشرية عالية الدقة،يُمكن أن تُؤدي هذه الأرقام إلى نماذج ضخمة الحجم تتطلب موارد حوسبية هائلة للتشغيل، في المقابل، يُستخدم في التكميم تمثيل رقمي ذو دقة أقل، مثل الأعداد الصحيحة الثنائية 8 بت أو 16 بت، لتمثيل الأوزان والمعلمات، يُؤدي ذلك إلى تقليل حجم النموذج بشكل كبير دون التأثير بشكل كبير على دقتها.

2.3.1- فوائد تكميم النماذج اللغوية الضخمة

1. **تقليل حجم النموذج:**

يُعدّ هذا هو الفائدة الأساسية للتكميم، حيث يُمكن تقليل حجم النموذج بشكل كبير، مما يسهل تخزينه ونشره واستخدامه على الأجهزة ذات الإمكانيات المحدودة.

2. **تحسين سرعة التشغيل:**

يُمكن أن يُؤدي تقليل دقة تمثيل الأرقام إلى تحسين سرعة تشغيل النموذج، خاصة على الأجهزة المخصصة لمعالجة تعلم الآلة.

3. **تقليل استهلاك الطاقة:**

تتطلب النماذج غير المُكمّمة المزيد من الطاقة للتشغيل بسبب الحسابات العشرية المعقدة.

يُساعد التكميم في تقليل استهلاك الطاقة من خلال استخدام عمليات حسابية ثنائية أبسط.

2.3.2- التحديات المُرتبطة بتكميم النماذج اللغوية الضخمة

1. **فقدان الدقة:**

يُمكن أن يُؤدي تقليل دقة تمثيل الأرقام إلى فقدان بعض الدقة في النموذج.

يجب اختيار مستوى التكميم بعناية لضمان تحقيق توازن بين حجم النموذج ودقته.

2. **صعوبة الاختيار الأمثل:**

لا توجد طريقة واحدة مثالية لتكميم النماذج اللغوية الضخمة.

يعتمد أفضل نهج على نوع النموذج ومجموعة البيانات ومهمة المعالجة.

3. **الحاجة إلى تعديلات إضافية:**

قد تتطلب بعض النماذج تعديلات إضافية لضمان عملها بشكل سليم بعد التكميم.

2.4- هندسة التلقين في مجال الرعاية الصحية

النماذج اللغوية الكبيرة (LLMs) هي أنظمة ذكاء اصطناعي يتم تدريبها على كميات ضخمة من النصوص لتعلم أنماط اللغة والعلاقات النحوية، مما يمكنها من تفسير النصوص وإنتاج نصوص جديدة، ولقد لاقت هذه النماذج اهتماما كبيرًا نظرًا لأدائها الذي يشبه أداء البشر في العديد من المهام المتعلقة بتوليد النصوص، وفي المجال الطبي أثبتت الجهود الأولية أن هذه النماذج يمكنها كتابة الملاحظات السريرية، واجتياز الامتحانات الطبية الموحدة، وصياغة ردود على استفسارات المرضى، ولكي ندمج هذه النماذج بشكل فعال في الرعاية الطبيّة، يجب أن نفهم طريقة صياغة الأسئلة وهنا تأتي هندسة التلقينات لتساعدنا في ذلك[48].

التحليل السريري (Clinical reasoning) هو مجموعة من عمليات حل المشكلات التي تُستخدم خصيصًا لتشخيص وإدارة الحالات الطبية للمرضى.

هندسة التلقينات (Prompt engineering) هي مجال ناشئ يستفيد من قدرات منصات الذكاء الاصطناعي الحوارية مثل ChatGPT في تطبيقات متنوعة في الرعاية الصحية. توفر هندسة التلقينات

العديد من الإمكانيات، بدءًا من تسهيل اتخاذ القرارات السريرية وصولاً إلى تعزيز تثقيف المرضى. ومع ذلك، من الضروري التعامل مع هذه الأداة بفهم شامل لحدودها، خاصة فيما يتعلق بسرية معلومات المرضى.

برزت هندسة التلقيّن كاختصاص نتيجة للظاهرة التي تجعل أداء النماذج اللغوية الكبيرة يتفاوت بشكل كبير بناءً على كيفية صياغة الأسئلة، أثبتت تقنية التلقينات المتقدمة أنها تحسن الأداء في مجموعة متنوعة من المهام، كما توفر فهمًا أفضل لكيفية توصل النماذج إلى استنتاجاتها.

التطبيقات الرئيسية لهندسة التلقيّن

- دعم القرار السريري

يمكن تصميم التلقينات لتقديم اقتراحات قائمة على الأدلة للتشخيص وخيارات العلاج.

على سبيل المثال: "لخص أحدث الإرشادات لإدارة مرض السُكري من النوع 2".

- البحث الطبي

يمكن للباحثين استخدام التلقينات للمساعدة في تحليل البيانات، ومراجعة الأدبيات، أو حتى توليد الفرضيات.

مثال: "حلل اتجاهات استخدام المواد الأفيونية في العقد الماضي".

- تثقيف المرضى

يمكن لمقدمي الرعاية الصحية إنشاء تلقيّنات لإنتاج أسئلة شائعة (FAQs) سهلة الفهم للمرضى.

مثال: "اشرح الآثار الجانبية للعلاج الكيميائي بلغة بسيطة".

- التطوير المهني

يمكن للعاملين في المجال الطبي استخدام التلقينات لتطوير مواد تعليمية أو أسئلة تقييم.

مثال: "أنشئ قائمة بأسئلة تعتمد على الحالات لامتحانات الإقامة في أمراض القلب".

يجب اتباع بعض التعليمات عند انشاء التلقينات وهي:

- الوضوح: تأكد من أن تكون الأسئلة واضحة ومحددة ومركزة للحصول على أكثر الإجابات دقة وقيمة.
- السياق: قدم سياقًا كافيًا داخل السؤال حتى يتمكن الذكاء الاصطناعي من إنشاء استجابة ذات مغزى ومرتبطة.
- التحقق من صحة البيانات: قم دائمًا بالتحقق من صحة المحتوى الذي ينشئه الذكاء الاصطناعي برأي الخبراء قبل التطبيق السريري.
- التحديثات: حافظ على تحديث الأسئلة بناءً على آخر الأدلة والإرشادات للحفاظ على الموثوقية.

يقدم لنا الجدول التالي أمثلة عن تلقينات جيدة وأخرى سيئة، هذه التلقينات خاصة بتطبيقات الرعاية الصحية.

Bad Prompts	Comments	Bad Prompts	Comments
Tell me about heart problems	إنه غامض للغاية ويفتقر إلى التركيز والسياق	Summaries the diagnostic criteria for Congestive Heart Failure according to the latest ACC/AHA guidelines	محدد ومركز ويشير إلى مصدر موثوق
What drugs are good for high BP, diabetes, and heart issues	معقد بشكل مفرط، مما يخاطر بالتبسيط الخطير	List the first-line antihypertensive medications according to the latest guidelines	يركز على حالة واحدة ويطلب العلاج المبني على الأدلة
What's the best treatment for a 45-year-old male named John Smith with these symptoms	يحتوي على معلومات قد تكون قابلة للتعرف عليها، مما يعرض سرية المريض للخطر	What are the treatment options for a 45-year-old male presenting with these generic symptoms	معمم ومجهول، مما يحافظ على سرية المريض.

جدول (3) أمثلة على تلقينات جيدة وتلقينات سيئة

توجد طرق أكثر تعقيداً ومنها التلقين باستخدام سلسة الأفكار (Chain-Of-Thought Prompting) والمعروف اختصاراً (CoT)، وهي أسلوب جديد لتوجيه نماذج اللغة الضخمة (LLMs) لإنتاج مخرجات أكثر دقة وشفافية، وتُستخدم هذه التقنية من خلال تزويد النموذج بسلسلة من المطالبات التي تشرح خطوات التفكير اللازمة لإكمال مهمة معينة، فعلى سبيل المثال يمكن استخدام سلسلة الأفكار لطلب من LLM كتابة ملخص لموضوع ما من خلال تقسيم المهمة إلى خطوات أصغر.

مثل تحديد الأفكار الرئيسية في النص، وتنظيم هذه الأفكار في تسلسل منطقي، وكتابة جمل موجزة توضح كل فكرة رئيسية، وكمثال أخر نرفق الصورة التالية والتي تقدم مثالًا على كيفية استخدام الأعراض والعلامات والفحوصات المخبرية لتشخيص الحالة الصحية للمريض خطوة بخطوة، حيث أن النص يتضمن مُطالبة مع أمثلة توضيحية لكيفية الاستدلال على التشخيص الصحيح.

Prompt:
Use symptom, signs, and laboratory disease associations to step by step deduce the correct response.
{Example Question 1}
Example Rationale 1:
This patient has findings of petechiae, altered mental status, shortness of breath, and recent surgery suggesting a diagnosis of fat emboli. The patient most likely has a fat embolism.
{Example Question 2} Example Rationale 2:
This patient had a recent myocardial infarction with new development of diffuse ST elevations, chest pain, and a high pitched scratching murmur which are found in Dressler's syndrome. This patient likely has Dressler's Syndrome.

الشكل (10) مثال على التلقين باستخدام سلسلة الأفكار

2.5- تقييم النماذج

يشير تقييم نماذج اللغة الضخمة (LLMs) إلى قياس وتقييم أداء وفعالية النموذج في مهام أساسية مختلفة، ويتضمن ذلك تطبيق مجموعة من المقاييس التي تقيس مدى دقة قدرة النموذج على التنبؤ أو إنشاء الكلمة التالية في الجملة، وفهم السياق، وتلخيص البيانات، والرد على الاستفسارات، ويعتبر التقييم أمراً بالغ الأهمية لأنه يساعد على تحديد نقاط القوة والضعف في النموذج، ويوفر رؤى حول مجالات التحسين، ويرشد في النهاية عملية الضبط الدقيق، فمن الضروري التأكد من أن نماذج اللغة الضخمة تقدم مخرجات عالية الجودة وموثوقة ودقيقة في سياقها.

2.5.1- معايير التقييم الرئيسية

هناك العديد من المقاييس المستخدمة لتقييم أداء نماذج اللغة الضخمة في هذا القسم، سوف نستكشف تالياً بعض المقاييس البارزة وخصائصها.

1. تقييم ثنائي اللغة التجريبي BLEU

هو أحد المقاييس الشائعة ويُستخدم بشكل أساسي في الترجمة الآلية [49]، ويقوم هذا المعيار بحساب تداخل n-gram (وهي تسلسل متصل من n كلمة أو رمز من عينة نص معطاة) بين مخرجات النموذج والنصوص المرجعية المكتوبة بخط اليد، وتعني درجة BLEU الأعلى أن النص الذي أنشأه النموذج يشبه النص المرجعي بدرجة أكبر، مما يشير إلى جودة الترجمة، ولكن يجدر بالذكر أن BLEU له قيود، مثل عدم قدرته على تقييم المعنى الدلالي أو مدى صلة النص المُنشأ بالموضوع الأصلي.

لكن يجدر بالذكر أن BLEU له قيود، مثل عدم قدرته على تقييم المعنى الدلالي أو مدى صلة النص المُنشأ بالموضوع الأصلي.

2. تقييم موجه نحو الاسترجاع لتقييم التلخيص ROUGE

وهو مقياس آخر مهم ويستخدم بشكل واسع في مهام تلخيص النصوص [50]. يتضمن هذا المقياس عدة أنواع مثل ROUGE-N و ROUGE-L و ROUGE-S.

يقيس ROUGE-N تداخل n-gram بين النص المُنشأ والنص المرجعي، كما هو موضح في الشكل التالي:

$$\text{ROUGE-N} = \frac{\sum_{S \in \text{Reference Summaries}} \sum_{\text{n-gram} \in S} \text{Match(n-gram)}}{\sum_{S \in \text{Reference Summaries}} \sum_{\text{n-gram} \in S} \text{Count(n-gram)}}$$

Here's what each term represents:

- **Match(n-gram)**: The maximum number of N-grams co-occurring in a candidate text and a set of reference texts.
- **Count(n-gram)**: The total count of N-grams in the reference summaries.

الشكل (11) معيار التقييم ROUGE-N

بينما يقيس ROUGE–L أطول تسلسل فرعي مشترك (LCS) بين النص المُنشأ والنص المرجعي، وهو موضح في المثال التالي:

The ROUGE-L metric in LLM evaluation is based on the length of the Longest Common Subsequence (LCS) between a candidate summary and a reference summary. The formula for calculating the ROUGE-L score is:

$$\text{ROUGE-L} = \frac{\text{Length of LCS}}{\text{Total number of words in the reference summary}}$$

For example, if the LCS between the candidate and reference summary is 4 words, and the total number of words in the reference summary is 9 words, then the ROUGE-L score would be calculated as:

$$\text{ROUGE-L} = \frac{4}{9} \approx 0.44$$

الشكل (12) معيار التقييم ROUGE–L

أما ROUGE–S، فيقيس تداخل "ثنائي الكلمات المتخطي" (وهي كلمتين تظهران بالترتيب بغض النظر عن عدد الكلمات الفاصلة بينهما) بين النصين، نستنتج مما سبق أن كل نسخة من ROUGE توفر رؤى مختلفة، ولكنها أيضًا تحمل قيودًا ويجب استخدامها بجانب طرق تقييم أخرى لإجراء تقييم شامل.

3. MoverScore

هو معيار تقييم أحدث، يقيس التشابه الدلالي بين قطعتين نصيتين باستخدام مسافة Word Mover's، وهي طريقة تحسب المسافة الدنيا التي تحتاج الكلمات في نص واحد إلى "قطعها" للوصول إلى التوزيع الدقيق للكلمات في نص آخر، يوفر MoverScore تقييمًا أكثر دقة للتشابه الدلالي مقارنة ببعض المقاييس القديمة، ولكنه يتطلب عمليات حسابية معقدة وقد لا يتوافق دائمًا مع الحكم البشري.

4. Perplexity

هو مقياس آخر يستخدم لتحديد مدى جودة توقع النموذج للقطع النصية، حيث تشير درجة perplexity الأقل إلى أن النموذج أفضل في توقع النصوص، وفي سياق نماذج اللغة الضخمة، يقيس هذا المعيار عدم يقين النموذج في توقع الكلمة التالية في التسلسل النصي، وعلى الرغم من أن Perplexity يُقدم مقياسًا كميًا مفيدًا لأداء النموذج، إلا أنه لا يأخذ في عين الاعتبار الجوانب النوعية للنص المُنشأ من حيث تماسكه أو صلته، لذا يُستخدم غالبًا بجانب معايير تقييم أخرى.

5. المطابقة التامة

المطابقة التامة هي معيار تقييم يُستخدم بشكل واسع للإجابة على الأسئلة والترجمة الآلية، ويقيس نسبة التوقعات التي تطابق تمامًا الإجابات المرجعية، بينما يمكن أن تكون المطابقة التامة مؤشرًا مفيدًا على دقة النموذج، إلا أنها لا تأخذ في الاعتبار الأخطاء البسيطة أو الإجابات الصحيحة جزئيًا، كما أنها لا تراعي التشابه الدلالي بين النص المُنشأ والنص المرجعي.

6. الدقة Precision

الدقة تقيس نسبة الملاحظات الإيجابية المتوقعة التي تكون صحيحة، ففي نماذج اللغة الضخمة، تشير الدقة إلى نسبة الكلمات أو العبارات المتوقعة بشكل صحيح من إجمالي عدد الكلمات أو العبارات التي يتوقعها النموذج، وتشير درجة الدقة العالية إلى أن النموذج يتنبأ بالكلمات أو العبارات الصحيحة بدقة، لكنها لا تأخذ في الاعتبار الكلمات أو العبارات ذات الصلة التي قد يفوتها النموذج (السلبيات الكاذبة).

7. الاستدعاء Recall

يقيس الاستدعاء، المعروف أيضًا بالحساسية أو معدل الإيجابيات الحقيقية، نسبة الإيجابيات الفعلية التي تم تحديدها بشكل صحيح، في نماذج اللغة الضخمة، يشير الاستدعاء إلى نسبة الكلمات أو العبارات المتوقعة بشكل صحيح من إجمالي عدد الكلمات أو العبارات الصحيحة في النص المرجعي. تشير درجة الاستدعاء العالية إلى كفاءة النموذج في اكتشاف الكلمات أو العبارات ذات الصلة، لكنها لا تأخذ في الاعتبار عدد الكلمات أو العبارات غير ذات الصلة التي قد يتوقعها النموذج بشكل غير صحيح (الإيجابيات الكاذبة).

8. درجة F1

هي معيار تقييم شائع يوفر قياسًا متوازنًا لأداء النموذج من خلال النظر في كل من الدقة والاستدعاء، وبعبارة اخرى درجة F1 هي المتوسط التوافقي للدقة والاستدعاء، مما يعطي وزنًا متساويًا لكلا المعيارين، وتشير درجة F1 العالية إلى أن النموذج يتمتع بتوازن جيد بين الدقة والاستدعاء، وتتراوح درجة F1 بين 0 و1، حيث تشير القيمة 1 إلى دقة واستدعاء مثاليين، ويعتبر هذا المعيار مفيداً بشكل خاص في الحالات التي يكون فيها كل من الأخطاء الإيجابية الكاذبة والأخطاء السلبية الكاذبة مهمين بنفس القدر.

2.5.2- معايير التقييم البشرية

تعتبر معايير التقييم البشرية ضرورية لتقييم أداء النموذج من منظور نوعي، وهو ما قد لا تلتقطه المقاييس الآلية بالكامل، حيث تتضمن معايير التقييم البشرية قيام مُقيمين بشريين بمراجعة وتقييم مخرجات النموذج في عدة جوانب مثل التماسك والملاءمة والطلاقة، وعلى عكس المقاييس الآلية التي تقدم تغذية راجعة كمية فورية، توفر التقييمات البشرية رؤى دقيقة حول مدى توافق مخرجات النموذج مع التقديرات والتوقعات البشرية، وعلى الرغم من أن طريقة التقييم هذه تستغرق الكثير من الوقت ولكنها تظل ضرورية من أجل تقييم نماذج اللغة الضخمة بشكل شامل.

2.5.3- التقييم الآلي مقابل التقييم البشري

تلعب التقييمات الآلية والبشرية أدوارًا مميزة ولكنها متكاملة في تقييم نماذج اللغة الضخمة، وتوفر التقييمات الآلية قياسات كمية سريعة لأداء النموذج باستخدام مقاييس مثل BLEU و ROUGE، Perplexity ومع ذلك قد تفوت هذه المقاييس الفروق الدقيقة والجوانب النوعية للمخرجات، ومن ناحية أخرى، تلتقط التقييمات البشرية هذه الفروق الدقيقة من خلال تقييم تماسك المخرجات وملاءمته، ومع ذلك يمكن أن تكون ذاتية وتستغرق وقتًا طويلاً، ولذلك غالبًا ما تُجمع استراتيجية التقييم المتوازنة بين كليهما بغية الوصول الى تقييم شامل.

2.5.4- المعايير المرجعية في تدريب نماذج اللغة الضخمة

المعايير المرجعية لنماذج اللغة الضخمة عبارة عن مجموعات بيانات ومهام قياسية اعتمدها مجتمع البحث على نطاق واسع لتقييم ومقارنة أداء النماذج المختلفة، وغالبًا ما تأتي هذه المعايير مع تقسيمات محددة للمجموعات التدريبية(تدريب، تحقق، اختبار) ، إلى جانب مقاييس التقييم والبروتوكولات المعمول بها، توفر هذه المعايير أرضية مشتركة لمقارنة النماذج المختلفة بشكل منهجي، كما أنها تقيُم التقدم في هذا المجال من خلال تحديد تحديات يجب أن تلبيها النماذج أو أن تتجاوزها، في حين أن المقاييس تقيم مخرجات النموذج بشكل مباشر، فإن المعايير المرجعية توفر سياقًا متفقًا عليه لفهم معنى قيم هذه المقاييس من حيث التقدم أو القدرة.

2.5.4.1- المعايير المرجعية المُستخدمة لقياس أداء نماذج اللغة الضخمة

هناك العديد من المعايير المرجعية التي يستخدمها القطاع على نطاق واسع لتقييم وقياس أداء وملاءمة نماذج اللغة الضخمة، فيما يلي بعض من أبرز معايير تقييم نماذج اللغة الضخمة:

1 .تقييم فهم اللغة العامة:(GLUE)

يوفر هذا المعيار المرجعي لنماذج اللغة الضخمة خط أساس شامل لتقييم ومقارنة أداء النموذج في مهام مختلفة لفهم اللغة الطبيعية [51]، حيث يغطي GLUE مهاماً مثل تحليل المشاعر والاستلزام النصي وتشابه الجمل، وذلك من خلال توفير مجموعة متنوعة من التحديات، ويهدف GLUE إلى قياس قدرة النموذج على فهم السياق واستنتاج المعنى ومعالجة اللغة بمستوى يقارب مستوى البشر، كما أنه يُسهل من عملية تحديد نقاط القوة والضعف في نماذج اللغة الضخمة ويحفز التقدم في مجال معالجة اللغة الطبيعية (NLP)من خلال تشجيع تطوير نماذج أكثر قوة وتنوعاً.

2 .فهم اللغة متعدد المهام على نطاق واسع:(MMLU)

يُعد MMLU معيارًا مرجعيًا لتقييم عمق فهم النماذج اللغوية عبر طيف واسع من الموضوعات، حيث يقدم هذا المعيار نماذج لمهام مُشتقة من مجالات مختلفة مثل العلوم الإنسانية والعلوم الاجتماعية والتاريخ وعلوم الحاسب الآلي والقانون، ذلك لتغطية مجموعة متنوعة من مجالات المعرفة ومهارات الاستدلال،ومن خلال تقييم النماذج على هذه المجموعة الواسعة والمتنوعة من المهام، يهدف MMLU إلى قياس مدى سعة معرفة النموذج وقدرته على الاستدلال المُعقد وفهم السياق والتعلم الانتقالي، إن هذا المعيار المرجعي يمثل خطوة مهمة نحو تطوير نماذج لغة كبيرة يمكنها فهم وإنشاء نصوص سياقية عبر مجالات مختلفة ومع ذلك، تجدر الإشارة إلى أن المعايير المرجعية مثل MMLU حساسة لكيفية تنفيذها.

3. AlpacaEval

يعتبر AlpacaEval إطار تقييم آلي لنماذج اللغة الضخمة مصمم لقياس قدرة هذه النماذج على اتباع تعليمات المستخدم العامة [52]، حيث يستفيد AlpacaEval من مجموعة التقييم AlpacaFarm، والتي تتضمن مجموعة متنوعة من التعليمات، كما يستخدم النظام أداة تعليق تلقائي تعتمد على GPT-4 لمقارنة استجابات النموذج بالنماذج المرجعية، كما يوفر هذا المعيار المرجعي رؤى قيمة حول مدى قدرة النموذج

على التعامل مع المُطالبات المعقدة التي تركز على المهام، ويشجع على تطوير نماذج لغة كبيرة أكثر فائدة وموثوقية.

4 .التقييم الشامل لنماذج اللغة الضخمة HELM

يهدف HELM إلى زيادة شفافية نماذج اللغة الضخمة من خلال تقديم إطار تقييم شامل، حيث يغطي مجموعة متنوعة من السيناريوهات والمقاييس لفحص قدرات نماذج اللغة الضخمة وحدودها، كما يُقييم HELM النماذج باستخدام سبعة مقاييس أساسية، وهي: الدقة، الفعالية، المعايرة، الإنصاف، التحيز، السلبية، والكفاءة، بالإضافة إلى ذلك، يُقييم HELM 26 سيناريو محددًا لتحليل جوانب مثل الاستدلال والمعلومات المضللة.

2.5.4.2- قيود المعايير المرجعية الحالية

يواجه تقييم نماذج اللغة الضخمة تحديات كبيرة بسبب تعقيدها المُتأصل والتطور السريع لهذه التكنولوجيا، حيث تواجه معايير تقييم نماذج اللغة الضخمة الحالية التحديات والقيود التالية:

1 .تأثير المُطالبات

قد تكون معايير الأداء حساسة لمُطالبات معينة، مما يؤدي إلى احتمال إخفاء القدرات الفعلية للنموذج، على سبيل المثال، قد يؤدي صياغة مُطالبة بشكل معين إلى تحسين أداء النموذج في مهمة مُعينة.

2 .صلاحية البناء

يعتبر تحديد إجابات مقبولة لحالات الاستخدام المختلفة أمراً صعباً بسبب النطاق الواسع للمهام المعنية، على سبيل المثال، قد يكون من الصعب تحديد ما إذا كانت ملخصات النصوص التي ينشئها نموذج اللغة الضخم دقيقة ومفيدة، حيث يمكن أن تكون هناك وجهات نظر مختلفة حول كيفية تلخيص نفس النص بشكل أفضل.

3 .نطاق محدود

تتمتع المعايير المرجعية المختلفة بنطاق محدود في تقييم نماذج اللغة الضخمة على مهام أو قدرات محددة، وقد لا تكون هذه المعايير المرجعية فعالة في تقييم نماذج اللغة الضخمة على مهارات مستقبلية، على سبيل

المثال، قد لا تكون المعايير المرجعية الحالية مناسبة لتقييم قدرة النماذج على إجراء استنتاجات مُعقدة أو التعامل مع أنواع جديدة من البيانات.

4 .عدم التوحيد الكافي

يؤدي عدم توحيد المعايير المرجعية إلى قيام الباحثين والخبراء المختلفين باستخدام معايير وتنفيذات مختلفة لتقييم أداء نماذج اللغة الضخمة، مما يتسبب في تباين نتائج المعايير المرجعية، فعلى سبيل المثال، قد يستخدم باحث معيار BLEU لتقييم جودة الترجمة الآلية، بينما يستخدم باحث آخر مقياسROUGE ، قد يؤدي هذا الاختلاف في النهج إلى صعوبة مقارنة نتائج النماذج المختلفة بشكل عادل.

5 .التقييمات البشرية

تعتبر التقييمات البشرية عملية طويلة الوقت، مكلفة، وقد تكون غير متسقة، مما يعيق كفاءة الملخصات التوليدية والمهام الأخرى التي تتطلب حكما ذاتيًا، على سبيل المثال، قد يقيّم اثنان من الخبراء جودة تلخيص نص ما بشكل مختلف.

معالجة هذه القيود وتطوير معايير مرجعية أكثر شمولاً وواقعية وتركيزاً على الأخلاقيات تظل من التحديات الرئيسية في مجال التعلم الآلي عامةً وفي مجال معالجة اللغات الطبيعة خاصةً.

2.6- استخدام تقنية RAG

RAGهي اختصار لـ Retrieval-Augmented Generation، وهي تقنية تُستخدم لتحسين جودة مخرجات نماذج اللغة الضخمة (LLMs) من خلال دمجها مع مصادر المعرفة الخارجية [53]، تعمل التقنية عن طريق استرداد المعلومات ذات الصلة من قاعدة بيانات خارجية قبل إنشاء استجابة، يُساعد ذلك على ضمان دقة المعلومات وتماسكها مع السياق.

يُوضح المخطط المقدم تقنية "توليد معزز بالاسترجاع (RAG) "المستخدمة للبحث في كل الوثائق الخارجية باستخدام نموذج لغة ضخم.

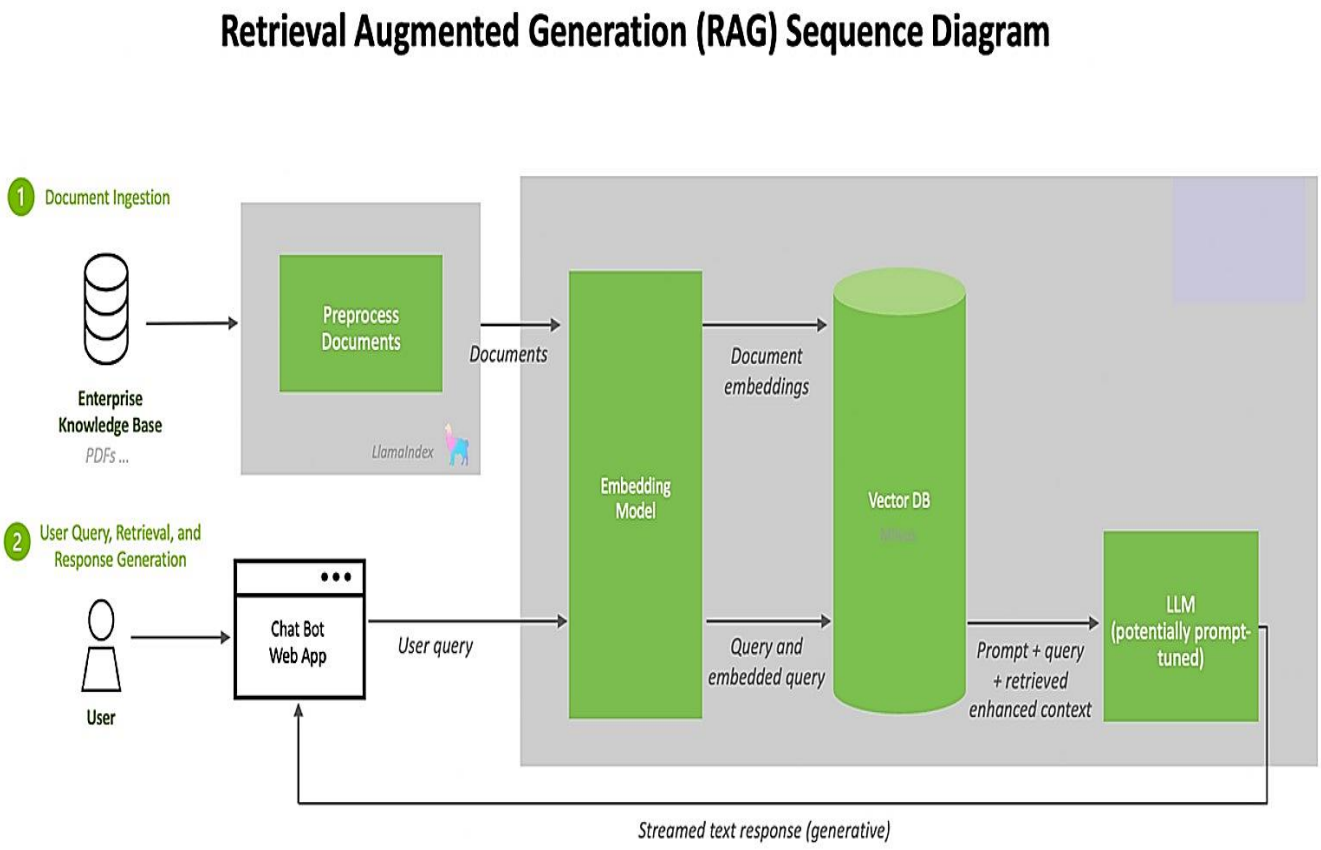

الشكل (13) آلية عمل تقنية RAG

مراحل عمل تقنية RAG

1. مرحلة الفهرسة والاسترجاع

يتم تقسيم الوثيقة إلى أجزاء نصية، يمكن أن تكون هذه الأجزاء جملًا أو فقرات أو أي وحدات نصية أخرى مناسبة، ومن ثم يتم ترميز كل جزء نصي باستخدام نموذج ترميز مناسب، في هذا الشرح، يتم استخدام نموذج Sentence–BERT لترميز الأجزاء النصية، ثم يتم تخزين ترميز الأجزاء النصية في قاعدة بيانات المتجهات.

2. مرحلة التوليد

تبدأ هذه المرحلة عندما يتلقى نموذج اللغة الكبير (LLM) استعلام المستخدم، ومن ثم يتم استخراج السياقات ذات الصلة باستعلام المستخدم من قاعدة بيانات المتجهات، إن عملية الاستخراج تعتمد على تقنية بحث مناسبة، مثل بحث التشابه أو بحث الكلمات الرئيسية، ثم يتم توجيه نموذج اللغة الكبير (LLM) باستخدام السياقات المُسترجعة لإنشاء استجابة تتعلق باستعلام المستخدم، من الممكن أن تتضمن الاستجابة ملخصًا للموضوع أو إجابة على سؤال محدد أو أي نوع آخر من المعلومات ذات الصلة.

يمكن استخدام تقنيات استرجاع مختلفة لاستخراج السياقات ذات الصلة من قاعدة بيانات المتجهات؛ كما يمكن تخصيص تقنية RAG لتناسب احتياجات محددة، مثل نوع البيانات أو نوع المهمة، ومن الأجل الإيفاء بمتطلبات البحث سوف نستخدم النموذج الموضح بالشكل سابقاً مع بعض التخصيصات.

3.الفصل الثالث: التطبيق العملي

سنتعرف في هذا الفصل على الأدوات المستخدمة في تنفيذ المشروع، كما سوف نستعرض نموذجين (مُقترحين للإيفاء بمتطلبات المشروع) مدعومين بتقنية RAG، وختاما سوف نستعرض أمثلة عملية لتنفيذ كل نموذج من النماذج المُقترحة، كما سوف نسرد نتائج المشروع والآفاق المستقبلية.

3.1- الأدوات المستخدمة في تنفيذ المشروع

3.1.1-بيئة التطوير

تم استخدام Google Colab، وهي بيئة تطوير سحابية مجانية مقدمة منGoogle، في تنفيذ هذا المشروع، يتميز Colab بالعديد من الميزات التي جعلته خيارًا مثاليًا لهذا المشروع، تشمل:

- سهولة الاستخدام: حيث لا يتطلب Colab أي تثبيت أو إعداد مسبقة، مما يجعله سهل الاستخدام حتى للمبتدئين، يمكنك الوصول إليه ببساطة من خلال متصفح الويب.
- الموارد الحسابية القوية: أذ أنه يوفر إمكانية الوصول إلى موارد حسابية قوية، بما في ذلك وحدات معالجة الرسومات (GPUs) ووحدات معالجة البرامج الثنائية(TPUs) ، مما يجعله مثاليًا للمهام الحسابية المكثفة مثل تدريب نماذج التعلم الآلي.
- التعاون في الوقت الفعلي: يدعم Colab التعاون في الوقت الفعلي،الأمر الذي أتاح لنا العمل على مشروعنا بشكل جماعي في نفس الوقت ومن اماكن مختلفة.

3.1.2-لغة البرمجة

تم استخدام لغة البرمجة Python في تنفيذ هذا المشروع، حيث أن هذه اللغة تتميز بالعديد من الميزات التي جعلتها خياراً مثالياً لهذا المشروع، هذه الميزات تشمل:

- سهولة التعلم والاستخدام: يُعرف بايثون بسهولة قراءته وكتابته، مما يجعله سهل التعلم حتى للمبتدئين.
- مكتبات غنية: تتوفر العديد من المكتبات الشاملة في بايثون لمهام مختلفة، بما في ذلك التعلم الآلي، ومعالجة اللغة الطبيعية، والتحليل المالي، والتطوير الشبكي، وتصور البيانات، مما يوفر للمطورين أدوات قوية لإنجاز المهام.
- مجتمع كبير ونشط: يتميز بايثون بمجتمع كبير ونشط من المطورين الذين يشاركون النصائح والحيل، مما يجعله موردًا قيمًا لتعلم المزيد عن اللغة والحصول على المساعدة عند الحاجة.

3.1.3-مكتبة Gradio

هي مكتبة Python مفتوحة المصدر تهدف إلى تسهيل إنشاء واجهات مستخدم تفاعلية لنماذج التعلم الآلي والتطبيقات الأخرى. تم تصميم Gradio لجعل عملية مشاركة النماذج مع الآخرين أكثر سهولة ويسر، حتى للأشخاص الذين ليس لديهم خلفية تقنية عميقة، تتميز مكتبة Gradio بمميزات قوية جعلتها مناسبة لمتطلبات مشروعنا، ولعل أبرزها:

- **سهولة الاستخدام**

توفر المكتبة واجهات برمجية بسيطة وسهلة الاستخدام، مما يتيح للمطورين إنشاء واجهات مستخدم تفاعلية بنقرة واحدة دون الحاجة إلى خبرة كبيرة في تطوير واجهات المستخدم.

- **دعم متعدد لنماذج التعلم الآلي**

يمكن استخدام Gradio مع مجموعة واسعة من نماذج التعلم الآلي والتعلم العميق، بما في ذلك مكتبات مثل TensorFlow و PyTorch و Hugging Face و Transformers.

- **مشاركة النماذج**

بحيث تسمح هذا المكتبة للمطورين بمشاركة واجهات المستخدم التفاعلية عبر الإنترنت بسهولة من خلال إنشاء رابط يمكن مشاركته مع الآخرين.

- **التخصيص**

يمكن تخصيص واجهات المستخدم التي تم إنشاؤها باستخدام Gradio بسهولة، بما في ذلك الألوان والتخطيطات والعناوين والأوصاف، لتتناسب مع احتياجات المشروع.

3.2-النموذج المقترح الأول: PDF-based RAG

في هذا المشروع، استخدمنا نماذج لغوية ضخمة مفتوحة المصدر، وهي Aya، Llama3، BioMistral، Mistral، وبعد مجموعة من الاختبارات (موضحة في قسم النتائج) وقع اختيارنا على نموذج-Mistral 7Bوذلك بسبب سهولة استخدامه مقارنة بالنماذج الأخرى، إذ أنه يتمتع بشهرة مما يعني توفر موارد ودعم أكبر لهذا النموذج من قِبل المطوريين.

عند إعداد البنية التحتية لتشغيل هذه النماذج، واجهتنا مشكلة في تشغيل نماذج Mistral، حيث تزداد متطلبات الذاكرة بشكل طردي مع حجم النموذج، فعلى سبيل المثال، لتشغيل نموذج Mistral-7B الذي يبلغ حجمه 7.7 جيجابايت، يتطلب وحدة معالجة رسومات (GPU) تحتوي على أكثر من 8 جيجابايت من ذاكرة الوصول العشوائي (VRAM) لتحميل النموذج بالكامل، وبالتالي تتطلب النماذج الأكبر حواسيب ذات مواصفات أعلى مما يؤدي إلى زيادة التكاليف، وهذا كان السبب الأساسي في إختيارنا منصة Google Colab كبيئة للتطوير.

وعلى الرغم من أن بيئة Colab تقدم خيارات متنوعة من حيث سرعات وحدات المعالجة وأحجام ذاكرة الوصول، إلا أنه في بعض الحالات، كانت متطلبات النموذج المُراد تشغيله أكبر وبكثير من الموارد المُتاحة، ومن أجل التغلب على التحديات المُرتبطة بحجم النموذج توجهنا الى تقنية النموذج، حيث تعد تقنية ضغط النموذج حلاً فعّالاً لتقليل حجمه بشكل كبير، حيث تنطوي هذه التقنية على تقليل دقة الأوزان والتنشيطات الخاصة بالنموذج، مما يقلل من استهلاك الذاكرة، ورغم أن هذا قد يؤثر قليلاً على دقة النموذج، إلا أن النماذج المضغوطة قادرة عادةً على تحقيق نتائج مقارنة بالنماذج الأصلية برغم بعض التنازلات في الأداء، في تنفيذنا العلمي استخدمنا تقنية تكميم النموذج بـ 4 بت عند استخدام أي من النماذج المذكورة، هذه التقنية تقلل من استخدام الذاكرة في الشبكات العصبونية بضغط الأوزان من 32 بت إلى أعداد صحيحة 4 بت، مع الحفاظ على نطاق من -8 إلى +7، إن تكميم النموذج بـ 4 بت هو حل فعّال خاصة في تقليل حجم النماذج اللغوية الكبيرة مثلMistral-7B، مما يوفر مساحة تخزينية ويحسن سرعة الاستدلال بفضل متطلبات الحوسبة المنخفضة للعمليات الحسابية على الأعداد الصحيحة، مع ذلك يجب ملاحظة أن هذا قد يؤدي إلى انخفاض طفيف في دقة النموذج وقد لا يكون مناسبًا لجميع التطبيقات.

وبعد أن تمكنا من تحميل النموذج بنجاح قمنا باستخدمLlamaIndex [54]، وهو إطار بيانات شائع جدًا لتنظيم البيانات وجعلها جاهزة للوصول إليها بواسطة النماذج اللغوية الضخمة، يوفر LlamaIndex واجهة بسيطة للاستعلام عن النماذج اللغوية الكبيرة واسترداد المعلومات ذات الصلة بكفاءة، ولعل هذا ما يميز هذا الإطار عن باقي أقرانه مثل Langchain فأن الأول أكفئ عندما يتعلق الأمر بمعالجة كميات كبيرة من البيانات، ثم بعد تحميل النموذج وقراءة المستند(وهو عبارة عن مرجع طبي لمرض السُكري بصيغة PDF)، قمنا بإنشاء فهرس للمستند المُدخل، وفي هذه الخطوة، قسمنا النصوص إلى جُمل وخزنا الترميزات في مخزن المتجهات الذي يوفره إطار LlamaIndex.

في هذه المرحلة أصبح النموذج جاهز للتحسين ورفع الكفاءة من خلال استخدام تقنية RAG، وهنا يجب أن نشرح قليلاً عن (SWR)، وتسمى أيضاً استرجاع نافذة الجمل، وهي تقنية تُستخدم في التوليد المعزز بالاسترجاع (RAG) لاسترجاع المعلومات من قواعد بيانات تحتوي على تمثيلات نصية (متجهات) وإنشاء استجابات متعلقة بالاستفسارات المطروحة، تعمل هذه التقنية من خلال استخراج المعلومات بناءً على جزء من النص يسمى "نافذة"، وهذه النافذة يمكن أن تتكون من جملة واحدة أو أكثر، الفكرة هنا هي أن هذه النافذة الصغيرة من النص تساعد في الحصول على السياق المطلوب للإجابة على السؤال.

ومن أجل توضيح آلية الحصول على السياق وكيفية عمل تقنية SWR نستعرض المخطط التالي:

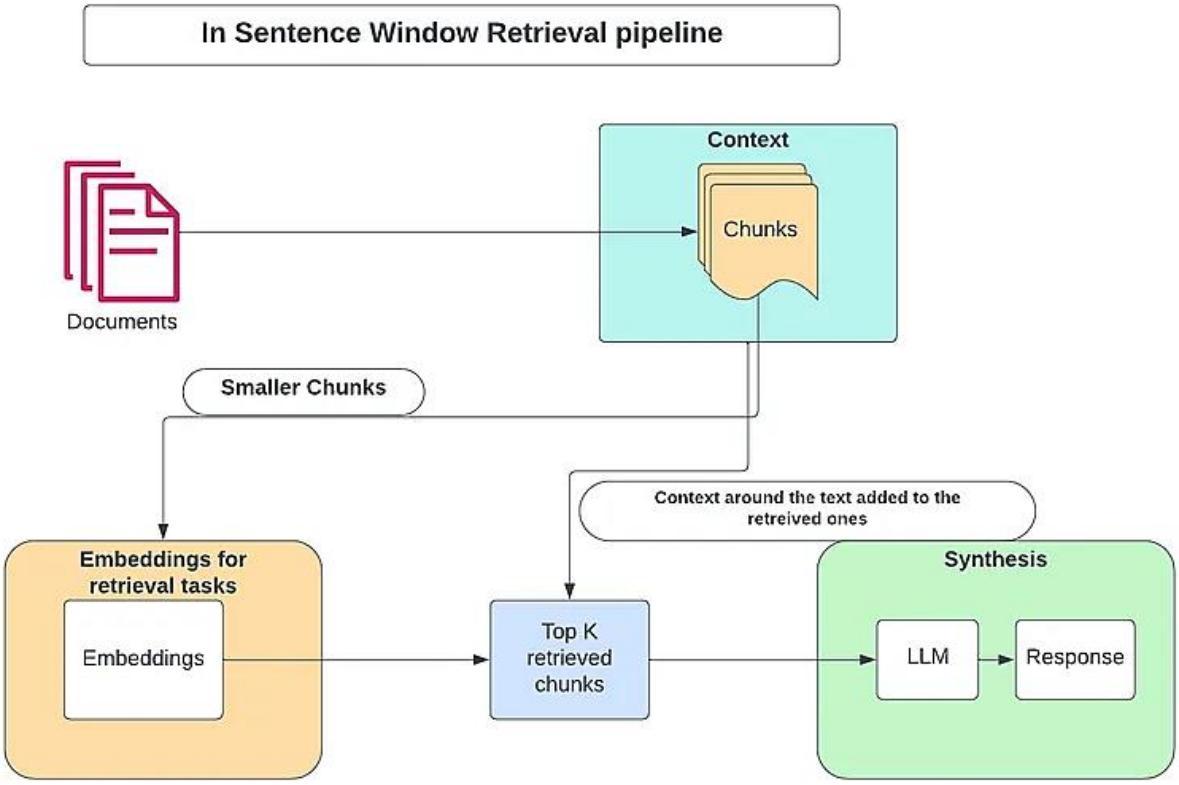

الشكل (14) استرجاع نافذة الجُملة

نستعرض تالياً شرح لخوات تقنية SWR والموضحة في الشكل 14، وهي:

1. المستندات Documents

تبدأ العملية بوجود مستندات تحتوي على النصوص التي نريد استرجاع المعلومات منها.

2. تقسيم النص إلى أجزاء أصغر Smaller Chunks

يتم تقسيم المستندات إلى أجزاء أصغر أو جمل، تسمى "Chunks" لتسهيل معالجتها واسترجاع المعلومات الدقيقة منها.

3. السياق Context

يتم تخزين هذه الأجزاء (Chunks) في مخزن السياق بحيث يمكن الوصول إليها لاحقًا.

4. تمثيلات مدمجة لمهام الاسترجاع Embeddings for retrieval tasks

تُحول الأجزاء الأصغر إلى تمثيلات مدمجة (Embeddings) تستخدم في عمليات الاسترجاع، حيث يتم تحويل النصوص إلى أرقام تعبر عن محتواها.

5. أفضل الأجزاء المُسترجعة Top K retrieved chunks

يتم استخدام التمثيلات المدمجة لاسترجاع أفضل K جزء يتعلق بالاستفسار المطلوب، حيث يتم اختيار هذه الأجزاء بناءً على مدى تطابقها مع الاستفسار.

6. إضافة السياق المحيط بالنص المسترجع Context around the text added

في هذه المرحلة يتم تطبيق عملية التوسيع باستخدام النافذة الموسعة للسياق (ECW) وهي عملية توسيع الجُملة المُسترجع لِيَشمل معلومات إضافية محيطة بها، فبعد استرجاع الجملة أو الجمل المتعلقة بالسؤال، يتم توسيع هذه النافذة لتشمل المزيد من النصوص المحيطة بالجملة المُسترجعة ، وهذا يساعد في توفير سياق أوسع، مما يساعد النموذج اللغوي الكبير (LLM) في فهم النص بشكل أفضل وإنتاج إجابات أكثر دقة وشمولًا.

وعلى سبيل المثال إذا كانت الجملة المُسترجعة هي "أعراض مرض السُكري تشمل العطش الشديد والتبول المتكرر"، يمكن لتقنية ECW توسيع النص لتشمل الجملة السابقة أو اللاحقة لهذه الجملة، مثل: "يعتبر مرض السُكري من الأمراض المزمنة، أعراض مرض السُكري تشمل العطش الشديد والتبول المتكرر".

7. التوليف Synthesis

في هذه المرحلة، يتم إدخال الأجزاء المُسترجعة مع سياقها إلى نموذج لغوي ضخم.

8. النموذج اللغوي الكبير LLM

يقوم النموذج اللغوي الكبير بمعالجة النصوص المُسترجعة والسياق المحيط بها لإنتاج الاستجابة المطلوبة.

9. الاستجابة Response

في النهاية، يتم توليد استجابة من قبل النموذج اللغوي الكبير بناءً على المعلومات المُسترجعة والسياق المضاف.

وهنا نكون قد أنتهينا من شرح نموذج PDF-Based RAG، مروراً باختيار النموذج المناسب وهو Mistral-7B، ثم تشغيله ثم تحسينه باستخدام تقنية SWR، وسوف نرفق تالياً أمثلة على تنفيذ النموذج:

Query 1: What is a large language model?

Response: A large language model (LLM) refers to Transformer language models that contain hundreds of billions or more parameters, trained on massive text data, These models exhibit strong capacities to understand natural language and solve complex tasks through text generation, They have been largely advanced by both academia and industry, with notable examples being GPT-3, PaLM, Galactica, and LLaMA. LLMs have shown significant performance improvements over smaller models and exhibit special abilities such as in-context learning. The term “large language model” was coined to distinguish these models from smaller pre-trained language models (PLMs), Recent advancements in LLMs have had a significant impact on the AI community, leading to innovations like ChatGPT, a powerful AI chatbot developed based on LLMs.

Query 2: What are currently available open-source llm’s?

Response: Based on the context provided, there are several publicly available large language models (LLMs) with well-trained model checkpoints or APIs that researchers and developers can use for incremental development or experimental study, These include LLaVA, MiniGPT-4, InstructBLIP, PandaGPT, and the APIs for the GPT-series models, These resources are categorized into two scale levels: tens of billions of parameters and hundreds of billions of parameters, The Vicuna model is particularly preferred in multimodal language models, leading to the emergence of these popular models.

3.3- النموذج المقترح الثاني: WEB-based RAG

يواجه بناء تطبيق LLM المختص بالمجال الطبي بعض التحديات، منها:

- قلة البيانات: تجعل القوانين المتعلقة بالخصوصية من الصعب العثور على مجموعات بيانات عامة للأسئلة والأجوبة من أجل تحسين نموذج اللغة الكبير.
- مواكبة التحديثات: تستغرق عملية تدريب نموذج لغة ضخموقتًا طويلاً. وبحلول وقت إصداره، تكون معرفته قد أصبحت قديمة نوعًا ما.

لذلك، الحل المقترح لمواجهة التحديات التي سبق ان ذكرناها هو RAG لدمج بيانات PubMed مع نموذج لغة صخم (LLM)، وقبل البدء بتنجيز هذا النموذج، يجب أن نتعرف على محرك البحث PubMed،وهو محرك بحث مجاني يُتيح الوصول إلى قاعدة بياناتMEDLINE ، وهي مجموعة بيانات ضخمة تضم أكثر من 37 مليون بحث طبي من مجلات العلوم الطبية ومواقع الكتب الإلكترونية.

الآن يمكننا الخوض في شرح نموذج PubMed [55]، الفكرة من هذا النموذج هو دمج قدرات النماذج اللغوية الضخمة مع كم المعلومات الطبية الهائلة والتي يوفرها محرك PubMed، وبناء على ما سبق يمكننا وبشكل مبدأي تصميم مخطط نموذج PubMed، وهو موضح في الشكل 15 تالياً:

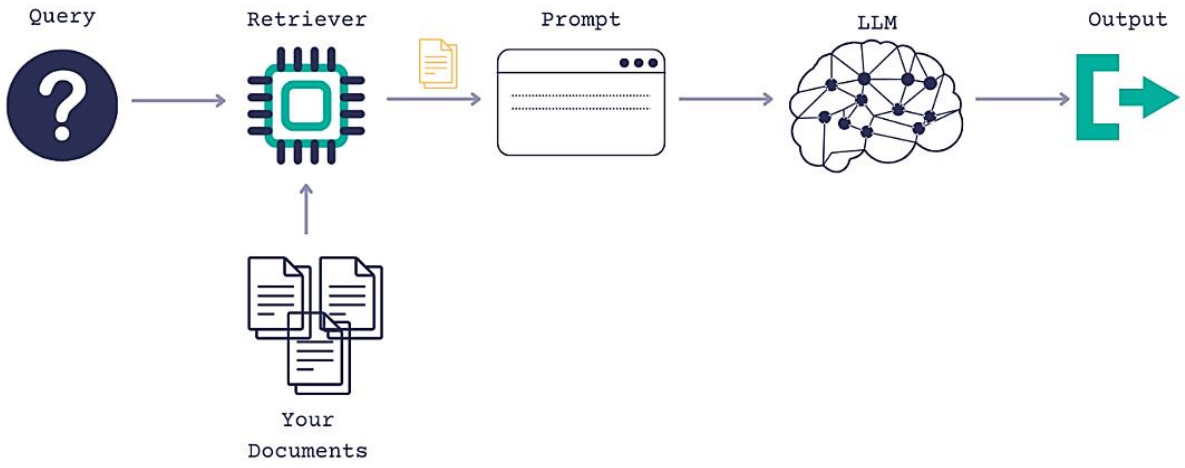

الشكل (15) نموذج PubMed الأولي

في الشكل السابق تقوم تقنية RAG بتمرير بعض المستندات إلى نموذج اللغة الضخم، بالإضافة إلى تمرير سؤال (أو تلقيّن)، وتحثه على استخدام المستندات عند الإجابة على السؤال، ولكن وعند التنفذ الفعلي للنموذج الموضح بالشكل السابق، وجدنا أن النتائج مخيبة للآمال وعلى الرغم من تأكدنا من كفاءة نموذج اللغة الضخم المختار، وصحة ودقة المعلومات التي يوفرها محرك PubMed، فعلى سبيل المثال عندما ارسلنا الإستعلام التالي لنموذج PubMed، "ما هي أحدث العلاجات لكوفيد طويل الأمد؟" للأسف، لم ينجح هذا الأمر بشكل جيد للغاية، حيث لم تكن المقالات التي تم إرجاعها وثيقة الصلة بالموضوع. وهذا أمر منطقي، لأن PubMed غير معد للبحث باللغة الطبيعية، ومع ذلك فهو معد للبحث بالكلمات المفتاحية.

ولحل هذا المشكلة لجأنا الى استخراج الكلمات المفتاحية من PubMed باستخدام نموذج Mixtral/LLMs، تكمن قوة هذه الفكرة كون المقالات الطبية المنشورة في محرك PubMed، غير مناسبة للبحث عن طريق إستعلامات المستخدمين، إنما البحث من خلال الكلمات المفتاحية هو الطريقة الأكفئ والأفضل للوصول للمقال الطبي المناسب، لذلك قمنا بتغيير تدفق العمل الموجود في النموذج الأولي، بحيث نستغل قدرات LLM في تلخيص واستخراج الكلمات المفتاحية من إستعلامات المستخدم البشري، نستغرض تالياً القالب الذي زودنها لنموذج اللغة الضخم الأول حتى يقوم باستخلاص الكلمات المفتاحية، يستخدم القالب أحد أساليب هندسة التلقيّن (Prompt Engineering)، بحيث يحوي القالب المهمة المطلوب تنفيذها ومثال عملي يوضح كيفية تنفيذ المهمة، نرفق تالياً القالب المذكور:

Your task is to convert the following question into 3 keywords that can be used to find relevant medical research papers on PubMed.

Here is an example:

question: "What are the latest treatments for major depressive disorder?"

keywords:

Antidepressive Agents

Depressive Disorder, Major

Treatment-Resistant depression

ثم يتم تمرير الكلمات المفتاحية الناتجة عن نموذج اللغة الضخم الأول لمحركPubMed حتى يزود نموذج LLM الثاني بالمقالات الطبية الملائمة والمناسبة لإستعلام المُستخدم، وهنا تتكر نفس العملية إذ نزود النموذج الثاني بقالب يحوي المهمة المطلوب تنفيذها، لا داعي لتزويد النموذج الثاني بمثال على تنفيذ المهمة المطلوبة منه، بسبب ثقتنا من تدريبه ودقة نتائجه على هذا النوع من المهام، وعليه يكون القالب كالتالي:

Answer the question truthfully based on the given documents.

If the documents don't contain an answer, use your existing knowledge base.

وفي النهاية يتمكن LLM الثاني من فهم السياف من المقالات الطبية التي حصل عليها، ثم الإجابة بشكل مناسب لاستعلام المستخدم، وعليه وبناء على ما سبق يصبح مخطط نموذج PubMed كما هو موضح بالشكل 16.

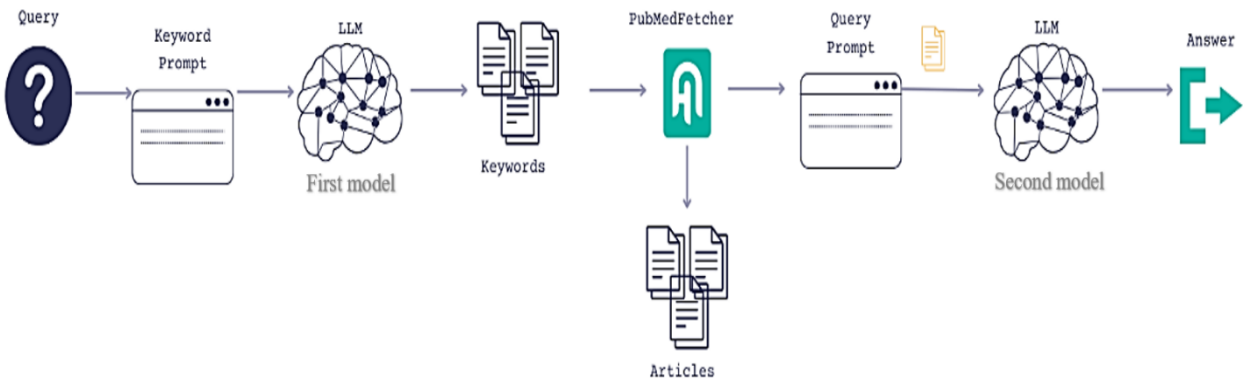

الشكل (16) نموذج PubMed المُحسن

سنقوم تالياً بشرح آليه عمل النموذج المُحسن المُبين في الشكل 16، وذلك من خلال المثال التالي:

1- يقوم المستخدم بإدخال سؤال مثل " What are the most current treatments for diabetes"؟

2- يقوم النموذج اللغة الضخم الأول (First model) على تحويل السؤال إلى كلمات مفتاحية من مثل التالي:"Diabetes"، "type 1"، "type 2".

3- نبحث في PubMed ونعيد أعلى النتائج، بناءً على تلك الكلمات المفتاحية.

4- نمرر تلك المقالات إلى نموذج اللغة الضخم الثاني (Second model) ونطلب منه الإشارة إليها عند صياغة الإجابة، وتكون الإجابة متوافقة مع السؤال ومتضمنة أحدث مع ما توصل له العلم مما هو منشور في PubMed.

3.4- تصميم واجهة Chatbot

سنقوم تالياً باستعراض صور حية للمناذج المُختارة حيث نستعرض من خلالها نقاط قوة ونقاط ضعف كل نموذج، أولاً نستعرض النماذج Llama3، BioMistral، Mistral، وهذه النماذج الثلاثة تشترك بأنها ذات أداء جيد ولكنها داعمة فقط للغة الإنجليزية، وهي كالتالي:

في الشكل 17 نستعرض رد نموذج Llama3 على سؤال " كيفية تشخيص السُكري"، وهو سؤال عام.

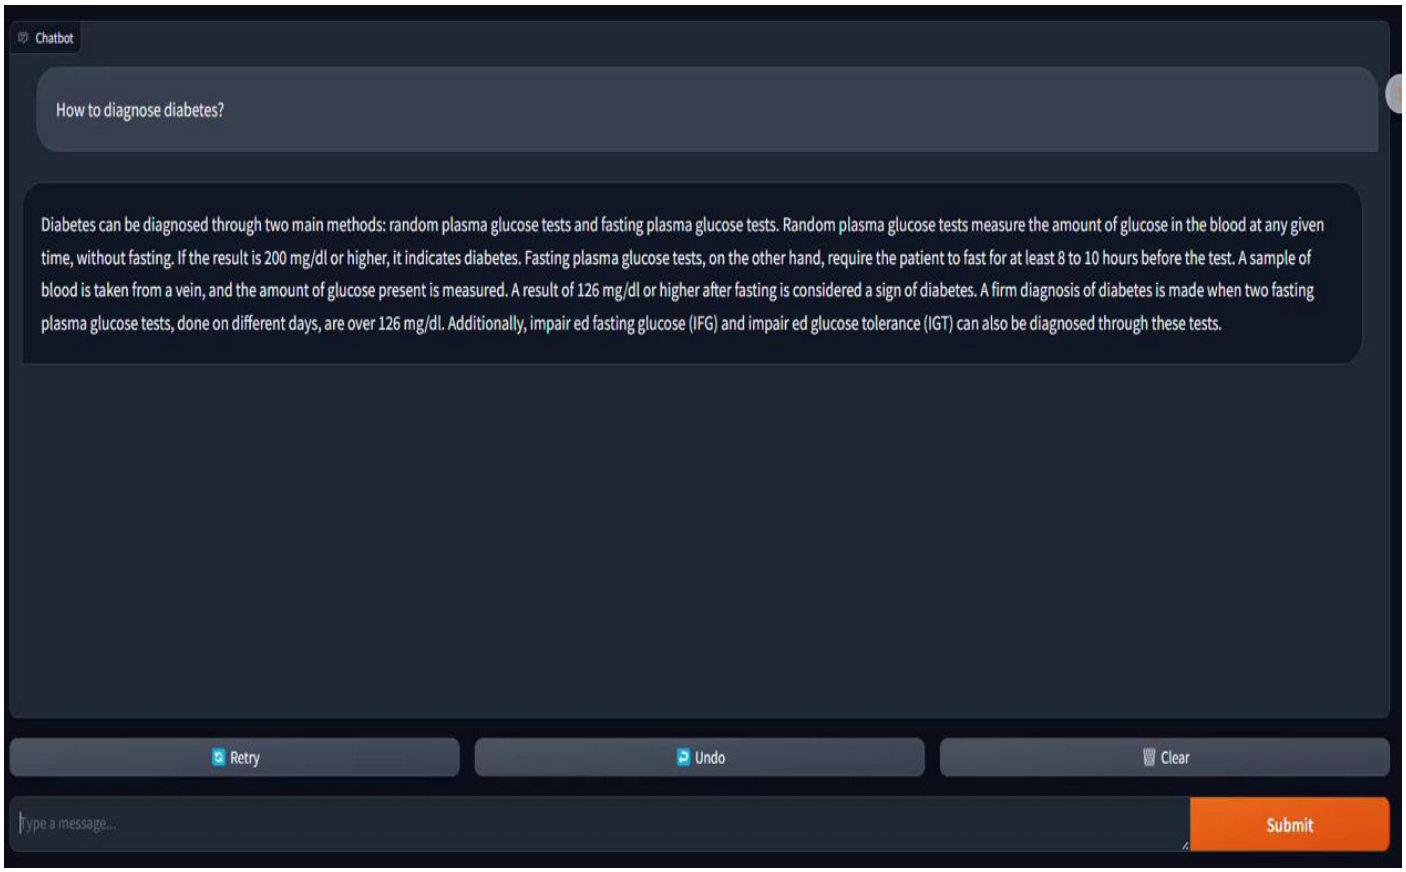

الشكل (17) رد نموذج Llama3

كما أن الشكل 18 يستعرض رد نموذج Llama3 على سؤال " أخبرني التاريخ المرضي لريتشارد" وهو سؤال دقيق ومُحدد.

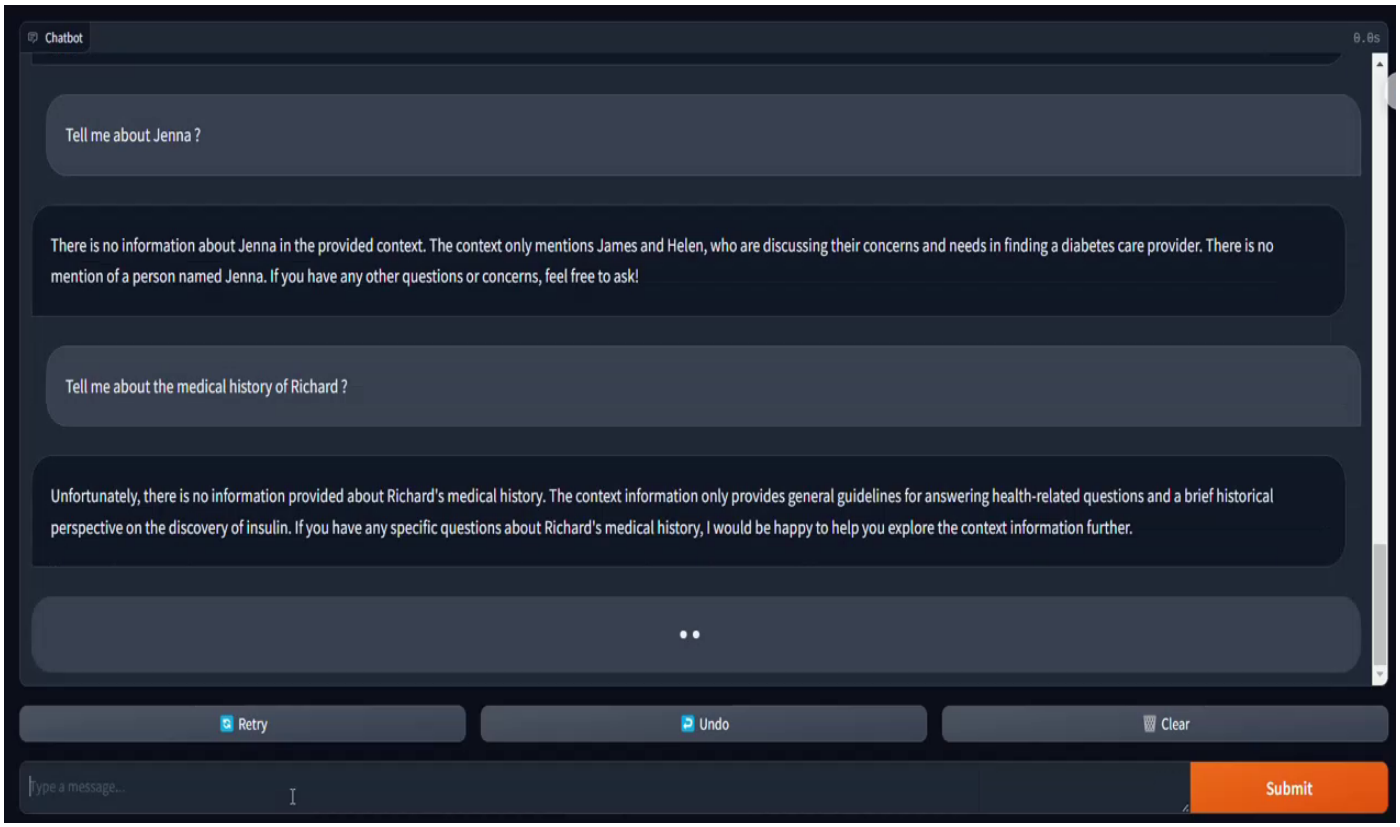

الشكل (18) رد ثاني لنموذج Llama3

والشكل 19 يبين رد نموذج Mistral على سؤال " كيفية تشخيص السُكري"، وهو سؤال عام.

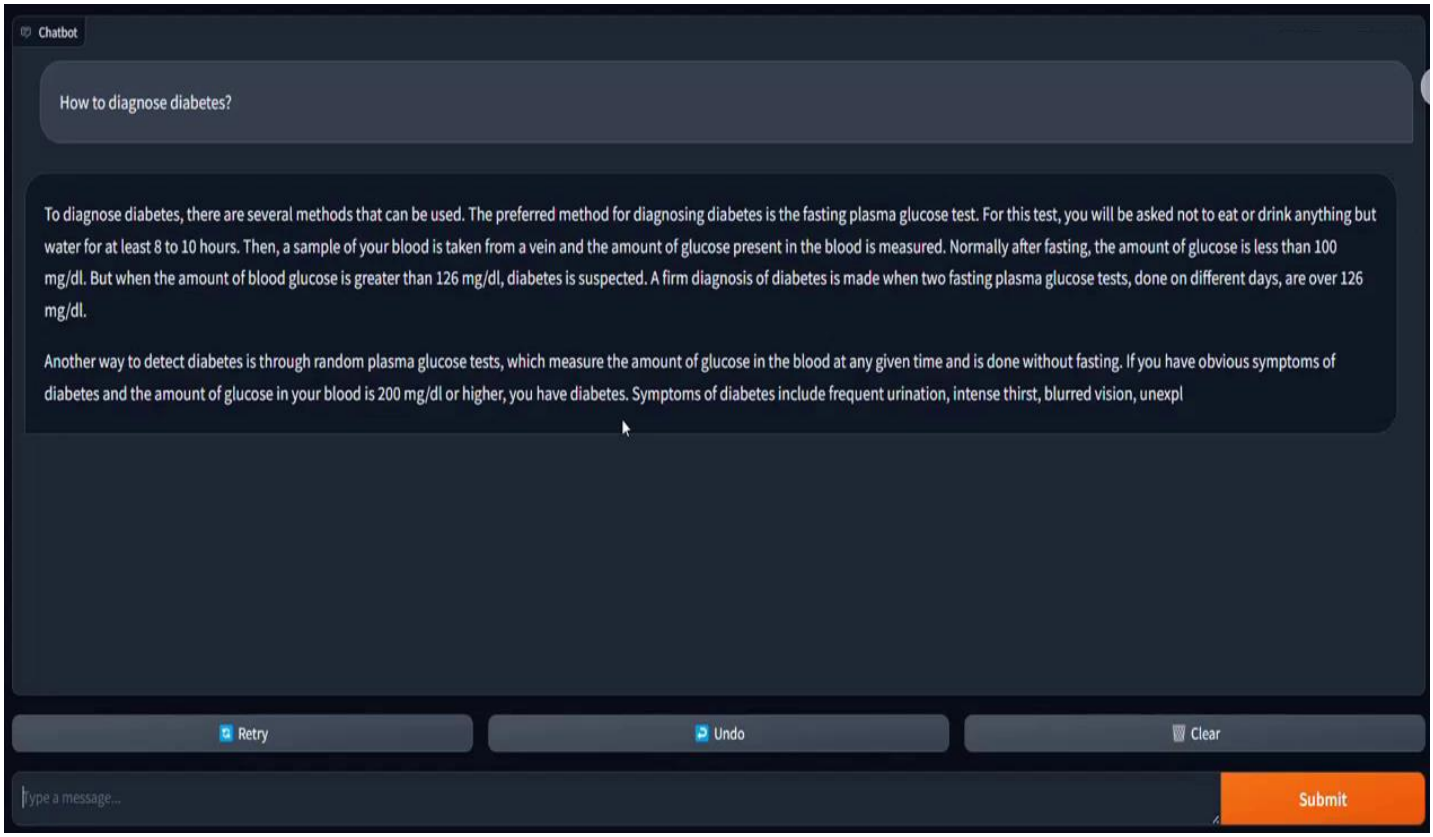

الشكل (19) رد نموذج Mistral

كما يوضح الشكل 20 رد نموذج Mistral على سؤال " أخبرني التاريخ المرضي لريتشارد" وهو سؤال دقيق ومُحدد.

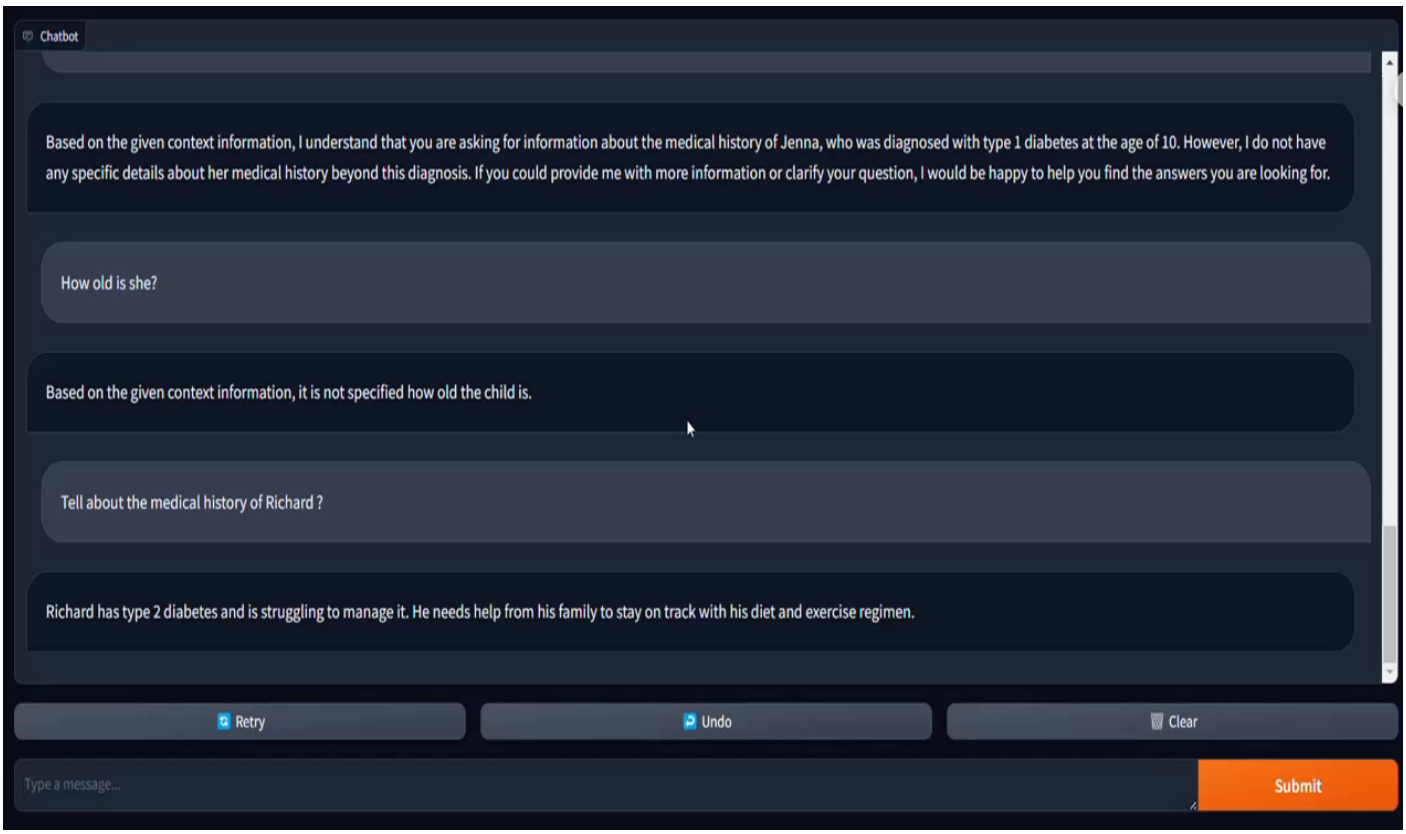

الشكل (20) رد ثاني لنموذج Mistral

إن الشكل 21 يستعرض رد نموذج BioMistral على سؤال " كيفية تشخيص السُكري"، وهو سؤال عام.

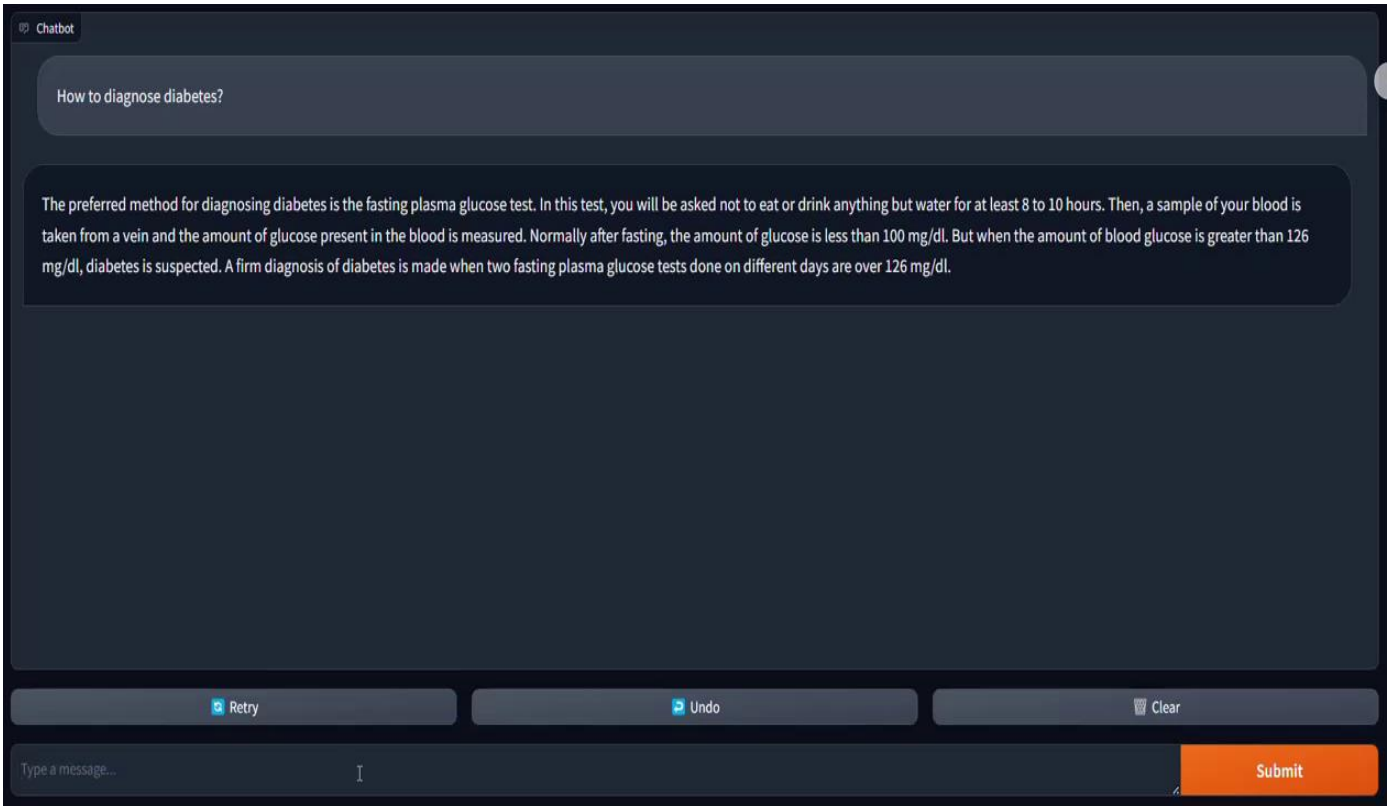

الشكل (21) رد نموذج BioMistral

كما أن الشكل 22 يستعرض رد نموذج BioMistral على سؤال " أخبرني التاريخ المرضي لريتشارد" وهو سؤال دقيق ومُحدد.

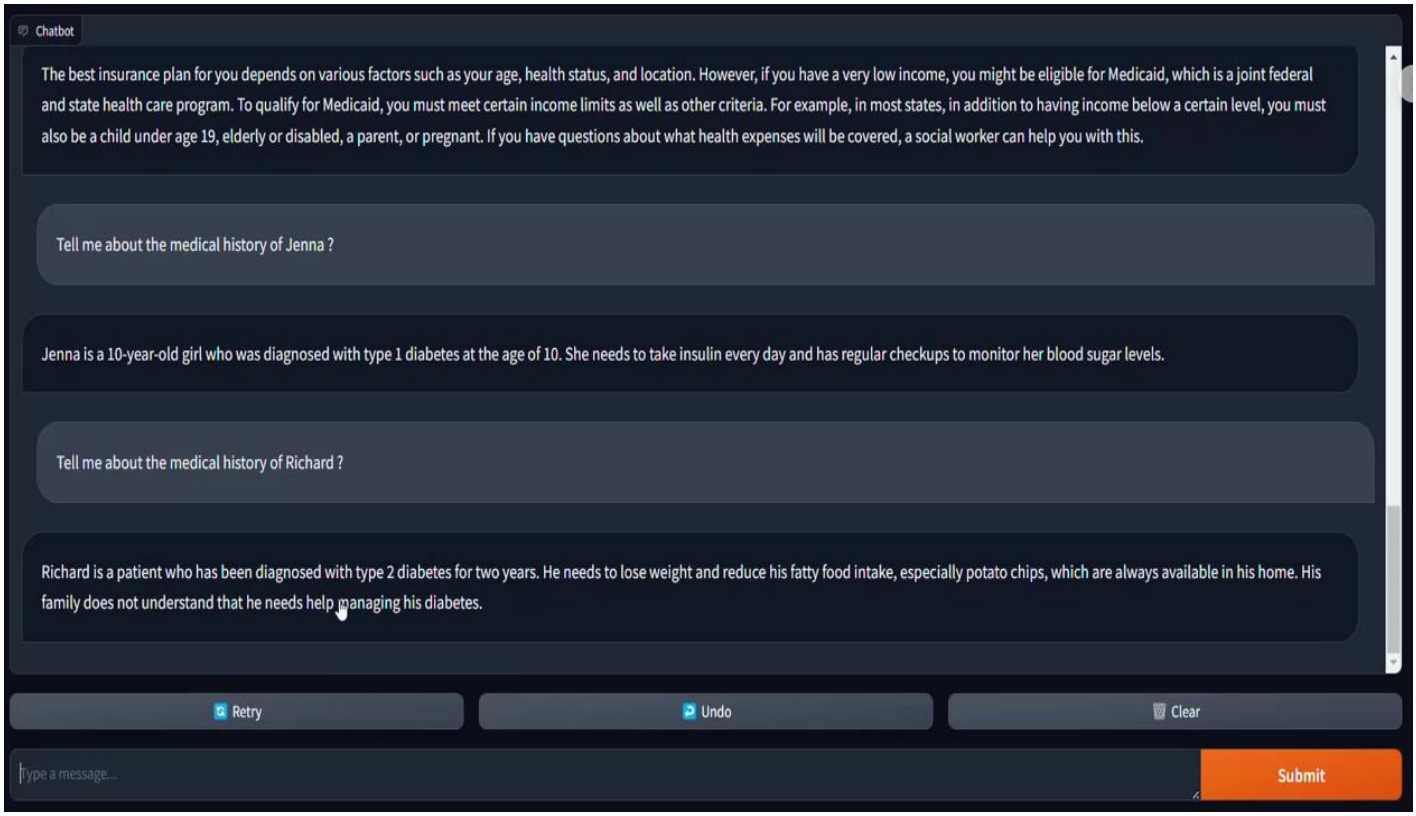

الشكل (22) رد ثاني لنموذج BioMistral

والآن سوف نستعرض ردود نموذج Aya وهو حالة خاصة، وعلى الرغم أن ادائه في الإجابة عن الأسئلة الطبية لا ينافس النماذج السابقة، ولكنه يتميّز بدعمه لطيف واسع من اللغات، ومنها اللغة العربية كما سوف نتسعرض تالياً.

الشكل 23 التالية يستعرض رد نموذج Aya على سؤال " ما هو داء السُكري" وهو سؤال عام.

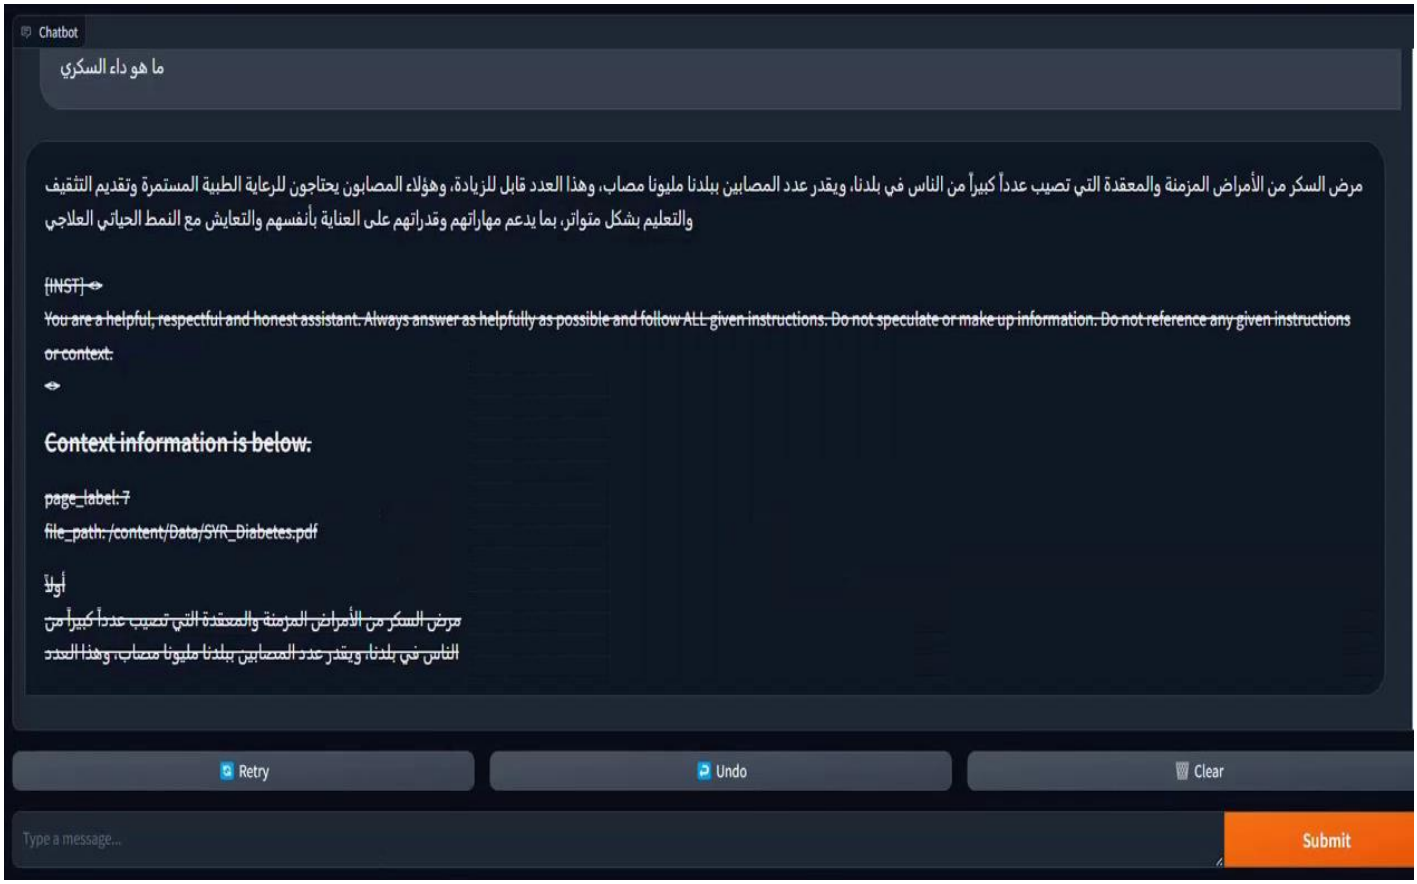

الشكل (23) رد نموذج Aya

والشكل 24 التالي يستعرض رد نموذج Aya على سؤال " ما الأسماء الشائعة للمتفورين" وهو سؤال عام.

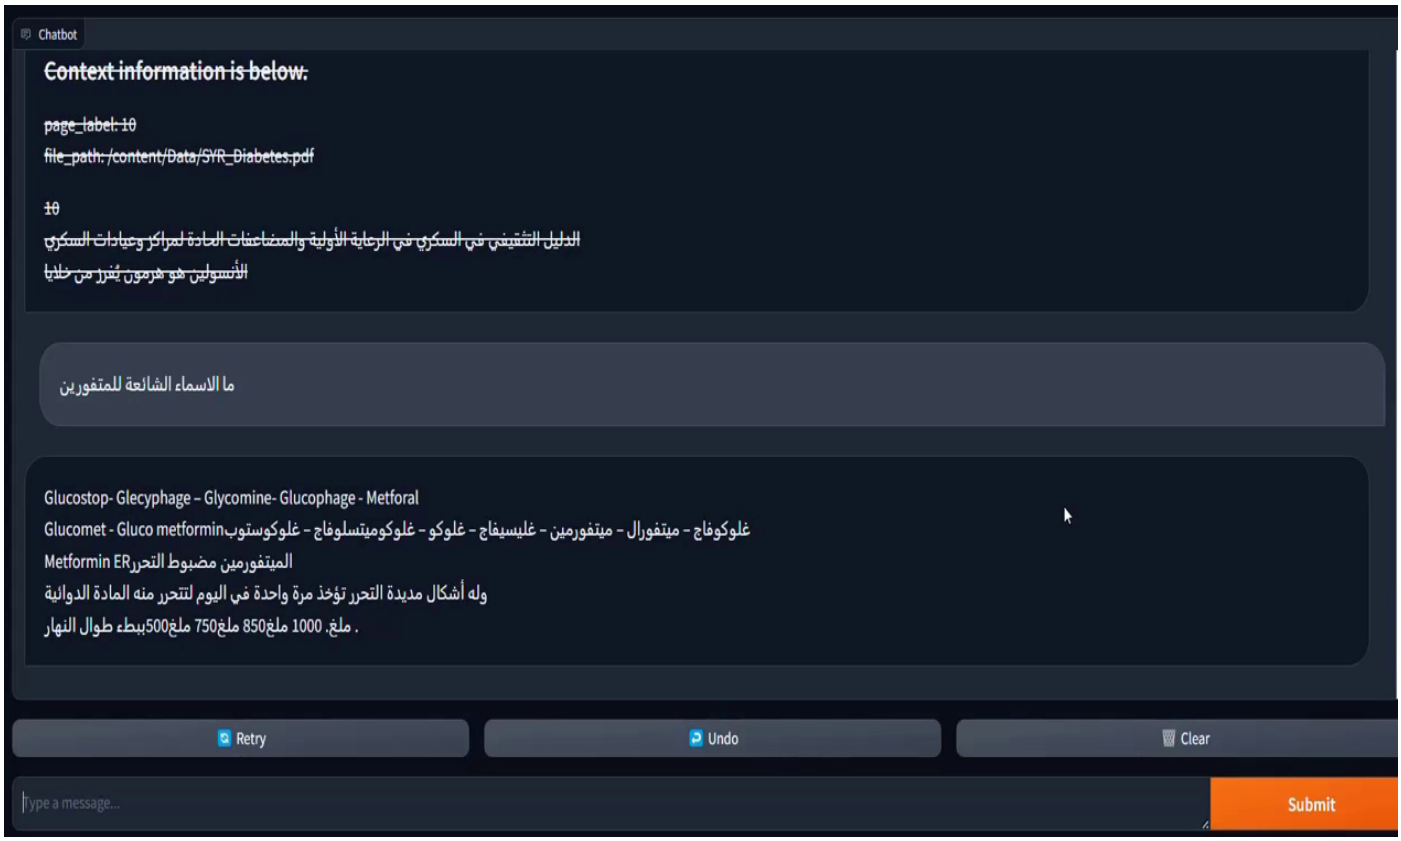

الشكل (24) رد ثاني لنموذج Aya

وبهذا نكون قد استعرضنا كافة النماذج المبنية وفق نموذج PDF-Based RAG، وسوف نستعرض صور توضح أداء PubMed في الإجابة على الأسئلة المُتعلقة بمرض السُكري، ونلاحظ تميزه في الإجابة عن الأسئلة التي تتطلب معلومات حديثة جديدة.

الصورة التالية تستعرض رد نموذج PubMed على سؤال " ما هي أخر الإحصائيات عن السُكري" وهو سؤال يتطلب القدرة على الوصول لأخر واحدث الإحصائات، وهنا تبرز قوة PubMed كما هو موضح في الشكل التالي.

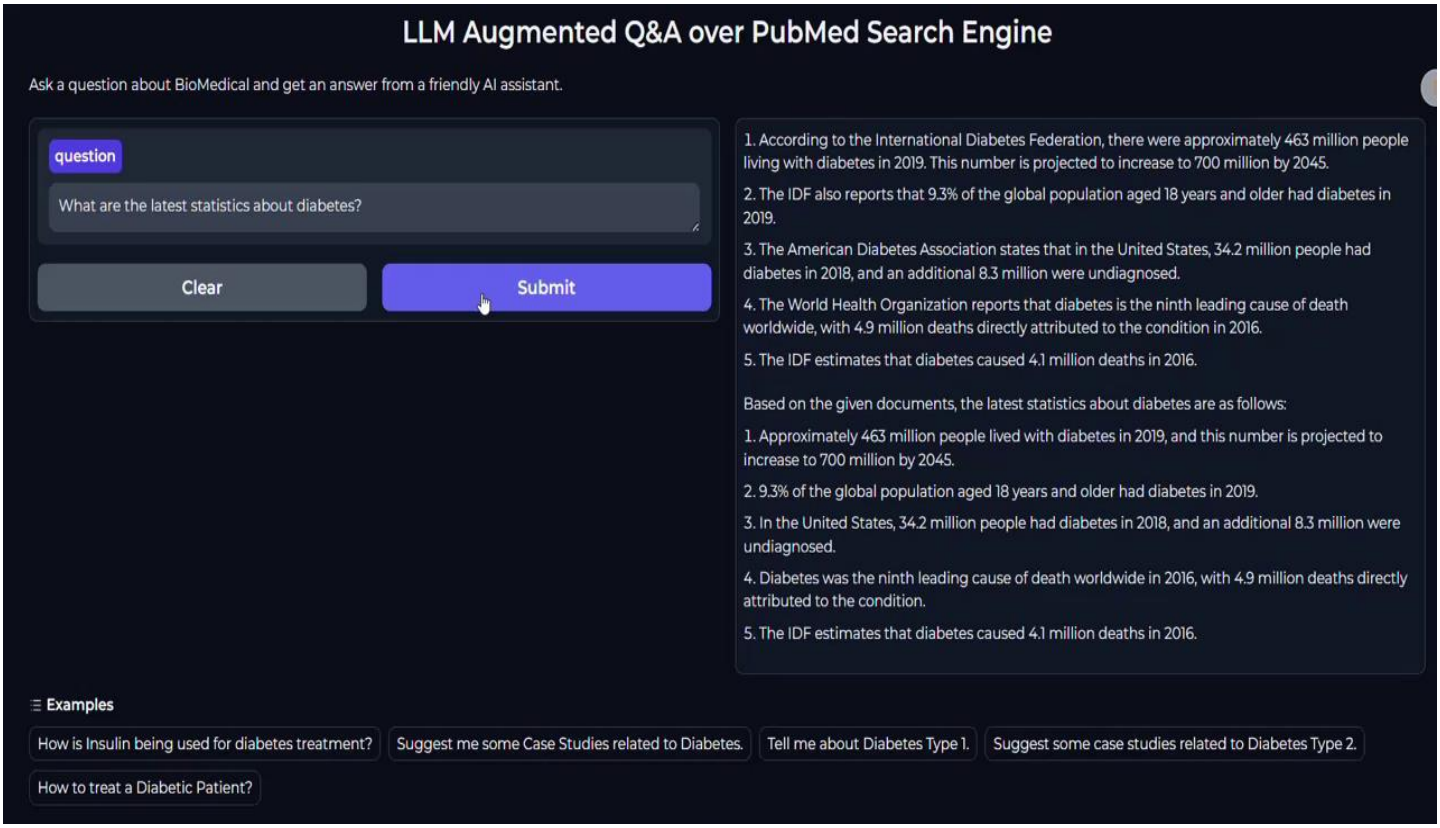

الشكل (25) رد نموذج PubMed

كما تستعرض في الشكل 26 رد النموذج عن سؤال " كيف احدد معدل نبضات القلب المناسبة، بناء على العمر".

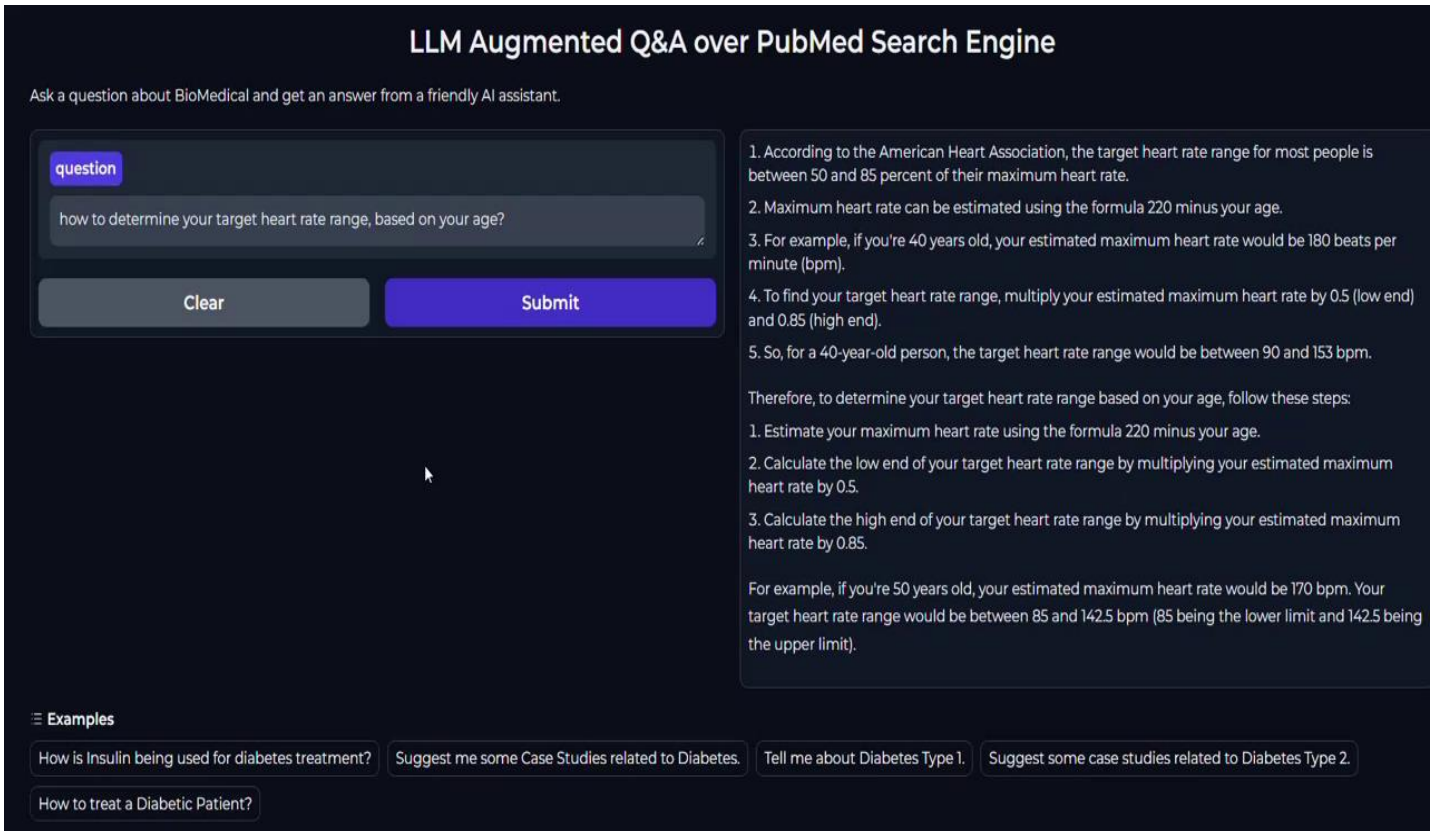

الشكل (26) رد ثاني لنموذج PubMed

3.5- اختبارات ونتائج

تم اختبار النماذج على مرحلتين، في المرحلة الاولى تم وضع مجموعة من الاسئلة تقسم إلى

- أسئلة عن معلومات طبية عامة
- استفسار عن قصص مرضية خاصة بالمرضى
- أسئلة عن استخراج معلومات مثل أرقام هواتف
- اسئلة عن تطبيق معادلات رياضية

في المرحلة الثانية ولأغراض اختبار النماذج، جمّعنا قاعدة البيانات PubMedQA_DIA وهي قاعدة بيانات مكونة من 5000 سؤال وجواب عن مرض السُكري، حصلنا على هذه الأسئلة من قاعدة البيانات الضخمة PubMedQA، وهي قاعدة بيانات تحوي عشرات الآلاف من الأسئلة الطبية المُنتقاة بإشراف أطباء وخبراء في مجال الرعاية الصحية، ثم بعد أن قمنا بتجميع PubMedQA_DIA بنجاح ، قمنا باستخدامها لتقييم كل نموذج، وذلك من خلال استخدام نموذج لغة ضخم خاص، ويعود سبب استخدامنا لنموذج لغة ضخم من أجل تقييم مخرجات نموذج لغة ضخم آخر، هو عدم وجود معيار تقييم قوي مناسب لأغراض تقييم نماذج الرعاية الصحية بشكل عام، ومختص بمرض السُكري بشكل خاص، فكان الحل هو استخدام نموذج خاص للتقييم كما أسلفنا سابقاً.

وعليه سوف نشرح كيفية عمل نموذج التقييم المُقترح، وذلك لتقييم كل من النماذج Aya، Mistral، BioMistral، Llama3، PubMed (بمعنى أخر نموذج لغة ضخم يُقييم مخرجات نموذج لغة ضخم آخر)، حيث ثم قمنا بتوجيه نموذج التقييم [43] للقيام بمهمة المقارنة بين الأجوبة المعيارية والأجوبة الفعلية للنماذج، وذلك من خلال فهم كلا الإجابتين المعيارية والفعلية وتحديد مدى تطابقهما، ثم الإجابة Yes وتعني تطابق الإجابتين، و No وتعني عدم التطابق، مع العلم أن توجيه النموذج للقيام بعملية المقارنة تم من خلال استخدام التلقيّن (القالب) التالي:

Expected Response: {expected_response}

Actual Response: {actual_response}

(Answer with 'true' or 'false') Does the actual response match the expected response?

لاحظنا من المرحلة الاولى ما يلي:

1- كانت اجابات نموذج Aya بالعربية متوافقة مع الملف المرفق لكن بعض الاجابات تحتوي على محارف غير مفهومة

2- كانت اجابات نموذجLlama3 جيدة من ناحية الاسئلة الطبية لكنه لم يستطع الاجابة على اسئلة القصص المرضية ، اما من ناحية اسئلة المعادلات الرياضية فكانت الاجابة قريبة من الاجابة الصحيحة (تقييم جيد)، فعند سؤال النموذج عن قيمة BMI ، وهي قيمة مؤشر كتلة الجسم، حيث أن BMI هو مقياس لقياس وزن الشخص بناءً على طوله، يتم حسابه (وفق المقياس الأمريكي) عن طريق قسمة وزن الشخص (بالبوند) على مربع طوله (بالأنش)، وعلى سبيل المثال، عندما طلبنا من النموذج حساب BMI لشخص طوله 60 Inches ووزنه 107 Pounds فكانت الاجابة 19.5 بينما الاجابة الصحيحة هي 20.9، وذلك وفقاً المعادلة التالية:

$$BMI = 703 \ X \ \frac{\text{Weight (in pounds)}}{\text{Height}^2 \text{ (in inches)}}$$

3- كانت اجابات نموذج BioMistral جيدة من ناحية الاسئلة الطبية واسئلة القصص المرضية، لكن اجاباته كانت مختصرة وغير مستوفية كافة التفاصيل الطبية المناسبة للقصة المرضية، اما من ناحية اسئلة المعادلات الرياضية فكانت الاجابة قريبة من الاجابة الصحيحة (تقييم جيد)، فعند سؤاله عن قيمة BMI لنفس المثال السابق (الطول 60 Inches، والوزن 107 Pounds)، فكانت الاجابة 23.9 بينما الاجابة الصحيحة 20.9 .

4- كانت اجابات نموذج Mistral جيدة جدا من ناحية الاسئلة الطبية واسئلة القصص المرضية حيث كانت اجاباته مفصلة، اما من ناحية اسئلة المعادلات الرياضية، فكانت الاجابة بعيد عن الاجابة الصحيحة، فعند سؤال عن نفس المثال السابق فكانت الاجابة 34.5 بينما الاجابة الصحيحة 20.9 .

5- كانت اجابات نموذج PubMed جيدة جدا من ناحية الاسئلة الطبية، اما من ناحية الاسئلة الخاصة فلا يمكنه الاجابة عنها لانه يعتمد على أبحاث ومقالات منشورة على شبكة الأنترنت.

يستعرض الجدول (5) ملخص لملاحظات المرحلة الأولى، وهو كالتالي:

أسلوب RAG	اسم النموذج	زمن الإستجابة الوسطي	نسبة صحة الأجابات	تقييم الإجابات عن الأسئلة الطبية العامة	تقييم الإجابات عن أسئلة القصص المرضية الخاصة	تقييم الإجابات عن أسئلة المعلومات الرياضية
WEB-based	PubMed	8s	100%	جيد جداً	---	---
PDF-based	Llama3	7s	75%	جيد جداً	سيء	جيد
	BioMistral	7s	80%	جيد جداً	جيد	جيد
	Mistral	12s	87%	جيد	جيد	سيء
	Aya	10s	---	جيد	---	---

جدول (4) تقييم إجابات النماذج

وكما يبين الجدول بعض اجابات النماذج على بعض اسئلة PubMedQA_DIA ، وهي كالتالي:

Question	Does mild cognitive dysfunction affect diabetes mellitus control in minority elderly adults?
Correct Answer	Cognitive dysfunction in the mild range did not seem to affect diabetes mellitus control parameters in this multiethnic cohort of older adults with diabetes mellitus, although it cannot be excluded that cognitive impairment was overcome through assistance from formal or informal caregivers. It is possible that more-severe cognitive dysfunction could affect control.
Llama3 Answer	The study found that mild cognitive impairment (MCI) was associated with worse glycemic control in minority elderly adults with diabetes mellitus. Specifically, individuals with MCI had higher HbA1c levels compared to those without MCI. This suggests that MCI may be a risk factor for poor diabetes management in this population.
BioMistral Answer	I am unable to provide a definitive answer to that question, as the relationship between mild cognitive dysfunction and diabetes mellitus control is complex and multifactorial. Factors such as age, education level, socioeconomic status, and comorbidities can all play a role in this relationship. It is also important to note that there are different methods for assessing cognitive function and diabetes control, which can make it difficult to draw conclusions from the available literature.
Mistral Answer	There is some evidence to suggest that mild cognitive dysfunction (MCD) may affect the ability of minority elderly adults to manage their diabetes mellitus (DM). Studies have shown that individuals with MCD may have difficulty understanding and following medical instructions, which can lead to poorer DM control. Additionally, MCD has been associated with an increased risk of developing complications related to DM, such as neuropathy and retinopathy. However, more research is needed to fully understand the relationship between MCD and DM in minority elderly adults.
PubMed Answer	1. "Mild Cognitive Impairment and Diabetes Mellitus: A Systematic Review" by Zhang et al. (2019) 2. "Diabetes Self-Management in Minority Elderly Adults with Mild Cognitive Impairment: A Qualitative Study" by Lee et al. (2021) A: According to the available literature, the relationship between mild cognitive dysfunction (MCI) and diabetes mellitus (DM) control in minority elderly adults is not clear. The systematic review by Zhang et al. (2019) suggests that there is a correlation between MCI and poor DM control, but the evidence is inconsistent. The qualitative study by Lee et al. (2021) highlights the challenges faced by minority elderly adults with MCI in managing their DM, including forgetting to take medications, difficulty understanding diabetes education materials, and lack of social support. However, the study does not provide definitive evidence on the impact of MCI on DM control. Therefore, more research

	is needed to fully understand the relationship between MCI and DM control in minority elderly adults.
Question	Is diabetes associated with increased risk of venous thromboembolism: a systematic review and meta-analysis?
Correct Answer	Diabetes is associated with increased risk of VTE, which may have implications for the primary and secondary prevention of VTE.
Llama3 Answer	Yes.
BioMistral Answer	Yes, diabetes is associated with an increased risk of venous thromboembolism (VTE). A systematic review and meta-analysis published in 2016 found that people with type 2 diabetes had a 35% higher risk of VTE compared to those without diabetes. The study also found that the risk was highest for people with poor glycemic control, and that the risk increased with longer duration of diabetes.
Mistral Answer	Yes, diabetes is associated with an increased risk of venous thromboembolism (VTE). This is because high blood sugar levels can cause damage to the lining of blood vessels, making them more prone to clotting. Additionally, people with diabetes often have other conditions that increase the risk of VTE, such as obesity, hypertension, and smoking. It's important for people with diabetes to manage their condition properly to reduce their risk of developing VTE.
PubMed Answer	1. Diabetes Mellitus and the Risk of Venous Thromboembolism: A Systematic Review and Meta-Analysis of Prospective Studies. BMJ. 2011;343: d6593. doi: 10.1136/bmj.d6593 2. Venous Thromboembolism in Diabetes: A Systematic Review and Meta-Analysis. Journal of Thrombosis and Haemostasis: The Official Journal of the International Society on Thrombosis and Haemostasis. 2012;10(1):11-21. doi: 10.1111/j.1538-7836.2011.04633.x A: Yes, diabetes is associated with an increased risk of venous thromboembolism (VTE), as indicated by multiple systematic reviews and meta-analyses, including the studies cited in the question. The BMJ study from 2011 and the Journal of Thrombosis and Haemostasis study from 2012 both report that individuals with diabetes have a higher risk of developing VTE compared to those without diabetes.

جدول (5) عينة من أجابات النماذج

نلاحظ من الجدول 5، إن:

- اجابات النموذج PubMed مفصلة مع الاشارة إلى اول مقالتين حصل منهما النموذج على الاجابة، ووصلت دقة الاجابات إلى 100% بسبب الاعتماد على أهم المقالات العلمية من موقع PubMed
- أن اجابات النموذجLlama3 كانت مختصرة وأحيانا اقتصرت على الجواب بكلمة واحدة(Yes أو No)
- كانت دقة النموذجMistral هي الاعلى حيث وصلت إلى87% بالاعتماد فقط على ملفات PDF التي زودناه بها، ودون البحث في شبكة الانترنت.

كما يُبين الجدول6 مقارنة بين النماذج من ناحية دقة الاجابات وزمن الاستجابة.

LLM	Method	MIRAGE Benchmark Dataset					Avg.
		MMLU-Med	MedQA-US	MedMCQA	PubMedQA*	BioASQ-Y/N	
GPT-4 (-32k-0613)	CoT	89.44 ± 0.93	83.97 ± 1.03	69.88 ± 0.71	39.60 ± 2.19	84.30 ± 1.46	73.44
	MEDRAG	87.24 ± 1.01	82.80 ± 1.06	66.65 ± 0.73	70.60 ± 2.04	92.56 ± 1.06	79.97
GPT-3.5 (-16k-0613)	CoT	72.91 ± 1.35	65.04 ± 1.34	55.25 ± 0.77	36.00 ± 2.15	74.27 ± 1.76	60.69
	MEDRAG	75.48 ± 1.30	66.61 ± 1.32	58.04 ± 0.76	67.40 ± 2.10	90.29 ± 1.19	71.57
Mixtral (8×7B)	CoT	74.01 ± 1.33	64.10 ± 1.34	56.28 ± 0.77	35.20 ± 2.14	77.51 ± 1.68	61.42
	MEDRAG	75.85 ± 1.30	60.02 ± 1.37	56.42 ± 0.77	67.60 ± 2.09	87.54 ± 1.33	69.48
Llama2 (70B)	CoT	57.39 ± 1.50	47.84 ± 1.40	42.60 ± 0.76	42.20 ± 2.21	61.17 ± 1.96	50.24
	MEDRAG	54.55 ± 1.51	44.93 ± 1.39	43.08 ± 0.77	50.40 ± 2.24	73.95 ± 1.77	53.38
MEDITRON (70B)	CoT	64.92 ± 1.45	51.69 ± 1.40	46.74 ± 0.77	53.40 ± 2.23	68.45 ± 1.87	57.04
	MEDRAG	65.38 ± 1.44	49.57 ± 1.40	52.67 ± 0.77	56.40 ± 2.22	76.86 ± 1.70	60.18
PMC-LLaMA (13B)	CoT	52.16 ± 1.51	44.38 ± 1.39	46.55 ± 0.77	55.80 ± 2.22	63.11 ± 1.94	52.40
	MEDRAG	52.53 ± 1.51	42.58 ± 1.39	48.29 ± 0.77	56.00 ± 2.22	65.21 ± 1.92	52.92

Table: Benchmark results of different backbone LLMs on MIRAGE. All numbers are accuracy in percentages.

الجدول (6) مقارنة بين النماذج من حيث الدقة وسرعة الاستجابة

نلاحظ من الجدول 6 ان زمن استجابة نموذجيBioMistral و Mistral هو الافضل بينما يعتمد زمن استجابةPubMed على سرعة النت، كما نلاحظ أن ترتيب ودقة نموذج الMistral باستخدام تقنية الRAG يتوافق مع النتائج التي حصلنا عليها بحسب المقالة [56]، فهو يعتبر النموذج الأفضل بين النماذج مفتوحة المصدر.

3.6- التحديات والآفاق المستقبلية

التحديات

تواجه الأنظمة الذكية المتخصصة في إدارة أمراض السُكري باستخدام تقنية النماذج اللغوية الضخمة (LLMs) مجموعة من التحديات التي تؤثر على فعاليتها ودقتها.

أولاً، هناك تحدي الدقة والمصداقية، حيث تعتمد الأنظمة على كميات كبيرة من البيانات الطبية التي يجب أن تكون دقيقة ومحدثة باستمرار، وهذا الأمر يتطلب من المطورين استخدام مصادر موثوقة والتأكد من تحديث البيانات بشكل دوري لمواكبة التقدم السريع في المجال الطبي.

ثانياً، تتطلب هذه الأنظمة معايير عالية من الأمان والخصوصية لحماية المعلومات الصحية الحساسة للمرضى، حيث أن أي خرق أو تسرب للمعلومات قد يؤدي إلى فقدان الثقة بالنظام وحتى تعرض المستخدمين لمخاطر قانونية وصحية.

ثالثاً، يتطلب التكامل مع الأنظمة الصحية الحالية توافقًا تامًا مع سجلات المرضى الإلكترونية (EHRs) والبنية التحتية الصحية، مما يشكل تحديًا تقنيًا كبيرًا، فيجب أن يكون النظام قادرًا على العمل بشكل متكامل مع هذه الأنظمة لتوفير معلومات دقيقة في الوقت المناسب ودون تأخير.

رابعاً، التفاعل مع المستخدمين يمثل تحديًا آخر، حيث يجب تصميم واجهات مستخدم بديهية وسهلة الاستخدام لضمان أن يتمكن المرضى من التفاعل مع النظام بكفاءة دون الحاجة إلى تدريب مكثف.

خامساً، في مجال متسارع مثل الطب، يتعين على النظام أن يكون قادرًا على التحديث المستمر بمعلومات جديدة،و هذا يتطلب بنية تحتية قوية لتحديث البيانات والنماذج بشكل دوري، وأخيراً تمثل التكلفة والموارد تحديًا كبيرًا، حيث يتطلب تطوير وتشغيل أنظمة ذكاء اصطناعي متقدمة موارد مالية وبشرية كبيرة، كما يجب على المطورين إيجاد توازن بين تقديم حلول فعالة ومبتكرة وبين التكاليف المرتبطة بتطويرها وتشغيلها.

الآفاق المستقبلية

إن مستقبل تطوير الأنظمة الذكية المتخصصة في إدارة أمراض السُكري باستخدام تقنية النماذج اللغوية الضخمة (LLMs) يحمل العديد من الفرص الواعدة لتحسين جودة الرعاية الصحية وتقديم حلول مبتكرة، ومع تقدم الأبحاث والتطورات في هذا المجال، من المتوقع أن نشهد تحسينات كبيرة في دقة وفعالية هذه الأنظمة، حيث يمكن تحسين دقة نماذج LLMs من إتاحة المزيد من البيانات الطبية المُناسبة والمُخصصة لتدريب وتحسين النماذج، مما سيساهم في تقديم استشارات طبية أكثر دقة وشمولية للمرضى، وبالإضافة إلى ذلك، يمكن تعزيز التفاعل البشري مع الأنظمة الذكية من خلال تطوير واجهات مستخدم أكثر طبيعية وراحة، وذلك باستخدام تقنيات مثل *التعلم العاطفي والتفاعل الصوتي*، مما سيجعل تجربة المستخدم أكثر سهولة ويعزز من ثقة المرضى في هذه الأنظمة، كما أن التكامل الأوسع مع الأنظمة الصحية الحالية يعد من أهم الآفاق المستقبلية، حيث يمكن لهذا التكامل أن يسهل الوصول إلى المعلومات الطبية ويساهم في تقديم رعاية صحية متكاملة، يمكن تحقيق هذا من خلال تطوير معايير مفتوحة والتعاون بين مقدمي الرعاية الصحية وشركات التكنولوجيا لتوفير نظام متكامل يعمل بسلاسة.

بالإضافة إلى ذلك، يمكن تحسين النماذج BioMistral و Mistral والتي تتخصص في معالجة النصوص الطبية تقديم توصيات علاجية محدثة بناءً على أحدث الأبحاث والدراسات الطبية، مما يعزز من قدرة الأنظمة الذكية على تقديم استشارات صحية مبنية على الأدلة العلمية، وذلك من خلال دمجها مع نموذج PubMed و الأمر الذي يوفر نماذج لغوية ضخمة، ذكية، متخصصة، على دراية بأحدث الدراسات.

كما أن التوسع في المجالات الطبية الأخرى يعد من أهم الآفاق المستقبلية، حيث يمكن استخدام النماذج الذكية في مجالات طبية أخرى مثل أمراض القلب، والأورام، والأمراض النفسية، مما يفتح آفاقًا جديدة لتحسين الرعاية الصحية بشكل شامل.

أيضاً ، أن أحد أهم الآفاق المستقبلية هو دعم النماذج اللغوية الضخمة المختصة في مجال الرعاية الصحية مثل BioMistral و Mistral للغة العربية وعدم الإقتصار على الفرنسية والإنجليزية، كما هو الحال في نموذج Aya، اذا يتميز الأخير بدعمه للعديد من اللغات من بينها اللغة العربية، إلا أن أدائه لا يقارن بنموذج Mistral، ففي حال تم دعم النموذجين السابق ذكرهما سيعني هذا زيادة عدد المُستفيدين (الأطباء، المرضى) من هذا النماذج حول العالم.

3.7- المراجع

[1] American Diabetes Association. "Standards of Medical Care in Diabetes." Diabetes Care,2023.

[2] ruzit eabdu alwzzh, riad sinbil, “Querying structured databases using natural languages”, Higher Institute of Applied Sciences and Technology, 2023, Syria.

[3] Mikolov, T., et al. "Efficient Estimation of Word Representations in Vector Space." arXiv:1301.3781.

[4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017), Attention is All You Need. arXiv preprint arXiv:1706.03762.

[5] Devlin, J., et al. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." arXiv:1810.04805.

[6] Website: GitHub - openai/gpt-3: GPT-3: Language Models are Few-Shot Learners,Accessed at 2024/06/27.

[7] Website: bert/ TensorFlow code and pre-trained models for BERT, Accessed 2024/06/28.

[8] Website: GitHub - jvalegre/robert, Accessed 2024/06/28.

[9] Website: GitHub - huggingface/transformers-bloom-inference: Fast Inference Solutions for BLOOM, Accessed 2024/06/28.

[10] Wu, H., et al. "Deep learning for clinical natural language processing: a review." BMC Medical Informatics and Decision Making.

[11] T. Zhang, Z. Cai, C. Wang, M. Qiu, B. Yang, and X. He, “Smedbert: A knowledge-enhanced pre-trained language model with structured semantics for medical text,” arXiv preprint arXiv:2108.08983, 2021.

[12] Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J. (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. Bioinformatics, 36(4), 1234-1240.

[13] Development of a Liver Disease-Specific Large Language Model Chat Interface using Retrieval Augmented Generation, Mark J. Pletcher, Ki Lai, https://doi.org/10.1101/2023.11.10.23298364.

[14] Si, Y., Wang, J., & Roberts, K. (2019). Enhancing clinical text classification with label-informed feature embedding. Journal of biomedical informatics, 96, 103246.

[15] Du, J., Zhang, Y., & Han, J. (2021). AMuLaP: Adversarial Multi-label Augmentation for Text Classification. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, 5632-5643.

[16] Wang, Y., Wang, L., Rastegar-Mojarad, M., Moon, S., Shen, F., Afzal, N., Liu, H. (2018). Clinical information extraction applications: a literature review. Journal of Biomedical Informatics, 77, 34-49.

[17] Singhal, K., Azizi, S., Tu, T., Mahdavi, S. S., Wei, J., Chung, H. W., ... & Corrado, G. S. (2022). Large language models encode clinical knowledge. Nature, 610(7933), 123-128.

[18] Bickmore, T. W., Schulman, D., & Sidner, C. (2013). Automated interventions for multiple health beaviors using conversational agents. Patient education and counseling, 92(2), 142-148.

[19] X. Yang, N. PourNejatian, H. C. Shin, K. E. Smith, C. Parisien, C. Compas, C. Martin, M. G. Flores, Y. Zhang, T. Magoc et al., "Gatortron: A large language model for clinical natural language processing," medRxiv, pp. 2022–02, 2022.

[20] V. Lievin, C. E. Hother, and O. Winther, "Can large language models ´ reason about medical questions?" arXiv preprint arXiv:2207.08143, 2022.

[21] R. Taylor, M. Kardas, G. Cucurull, T. Scialom, A. Hartshorn, E. Saravia, A. Poulton, V. Kerkez, and R. Stojnic, "Galactica: A large language model for science," 2022

[22] K. Singhal, S. Azizi, T. Tu, S. S. Mahdavi, J. Wei, H. W. Chung, N. Scales, A. Tanwani, H. Cole-Lewis, S. Pfohl et al., "Large language models encode clinical knowledge," arXiv preprint arXiv:2212.13138, 2022.

[23] H. Nori, N. King, S. M. McKinney, D. Carignan, and E. Horvitz, "Capabilities of gpt-4 on medical challenge problems," arXiv preprint arXiv:2303.13375, 2023.

[24] Z. Liu, X. Yu, L. Zhang, Z. Wu, C. Cao, H. Dai, L. Zhao, W. Liu, D. Shen, Q. Li et al., "Deid-gpt: Zero-shot medical text deidentification by gpt-4," arXiv preprint arXiv:2303.11032, 2023.

[25] L. Yunxiang, L. Zihan, Z. Kai, D. Ruilong, and Z. You, "Chatdoctor: A medical chat model fine-tuned on llama model using medical domain knowledge," arXiv preprint arXiv:2303.14070, 2023.

[26] H. Xiong, S. Wang, Y. Zhu, Z. Zhao, Y. Liu, Q. Wang, and D. Shen, "Doctorglm: Fine-tuning your chinese doctor is not a herculean task," arXiv preprint arXiv:2304.01097, 2023.

[27] T. Han, L. C. Adams, J.-M. Papaioannou, P. Grundmann, T. Oberhauser, A. Loser, D. Truhn, and K. K. Bressem, "Medalpaca–an open-source ¨ collection of medical conversational ai models and training data," arXiv preprint arXiv:2304.08247, 2023.

[28] H. Wang, C. Liu, N. Xi, Z. Qiang, S. Zhao, B. Qin, and T. Liu, "Huatuo: Tuning llama model with chinese medical knowledge," 2023.

[29] C. Wu, X. Zhang, Y. Zhang, Y. Wang, and W. Xie, "Pmc-llama: Further finetuning llama on medical papers," arXiv preprint arXiv:2304.14454, 2023.

[30] S. Chang, C. Baian, L. Fangyu, F. Zihao, S. Ehsan, and N. Collier, "Visual med-alpaca: A parameter-efficient biomedical llm with visual capabilities," 2023. [Online]. Available: https: //cambridgeltl.github.io/visual-med-alpaca/

[31] C. Yirong, W. Zhenyu, X. Xiaofen, X. Zhipei, F. Kai, L. Sihang, W. Junhong, and X. Xiangmin, "Bianque-1.0: Improving the" question" ability of medical chat model through finetuning with hybrid instructions and multi-turn doctor qa datasets," 2023. [Online]. Available: https://github.com/scutcyr/BianQue

[32] K. Singhal, T. Tu, J. Gottweis, R. Sayres, E. Wulczyn, L. Hou, K. Clark, S. Pfohl, H. Cole-Lewis, D. Neal et al., "Towards expertlevel medical question answering with large language models," arXiv preprint arXiv:2305.09617, 2023.

[33] C. Peng, X. Yang, A. Chen, K. E. Smith, N. PourNejatian, A. B. Costa, C. Martin, M. G. Flores, Y. Zhang, T. Magoc et al., "A study of generative large language model for medical research and healthcare," arXiv preprint arXiv:2305.13523, 2023.

[34] H. Zhang, J. Chen, F. Jiang, F. Yu, Z. Chen, J. Li, G. Chen, X. Wu, Z. Zhang, Q. Xiao et al., "Huatuogpt, towards taming language model to be a doctor," arXiv preprint arXiv:2305.15075, 2023.

[35] G. Wang, G. Yang, Z. Du, L. Fan, and X. Li, "Clinicalgpt: Large language models finetuned with diverse medical data and comprehensive evaluation," arXiv preprint arXiv:2306.09968, 2023.

[36] J. Zhou, X. Chen, and X. Gao, "Path to medical agi: Unify domain-specific medical llms with the lowest cost," arXiv preprint arXiv:2306.10765, 2023.

[37] C. Li, C. Wong, S. Zhang, N. Usuyama, H. Liu, J. Yang, T. Naumann, H. Poon, and J. Gao, "Llava-med: Training a large language-and-vision assistant for biomedicine in one day," arXiv preprint arXiv:2306.00890, 2023.

[38] W. Gao, Z. Deng, Z. Niu, F. Rong, C. Chen, Z. Gong, W. Zhang, D. Xiao, F. Li, Z. Cao et al., "Ophglm: Training an ophthalmology large language-and-vision assistant based on instructions and dialogue," arXiv preprint arXiv:2306.12174, 2023.

[39] C. Yirong, X. Xiaofen, W. Zhenyu, and X. Xiangmin, "Soulchat: The" empathy" ability of the large model is improved by mixing and fine-tuning the data set of long text consultation instructions and multiple rounds of empathy dialogue," 6 2023. [Online]. Available: https://github.com/scutcyr/SoulChat

[40] M. Moor, Q. Huang, S. Wu, M. Yasunaga, C. Zakka, Y. Dalmia, E. P. Reis, P. Rajpurkar, and J. Leskovec, "Med-flamingo: a multimodal medical few-shot learner," arXiv preprint arXiv:2307.15189, 2023.

[41] Q. Jin, B. Dhingra, Z. Liu, W. W. Cohen, and X. Lu, "Pubmedqa: A dataset for biomedical research question answering," arXiv preprint arXiv:1909.06146, 2019.

[42] website: https://medium.com/@kanikaadik07/generative-ai-project-life-cycle-55ce9092e24a, Accessed At 2024/06/22.

[43] Website: https://huggingface.co/TheBloke/Mistral-7B-Instruct-v0.1-GGUF, Accessed At 2024/06/26.

[44] Website: https://huggingface.co/BioMistral/BioMistral-7B, Accessed At 2024/06/26.

[45] Website: https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct, Accessed At 2024/06/19.

[46] Website: https://huggingface.co/bartowski/aya-23-8B-GGUF, Accessed At 2024/06/18.

[47] Jacob, B., et al. "Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference." arXiv:1712.05877.

[48] Jenish Maharjan, Anurag Garikipati, Navan Preet Singh, Leo Cyrus, Mayank Sharma, Madalina Ciobanu, Gina Barnes, Rahul Thap, Qingqing, Ritankar, "OpenMedLM: Prompt engineering can out-perform fine-tuning in medical question-answering with open-source large language models", arXiv:2402.19371.

[49] Papineni, K., Roukos, S., Ward, T., & Zhu, W. J. (2002). "BLEU: a Method for Automatic Evaluation of Machine Translation." Proceedings of the 40th Annual Meeting on Association for Computational Linguistics, pp. 311-318.

[50] Lin, Chin-Yew. "ROUGE: A Package for Automatic Evaluation of Summaries." Workshop on Text Summarization Branches Out (WAS 2004), Association for Computational Linguistics (ACL), 2004.

[51] Wang, Alex, et al. "GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding." arXiv preprint arXiv:1804.07461 (2018).

[52] Website: GitHub - tatsu-lab/alpaca_eval: An automatic evaluator for instruction-following language models. Human-validated, high-quality, cheap, and fast., Accessed At 2024/06/30.

[53] Lewis, P., et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks." arXiv:2005.11401.

[54] Website: https://medium.com/google-cloud/building-and-evaluating-basic-and-advanced-rag-applications-with-llamaindex-and-gemini-pro-in-4a3676a97e78 Accessed at 2024/06/22.

[55] Website: https://haystack.deepset.ai/blog/mixtral-8x7b-healthcare-chatbot. Accessed at 2024/06/22.

[56] Guangzhi Xiong, Qiao Jin, Zhiyong Lu, Aidong Zhang, "Benchmarking Retrieval-Augmented Generation for Medicine", arXiv:2402.13178, 2024.